

MACHINE LEARNING ENGINEERING

FASE 5 | AULA 08 -

MONITORAMENTO DE CONTÊINERES E MODELOS EM PRODUÇÃO

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
MERCADO, CASES E TENDÊNCIAS	10
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS.....	12

EMSE

O QUE VEM POR AÍ?

Nesta aula, vamos fechar o ciclo de MLOps com foco em confiabilidade contínua. Você verá como monitorar contêineres, cluster e comportamento de modelos em produção para detectar problemas técnicos e estatísticos antes que impactem o negócio.

O objetivo é construir uma visão operacional completa, combinando métricas, logs, traces, indicadores de inferência e sinais de drift para transformar monitoramento em tomada de decisão.

HANDS ON

Nessa aula, veremos a instrumentação de um serviço de inferência com indicadores técnicos de plataforma e métricas de desempenho do modelo. Você acompanhará a leitura desses sinais em painéis e entenderá como correlacionar sintomas para chegar mais rápido à causa raiz.

A prática também inclui desenho de alertas orientados à ação, com priorização por impacto e definição de resposta operacional. Esse passo é essencial para evitar fadiga de alerta e melhorar o tempo de recuperação em incidentes.

Ao final, você terá um blueprint mínimo de observabilidade para ML em produção, incluindo monitoramento de infraestrutura, inferência e degradação estatística do modelo.

SAIBA MAIS

Observabilidade em ML: além de “saber se está no ar”

Em produção, não basta saber se o serviço responde. Em Machine Learning, um endpoint pode estar estável do ponto de vista técnico e ainda assim gerar valor ruim por degradação estatística. Por isso, observabilidade em ML precisa unir duas lentes:

- Lente de infraestrutura (saúde técnica);
- Lente de modelo (saúde preditiva).

Quando essas lentes são analisadas juntas, a equipe detecta problemas mais cedo e responde com mais precisão.

Temos três pilares complementares: métricas, logs e traces e cada um deles responde uma pergunta diferente:

- Métricas: “o que está piorando?”
- Logs: “o que aconteceu em detalhe?”
- Traces: “onde o fluxo está degradando?”

Usar apenas um pilar tende a gerar diagnóstico incompleto. A combinação dos três reduz tempo de investigação e melhora a qualidade da decisão operacional.

Monitoramento de contêineres e cluster Kubernetes

No nível de plataforma, acompanhar saúde de Pods, saturação de nós e eventos de escalonamento ajuda a prevenir indisponibilidade antes que ela seja percebida pelo usuário.

```
apiVersion: monitoring.coreos.com/v1
kind: ServiceMonitor
metadata:
  name: recomendacao-monitor
spec:
  selector:
    matchLabels:
```

```
    app: recomendacao-api
  endpoints:
    - port: http
      path: /metrics
      interval: 15s
```

Código-fonte 1 – Exemplo de ServiceMonitor (Prometheus Operator) para coletar métricas de inferência (YAML)

Fonte: Elaborado pelo autor (2026)

Sem coleta contínua, não existe histórico confiável para comparar comportamento normal com comportamento anômalo.

Monitoramento de inferência em tempo real

Para serviços síncronos, métricas de latência, taxa de erro e throughput devem ser segmentadas por rota, versão e tipo de payload. Métrica agregada demais esconde gargalos específicos.

```
apiVersion: monitoring.coreos.com/v1
kind: PodMonitor
metadata:
  name: recomendacao-pods
spec:
  selector:
    matchLabels:
      app: recomendacao-api
  podMetricsEndpoints:
    - port: http
      path: /metrics
      interval: 10s
```

Código-fonte 2 – Exemplo de PodMonitor para capturar métricas de pods específicos (YAML)

Fonte: Elaborado pelo autor (2026)

Esse nível de granularidade é o que permite responder com precisão: problema de rota, de versão de modelo, de infraestrutura ou de volume de tráfego.

Qualidade de modelo em produção e sinais de drift

Monitorar só infraestrutura deixa uma lacuna crítica. É necessário acompanhar distribuição de entrada, confiança das predições, estabilidade de score e sinais de drift.

- Data drift: mudança no perfil dos dados de entrada.
- Concept drift: mudança na relação entre entrada e alvo.

Cada tipo de drift exige resposta diferente: retreinamento, ajuste de threshold, revisão de feature pipeline ou rollback de versão.

Mini-case 1 - queda de performance sem erro HTTP: um serviço manteve disponibilidade alta, mas a conversão de negócio caiu. O monitoramento estatístico revelou mudança de distribuição de entrada. Com essa evidência, o time ajustou o pipeline e recuperou performance sem precisar escalar infraestrutura.

Alertas orientados à ação (e não ao ruído)

Um alerta útil precisa indicar impacto, prioridade e ação sugerida. Sem esse padrão, a equipe sofre fadiga de alerta e responde pior em incidentes críticos.

```
apiVersion: monitoring.coreos.com/v1
kind: PrometheusRule
metadata:
  name: ml-alertas
spec:
  groups:
    - name: inferencia-latencia
      rules:
        - alert: LatenciaP95Alta
          expr: histogram_quantile(0.95,
rate(http_request_duration_seconds_bucket[5m])) > 0.35
          for: 10m
          labels:
            severity: warning
          annotations:
            summary: "Latência 95% acima do limite"
            description: "Serviço de inferência com 95%
acima de 350ms por mais de 10 minutos."
```

Código-fonte 3 – Exemplo de regra de alerta para latência elevada (YAML)

Fonte: Elaborado pelo autor (2026)

SLOs e SLIs servem para conectar técnica e negócio. SLO define compromisso de qualidade; SLI mede comportamento real. Em ML, combine:

- SLIs técnicos: erro, latência, disponibilidade.
- SLIs de valor: qualidade preditiva e impacto em KPI de negócio.

Essa combinação evita otimização local (por exemplo, reduzir latência) sem impacto positivo real no produto.

Já sobre dashboards em camadas para decisão rápida, painéis devem ser desenhados por público e decisão:

- Executivo: saúde geral e tendência.
- Tático: serviços críticos e alertas ativos.
- Diagnóstico: detalhe técnico para investigação.

A clareza visual reduz tempo de interpretação e melhora coordenação durante incidentes.

Incidente e pós-incidente como parte da observabilidade

Observabilidade madura não termina na detecção. Ela inclui resposta, documentação de causa raiz e ações preventivas. Em ML, o pós-incidente deve avaliar tanto aspectos técnicos quanto estatísticos.

Sem esse ciclo de aprendizado, a equipe repete erros e mantém custo operacional elevado.

NÍVEL	CARACTERÍSTICA	LIMITAÇÃO PRINCIPAL	PRÓXIMO PASSO
Inicial	Métricas básicas de infraestrutura	Sem visão de modelo	Incluir indicadores estatísticos
Intermediária	Métricas + logs + alertas	Diagnóstico parcial de fluxo	Adicionar traces e playbooks
Avançada	Observabilidade técnica + estatística + resposta estruturada	Maior complexidade	Automatizar mitigação e retreinamento assistido

Tabela 1 – Maturidade de observabilidade
Fonte: Elaborado pelo autor (2026)

Erros comuns de adoção e mitigação

Erro comum 1: monitorar só disponibilidade de API.

Correção: incluir indicadores de qualidade de inferência e drift.

Erro comum 2: alertas sem contexto de ação.

Correção: definir severidade e playbook por tipo de incidente.

Erro comum 3: monitoramento desconectado da esteira de deploy.

Correção: usar sinais de produção como gate de promoção/rollback.

Observabilidade de contêineres e modelos é o mecanismo que fecha o ciclo de MLOps com confiabilidade real. Quando técnica, estatística e processo de resposta caminham juntos, o time sustenta qualidade em produção com menos surpresa e mais previsibilidade.

MERCADO, CASES E TENDÊNCIAS

Observabilidade aplicada a ML se consolidou como prioridade de mercado porque a operação moderna não aceita apenas “modelo no ar”; ela exige estabilidade técnica e qualidade preditiva sustentada no tempo.

Por isso, cresce a adoção de arquiteturas que unem métricas de infraestrutura, sinais de negócio e indicadores estatísticos de modelo em uma mesma camada de decisão.

Um caso real de referência é o da DeepL, que compartilha sua abordagem para monitorar modelos em produção e tratar a observabilidade como parte nativa da prática de MLOps. O material pode ser consultado [aqui](#).

A principal lição para esta aula é que monitoramento efetivo não depende só de ferramenta, mas de critérios de qualidade bem definidos e acionáveis.

As tendências apontam para a transição de dashboards reativos para mecanismos de detecção de anomalias com resposta semiautomatizada, incluindo playbooks de incidente, gatilhos para revalidação de modelo e governança de release mais rigorosa. Em termos práticos, o mercado caminha para observabilidade orientada a decisão, não apenas para visualização de dados.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, você integrou os principais fundamentos de observabilidade para produção de ML, entendendo que monitorar infraestrutura sem monitorar qualidade de modelo gera uma visão incompleta do sistema.

Você consolidou o papel de métricas, logs e traces no diagnóstico técnico, aprendeu a interpretar sinais de drift e viu como estruturar alertas e dashboards orientados à ação.

Também compreendeu que confiabilidade não termina na detecção de incidentes: ela depende de processo de resposta, aprendizado pós-incidente e conexão direta entre monitoramento e decisões de deploy.

Em síntese, fechamos o ciclo operacional da disciplina com uma visão prática de como sustentar serviços e modelos com qualidade no longo prazo.

REFERÊNCIAS

BURNS, B.; BEDA, J.; HIGHTOWER, K. **Kubernetes: Up and Running**. Sebastopol: O'Reilly Media, 2022.

KLEPPMANN, M. **Designing Data-Intensive Applications**. Sebastopol: O'Reilly Media, 2017.


KUENKEL, T. **Practical MLOps**. Birmingham: Packt, 2023.

EMEND

PALAVRAS-CHAVE

DevOps. Containers. Docker. Kubernetes.

EMSE



POSTECH