

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	14
REFERÊNCIAS.....	15

EMSE

O QUE VEM POR AÍ?

Neste capítulo introdutório ao aprendizado por reforço, embarcaremos em uma jornada para entender os fundamentos dessa poderosa abordagem de machine learning. Começaremos explorando os conceitos básicos do aprendizado por reforço, compreendendo como os agentes aprendem a tomar decisões através da interação com um ambiente.

Além disso, analisaremos a estrutura de recompensa e punição que guia o comportamento do agente, destacando a importância da exploração e exploração para o processo de aprendizagem.

Em seguida, avançaremos para entender os componentes essenciais de um problema de aprendizado por reforço, examinando o ambiente, o agente e a política de decisão. Veremos como o ambiente fornece feedback ao agente em forma de recompensas e como o agente aprende a maximizar essas recompensas ao longo do tempo.

Ao compreendermos a dinâmica entre esses elementos, estaremos preparados(as) para explorar algoritmos fundamentais de aprendizado por reforço, dando os primeiros passos na implementação de soluções inteligentes para uma variedade de problemas.

HANDS ON

O que é aprendizado por reforço? Nesta jornada, exploraremos os fundamentos dessa poderosa abordagem de machine learning. Entenderemos como os agentes aprendem a tomar decisões através da interação com o ambiente, analisando a estrutura de recompensa e punição que guia seu comportamento, e explicaremos os componentes essenciais: o ambiente, o agente e a política de decisão.

Além disso, descobriremos como o feedback do ambiente, em forma de recompensas, ajuda o agente a aprender e a maximizar essas recompensas ao longo do tempo. Esta compreensão nos preparará para explorar algoritmos fundamentais de aprendizado por reforço e implementar soluções inteligentes para diversos problemas.

SAIBA MAIS

A ideia de que aprendemos interagindo com nosso ambiente é provavelmente a primeira a nos ocorrer quando pensamos sobre a natureza da aprendizagem. Quando uma criança agita os braços ou observa seus arredores, ela não tem um professor explícito, mas uma conexão sensório-motora direta com seu ambiente.

Naturalmente, existe a presença dos pais que, para uma determinada tarefa ou ação, pode alertar para um ato de perigo ou, eventualmente, "reforçar" um comportamento que mapeie uma nova habilidade, afinal é sempre uma festa quando uma criança aprende a andar ou falar.

Exercitar essa conexão produz uma riqueza de informações sobre causa e efeito, sobre as consequências das ações e sobre o que fazer para alcançar objetivos. Ao longo de nossas vidas, tais interações são sem dúvida uma importante fonte de conhecimento sobre nosso ambiente e nós mesmos.

Se estamos aprendendo a dirigir um carro ou a manter uma conversa, estamos muito conscientes de como nosso ambiente responde ao que fazemos e buscamos influenciar o que acontece por meio de nosso comportamento. Aprender através da interação é uma ideia fundamental subjacente a quase todas as teorias de aprendizagem e inteligência.

Para exercitarmos um exemplo mais prático, pense em colocar uma criança para jogar um videogame que ela nunca experimentou, entregar o controle para ela e deixá-la sozinha para descobrir:




Figura 1 – Exemplo simplificado de Aprendizado por Reforço Real – Parte 1
Fonte: Huggingface (2024)

Essa criança irá interagir com o ambiente (o videogame) pressionando o botão direito (ação). Como receber uma moeda é uma recompensa de +1, passa a ser automaticamente entendível que um dos objetivos do jogo é coletar moedas.




Figura 2 – Exemplo simplificado de Aprendizado por Reforço Real – Parte 2
Fonte: Huggingface (2024)

Mas, então, ela pressiona o botão direito novamente e toca um inimigo. Ela acabou de morrer, o que é uma recompensa de -1.




Figura 3 – Exemplo simplificado de Aprendizado por Reforço Real – Parte 3
Fonte: Huggingface (2024)

Ao interagir com seu ambiente por tentativa e erro, essa criança entende que precisa conseguir moedas nele, mas evitar os inimigos também. Sem qualquer supervisão, a criança ficará cada vez melhor no jogo. É assim que humanos e animais

aprendem: através da interação. O Aprendizado por Reforço é apenas uma abordagem computacional de aprendizado a partir de ações.

No vasto campo da aprendizagem de máquina (Machine Learning - ML), o aprendizado por reforço (Reinforcement Learning - RL) destaca-se como uma abordagem única e poderosa e está contido na aprendizagem de máquina (sendo esta uma sub-área).

Enquanto o aprendizado supervisionado e o aprendizado não supervisionado são amplamente utilizados em uma variedade de tarefas, o aprendizado por reforço se destaca por sua capacidade de aprender através da interação direta com um ambiente, tomando decisões sequenciais para alcançar objetivos específicos.

O aprendizado supervisionado é frequentemente utilizado em problemas de classificação e regressão, em que o objetivo é aprender a mapear entradas para saídas com base em exemplos rotulados fornecidos durante o treinamento. Por exemplo: em um sistema de reconhecimento de imagens, um algoritmo de aprendizado supervisionado é treinado com um conjunto de imagens rotuladas para reconhecer e classificar objetos.

O aprendizado não supervisionado, por outro lado, é empregado quando os dados de treinamento não estão rotulados e o objetivo é encontrar estrutura nos dados, como agrupamentos ou padrões subjacentes.

Em contraste, o aprendizado por reforço difere fundamentalmente desses dois paradigmas. Enquanto no aprendizado supervisionado o modelo recebe exemplos rotulados para aprender uma função específica e no aprendizado não supervisionado o modelo busca encontrar estrutura nos dados sem orientação externa, no aprendizado por reforço o agente aprende a partir da experiência direta de interagir com um ambiente.

O agente toma ações em um ambiente e recebe feedback na forma de recompensas ou penalidades, aprendendo assim a associar ações com resultados desejados.



Figura 4 – Tipos de Aprendizado de Máquina
Fonte: Elaborado pelo autor (2024)

Outra distinção importante é que, no aprendizado por reforço, não é fornecido um conjunto fixo de exemplos de treinamento como no aprendizado supervisionado. Em vez disso, o agente deve explorar ativamente seu ambiente para aprender como maximizar as recompensas ao longo do tempo. Isso introduz o desafio da exploração versus exploração, em que o agente deve equilibrar a busca por novas estratégias com a utilização das estratégias já conhecidas para maximizar o retorno cumulativo ao longo de múltiplas interações.

Além disso, enquanto o aprendizado supervisionado e o aprendizado não supervisionado são tipicamente usados para resolver tarefas estáticas e independentes do tempo, o aprendizado por reforço é especialmente adequado para problemas sequenciais e dinâmicos, nos quais as ações tomadas em um momento influenciam as oportunidades futuras e o resultado final da tarefa.

De forma geral, o aprendizado por reforço se distingue do aprendizado supervisionado e não supervisionado pela sua ênfase na interação ativa com o ambiente, na aprendizagem sequencial de ações para alcançar objetivos e na ausência de um conjunto fixo de exemplos de treinamento. Vamos a um exemplo simplificado.

Embora pareça ser abstrato no início, o aprendizado por reforço já está em nosso cotidiano e na mídia em diversas soluções tecnológicas, embora inicialmente pareçam ser abordagens vindas de outras técnicas de aprendizado. Na maioria das vezes em que temos algum "agente autônomo" tomando decisões sozinho, muito possivelmente estamos lidando com alguma forma de aprendizado por reforço. Vamos citar alguns exemplos:

- **Aprimorando Recomendações Personalizadas:** um exemplo notável de aprendizado por reforço é seu uso na melhoria de sistemas de recomendação personalizados. Empresas como Netflix e Amazon têm aproveitado as aplicações bem-sucedidas de RL para refinar suas sugestões a usuários, aumentando significativamente sua experiência e satisfação.
- **Veículos Autônomos:** outro grande exemplo de aprendizado por reforço tem sido o desenvolvimento de veículos autônomos. Eles são um dos casos de uso de RL mais emocionantes do mundo real. Ao aplicar essa tecnologia, os carros podem entender e navegar melhor em ambientes complexos, tornando a tecnologia de direção autônoma mais segura e confiável.
- **Otimizando o Consumo de Energia:** na sustentabilidade, um exemplo destacado de aprendizado por reforço tem sido a otimização do consumo de energia em edifícios grandes. Isso não apenas reduz os custos como também contribui para os esforços de conservação ambiental.
- **Saúde:** exemplos de aprendizado por reforço na área da saúde demonstram seu potencial para personalizar planos de tratamento de pacientes. Isso traz benefícios adicionais, incluindo melhores resultados de saúde e uso mais eficiente dos recursos médicos.
- **Transformando Logística de Varejo:** no setor varejista, o aprendizado por reforço é usado para otimizar a logística e a gestão da cadeia de suprimentos. Isso resulta em uma gestão de estoque mais eficiente e custos operacionais reduzidos.
- **Estratégias de Negociação Financeira:** a indústria financeira também viu uma transformação com a aplicação de aprendizado por reforço no desenvolvimento de estratégias de negociação sofisticadas. Isso permite

um melhor gerenciamento de riscos e retornos potenciais sobre investimentos.

- **Eficiência na Manufatura:** processos de manufatura foram otimizados usando aprendizado por reforço, resultando em maior eficiência de produção e redução de desperdício.
- **Robótica:** na robótica, o aprendizado por reforço permite que os robôs aprendam e se adaptem a novas tarefas com intervenção mínima humana, abrindo assim novas possibilidades na automação.

O aprendizado por reforço também desempenha um papel fundamental na robótica ao revolucionar a maneira como os robôs aprendem e executam tarefas complexas. O RL permite que os robôs aprendam comportamentos autônomos através da interação com o ambiente sem a necessidade de programação manual extensiva.

Um exemplo claro é o treinamento de robôs para navegação autônoma em ambientes desconhecidos. Usando técnicas de aprendizado por reforço, os robôs podem explorar e mapear seu ambiente, aprender a evitar obstáculos e encontrar o caminho mais eficiente para completar uma tarefa específica. Isso é especialmente útil em ambientes dinâmicos, em que as condições podem mudar rapidamente.

Além disso, o RL é amplamente utilizado no desenvolvimento de robôs manipuladores, que são capazes de realizar tarefas físicas complexas como montagem, empacotamento e manipulação de objetos variados. Por meio do aprendizado por reforço, esses robôs podem aprender a realizar movimentos precisos e adaptar suas estratégias de acordo com as condições do ambiente e as características dos objetos.

Outra aplicação promissora do RL na robótica é no campo da interação humano-robô. Os robôs podem aprender a interpretar e responder de maneira adequada a ações e comandos humanos, tornando a colaboração entre humanos e robôs mais intuitiva e eficiente.

O Projeto GR00T da Nvidia, por exemplo, se destaca no cenário de RL para robôs humanoides por apresentar um modelo de fundação multimodal inovador.

Através da entrada multimodal, que combina linguagem natural e dados de interações passadas, o modelo gera ações para o robô executar, permitindo que ele aprenda em simulações seguras e transfira esse conhecimento para o mundo real. Essa abordagem supera as limitações tradicionais do RL, abrindo caminho para robôs mais autônomos, adaptáveis e inteligentes.




Figura 5 – Projeto GR00T da Nvidia
Fonte: Nvidia (2024)

- **Inteligência Artificial em Jogos:** a indústria de jogos utilizou o aprendizado por reforço para criar oponentes de IA mais desafiadores e realistas, melhorando a experiência de jogo para os jogadores.
- **Large Language Model e Sistemas baseados GPT:** o método RLHF (Reinforcement Learning with Human Feedback) é uma abordagem inovadora no treinamento de modelos de aprendizado por reforço, como o ChatGPT. Ele combina os princípios do aprendizado por reforço com a valiosa contribuição do feedback humano para melhorar a eficácia e a qualidade do treinamento do modelo.

No contexto do ChatGPT, o RLHF permite que o modelo não apenas aprenda com interações automáticas, mas também seja aprimorado com insights e correções

fornecidos por humanos. Isso é especialmente importante em cenários em que a compreensão e a sensibilidade contextual são essenciais, como na geração de respostas adequadas e pertinentes em conversas.

- **Gestão de Redes Inteligentes:** por fim, a gestão de redes inteligentes foi revolucionada no setor de energia com o aprendizado por reforço, garantindo distribuição e uso mais eficientes dos recursos energéticos.

Mas, afinal de contas, como funciona o aprendizado por reforço? Antes de começarmos é importante falarmos de alguns conceitos fundamentais que serão a base dessa linha de aprendizado até as nossas últimas aulas.

O aprendizado por reforço é uma abordagem de aprendizado de máquina em que um agente interage com um ambiente, como dito anteriormente, buscando aprender a melhorar suas ações ao longo do tempo para atingir um objetivo definido. Aqui estão os principais elementos do aprendizado por reforço:

- **Agente:** o agente é a entidade que está aprendendo e tomando decisões no ambiente. Pode ser um robô, um programa de computador ou qualquer sistema capaz de interagir com o ambiente e executar ações.
- **Ambiente:** o ambiente é o contexto no qual o agente está inserido. Pode ser real, como o mundo físico, ou virtual, como um ambiente simulado em um computador. O ambiente responde às ações do agente e fornece feedback sobre o estado atual e as consequências das ações.
- **Ações:** são as escolhas que o agente pode realizar em um determinado momento. Essas ações podem ter impacto no ambiente e influenciar as recompensas que o agente recebe.
- **Estado:** o estado representa a situação atual do ambiente em um determinado momento. É uma descrição das características relevantes do ambiente que afetam as decisões do agente e as consequências de suas ações. Também podemos chamar o estado de observações em algumas literaturas da área.
- **Recompensa:** a recompensa é o feedback imediato que o agente recebe do ambiente após realizar uma ação. Ela indica o quão boa ou ruim foi a

ação em relação ao objetivo do agente, que é maximizar a recompensa total ao longo do tempo.

- **Política:** a política define a estratégia do agente para selecionar ações em diferentes estados. Pode ser uma regra simples, uma função matemática ou até mesmo um algoritmo complexo que mapeia estados para ações.

Esses elementos interagem dinamicamente enquanto o agente explora e aprende com o ambiente, buscando encontrar uma política que maximize as recompensas ao longo do tempo. Falaremos um pouco mais sobre como funcionam as relações desses elementos e como eles são calibrados ao longo das próximas aulas.




Figura 6 – Visão Geral do Aprendizado por Reforço
Fonte: databasecamp (2022)

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, exploramos a ideia fundamental de que aprendemos interagindo com o ambiente, desde as primeiras experiências de uma criança até as complexas interações que enfrentamos ao longo da vida.

Vimos que o aprendizado por reforço é uma abordagem poderosa que se destaca no vasto campo da aprendizagem de máquina, permitindo que agentes aprendam a tomar decisões sequenciais para alcançar objetivos específicos através da interação direta com o ambiente.

Durante nossa discussão, exploramos os principais elementos do aprendizado por reforço, incluindo o papel do agente, do ambiente, das ações, dos estados, das recompensas e da política. Esses elementos formam a base para entender como os agentes aprendem e se adaptam ao ambiente ao longo do tempo, buscando maximizar as recompensas ao alcançar seus objetivos.

Ao longo das próximas aulas, continuaremos a explorar como esses elementos interagem e como podemos calibrá-los para melhorar o desempenho dos agentes em uma variedade de tarefas desafiadoras.

REFERÊNCIAS

DATABASECAMP. **Reinforcement Learning – simply explained!** 2022. Disponível em: <<https://databasecamp.de/en/ml/reinforcement-learnings>>. Acesso em: 18 jun. 2024.

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and Tensorflow**: Concepts, Tools, and Techniques to Build Intelligent Systems. 3. ed. Sebastopol: O'Reilly Media, 2022.

HUGGING FACE. **Deep Reinforcement Learning Course**. 2024. Disponível em: <<https://huggingface.co/learn/deep-rl-course>>. Acesso em: 18 jun. 2024.


NVIDIA. **NVIDIA Announces Project GR00T Foundation Model for Humanoid Robots and Major Isaac Robotics Platform Update**. 2024. Disponível em: <<https://nvidianews.nvidia.com/news/foundation-model-isaac-robotics-platform>>. Acesso em: 18 jun. 2024.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning**: An Introduction. 2. ed. Cambridge: MIT Press, 2018.

PALAVRAS-CHAVE

Palavras-chave: Aprendizagem por Reforço. Aprendizagem de Máquina. Recompensa.

EMSE



POSTECH