

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	15
REFERÊNCIAS.....	16

EMSE

O QUE VEM POR AÍ?

Neste capítulo sobre os fundamentos do aprendizado por reforço (RL), exploraremos os elementos essenciais que compõem esse poderoso paradigma de aprendizado de máquina. Primeiramente, abordaremos o conceito de agente, que é o tomador de decisões dentro do ambiente. O agente interage com o ambiente através de ações, buscando maximizar uma medida de desempenho ao longo do tempo.

Em seguida discutiremos o ambiente, que é tudo o que está fora do agente e com o qual ele interage. O ambiente pode ser simples ou complexo, determinístico ou estocástico e fornecer feedback imediato ou atrasado ao agente em resposta às suas ações.

Continuando, examinaremos o conceito de recompensa, que é a medida de feedback fornecida pelo ambiente ao agente após cada ação. A recompensa indica ao agente o quão boa ou ruim foi sua ação em relação ao objetivo final. Além disso, abordaremos a noção de política, que é a estratégia que o agente utiliza para selecionar ações com base em sua percepção do ambiente.

A política pode ser determinística ou estocástica, dependendo da aleatoriedade incorporada na seleção de ações. Ao compreendermos esses fundamentos, estaremos preparados(as) para explorar os algoritmos e técnicas avançadas que impulsionam o aprendizado por reforço e sua aplicação em uma variedade de domínios desafiadores.

HANDS ON

Mas afinal quais são os elementos do RL e quais são os tipos de algoritmos? Nessa aula veremos mais a fundo os elementos que compõem um RL e seus tipos baseado em modelos ou não, sendo que estes últimos podem ser divididos em modelos baseados em valor e modelos baseados em política.



SAIBA MAIS

Na aprendizagem por reforço (RL) um agente interage com um ambiente, tomando ações em diferentes estados e recebendo feedback na forma de recompensas, como citado anteriormente. Esse paradigma é fundamentalmente diferente de outros tipos de aprendizado de máquina, como o supervisionado e o não supervisionado, pois não requer exemplos rotulados ou dados de entrada-saída. Em vez disso, o agente aprende através da tentativa e erro, explorando o ambiente para descobrir quais ações resultam em recompensas positivas e quais devem ser evitadas.

No contexto da RL, um ambiente é formalizado como um processo de decisão de Markov (MDP) composto por um conjunto de estados, ações, recompensas e uma função de transição de estado. Os estados representam as diferentes situações em que o agente pode se encontrar, as ações são as decisões que o agente pode tomar e as recompensas são os sinais de feedback que o agente recebe após cada ação. A função de transição de estado define como o ambiente muda de um estado para outro em resposta às ações do agente.

Para formalizar um MDP, é necessário definir um conjunto de estados, um conjunto de ações disponíveis em cada estado, uma função de transição de estado, que descreve as probabilidades de transição entre os estados após a execução de uma ação, e uma função de recompensa, que atribui uma recompensa a cada transição estado-ação-estado.

Com esses elementos, o agente pode usar algoritmos de aprendizado por reforço para aprender uma política de decisão ótima, que determina qual ação tomar em cada estado para maximizar a recompensa acumulada ao longo do tempo. O MDP fornece um quadro formal e poderoso para modelar uma ampla gama de problemas de tomada de decisão sob incerteza, tornando-se uma ferramenta fundamental no campo da aprendizagem por reforço.




Figura 1 – A interação agente-ambiente em um processo de decisão de Markov
 Fonte: Sutton; Barto (2018)

Agora falaremos um pouco mais sobre esses elementos que formam o MDP. Vamos imaginar que estamos criando um agente inteligente para jogar um jogo de forma automática, o que também é chamado de bot.




Figura 2 – A interação agente-ambiente em um processo de decisão de Markov em um game
 Fonte: Huggingface (2024)

- Nosso **agente (bot)** recebe o estado S_0 do **ambiente** – recebemos o primeiro quadro do nosso jogo (Ambiente).
- Baseado no estado S_0 , o agente toma a decisão A_0 – assim nosso agente vai para a direita.

- Com a tomada da decisão A_0 o ambiente vai para um novo estado S_1 – esse estado S_1 seria um novo frame do jogo.
- O ambiente dá alguma recompensa R_1 ao Agente – como o agente não morreu ao executar a ação A_0 , a recompensa é positiva em +1.

Este loop do RL gera uma sequência de estado, ação, recompensa e próximo estado e esse ciclo é realizado até o término de um episódio, que pode ser passar a fase, morrer (veremos a ideia de episódio mais adiante) ou outro critério acerca do problema.

Neste processo a ideia central do RL é maximizar o retorno esperado, uma vez que o AR é baseado na hipótese da recompensa, que postula que todos os objetivos podem ser descritos como a maximização do retorno esperado (recompensa cumulativa esperada).

É por isso que no Aprendizado por Reforço, para ter o melhor comportamento, buscamos aprender a tomar ações que maximizem a recompensa cumulativa esperada, em outras palavras, o somatório de todas as recompensas obtidas em cada ação tomada. Assim, quanto melhor for a ação tomada maior vai ser a recompensa e o somatório dessas recompensas também será maior.

Vamos falar agora um pouco mais sobre **estados** e **observações**, ações e recompensa. Observações/Estados são as informações que nosso agente obtém do ambiente. No caso de um videogame, pode ser um quadro (uma captura de tela); no caso de um trader do mercado financeiro, pode ser o valor de uma determinada ação; no caso de um carro autônomo é mais complicado, pois envolve localização e sensores do carro, bem como todo o mapeamento do ambiente ao seu redor.

De forma geral, o que difere os estados das observações é que no estado temos toda a descrição de todos os estados do ambiente, ou seja, não temos nenhuma informação oculta ou dinâmica. Se nosso agente está em um determinado estado, temos a visibilidade de todos os outros estados possíveis. Um exemplo claro disso é um jogo de damas.



Figura 3 – Jogo de damas, um exemplo de ambiente com visibilidade de todos os estados
Fonte: Marchesano (2021)

Quando temos apenas uma visualização parcial do estado, há o que chamamos de observação. No Super Mario Bros, só vemos a parte do nível mais próxima do jogador e por isso recebemos uma observação.



Figura 4 – Jogo Super Mario Bros, exemplo de ambiente com visibilidade parcial do estado, sendo assim cada frame uma observação
Fonte: Nintendo (2024)

Assim como nos estados, as **ações** podem ser classificadas em dois tipos: ações discretas e contínuas. As ações discretas são aquelas em que as possibilidades

de ação são finitas. Por exemplo: no jogo Super Mario Bros temos apenas quatro ações possíveis: esquerda, direita, para cima (pular) e para baixo (agachar). Nas ações contínuas, temos possibilidades de ações infinitas, como em um carro autônomo em que as ações podem ser virar à direita 15° , $16,1^\circ$, $16,2^\circ$, buzinar, acelerar em uma determinada potência do motor, etc.

Ainda existem outros dois elementos importantes que precisamos citar que são a **recompensa acumulada** e o **fator de desconto**. A recompensa acumulada é a soma das recompensas recebidas pelo agente em cada etapa de interação com o ambiente, desde o início até o final de um episódio ou trajetória. Essa medida permite ao agente avaliar o sucesso de sua política de decisão em alcançar seus objetivos ao longo do tempo, refletindo não apenas as recompensas imediatas mas também aquelas obtidas ao longo de múltiplas etapas.

Assim, maximizar a recompensa acumulada é, muitas vezes, o objetivo principal do agente na aprendizagem por reforço, incentivando-o a tomar ações que levem a resultados positivos a longo prazo.

Além disso, o fator de desconto é um componente crucial na formulação da recompensa acumulada em RL. O fator de desconto, representado por γ (gama), determina a importância relativa das recompensas futuras em relação às recompensas imediatas. Um valor de γ próximo de 1 indica que as recompensas futuras têm um peso significativo na recompensa acumulada, enquanto um valor de γ próximo de 0 atribui mais peso às recompensas imediatas. Ao ajustar o fator de desconto, o agente pode controlar a importância de considerar, para mais ou para menos, as recompensas futuras.

Para quem gosta de um pouco de matemática, podemos escrever a recompensa acumulada e o fator de desconto da seguinte forma:

$$R(\tau) = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \gamma^3 r_{t+4} + \dots$$

Return: cumulative reward Gamma: discount rate

Trajectory (read Tau)
Sequence of states and actions

$$R(\tau) = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

Figura 5 – Cálculo do desconto acumulado e fator de desconto
Fonte: HuggingFace (2024)

Um outro conceito importante de RL é o que chamamos de **trade-off entre Exploration e Exploitation**. Nas nossas aulas vamos usar os termos em inglês, pois não há uma tradução ideal para o nosso idioma (a tradução literal seria Exploração para Exploration e Aplicação para Exploitation). Nesse trade-off, o agente enfrenta o dilema de escolher entre explorar novas ações para descobrir mais sobre o ambiente ou aplicar ações conhecidas para maximizar a recompensa imediata.

Ao realizar o Exploration, o agente corre o risco de perder oportunidades de obter recompensas elevadas a curto prazo, enquanto o Exploitation excessivo pode levar a decisões subótimas e a uma exploração ineficiente do espaço de ações e estados. Encontrar o equilíbrio certo entre **Exploration e Exploitation** é crucial para o sucesso do agente na aprendizagem por reforço, pois isso permite uma adaptação eficaz às mudanças no ambiente e uma exploração eficiente de estratégias promissoras.

Vamos imaginar um exemplo simples, um jogo em que um rato precisa coletar a maior quantidade de queijo possível sem morrer. Neste jogo, nosso rato pode ter uma quantidade infinita de queijos pequenos (+1 cada). Mas no topo do labirinto há uma soma gigantesca de queijo (+1000). Se focarmos apenas no Exploitation, nosso agente nunca alcançará a gigantesca soma de queijo.

Em vez disso, ele explorará apenas a fonte de recompensas mais próxima, mesmo que esta fonte seja pequena (exploração). Mas se nosso agente explorar um

pouco, poderá descobrir a grande recompensa (a pilha de queijo grande). Por isso precisamos equilibrar o quanto exploramos (Exploration) o meio ambiente e o quanto aplicamos o que sabemos (Exploitation) sobre o meio ambiente. Veremos mais adiante mecanismos que permitem esse equilíbrio ao longo do treinamento do agente de RL.




Figura 6 – Exemplo do trade-off entre Exploration e Exploitation
Fonte: HuggingFace (2024)

Um exemplo prático do trade-off entre Exploration e Exploitation pode ser encontrado em sistemas de recomendação online. Quando um site de comércio eletrônico sugere produtos relacionados com base nas compras anteriores do usuário, ele precisa equilibrar a apresentação de produtos semelhantes (Exploitation) com a apresentação de novos produtos que o usuário pode gostar (Exploration).

Se o site apenas sugere produtos semelhantes aos que o usuário já comprou, corre o risco de limitar suas opções e perder oportunidades de apresentar novos itens que possam ser interessantes. Por outro lado, se o site apresentar apenas novos produtos, pode frustrar o usuário ao não atender às suas preferências conhecidas.

Encontrar o equilíbrio certo entre explorar novas sugestões e explorar as preferências conhecidas é essencial para fornecer uma experiência de recomendação personalizada e satisfatória ao usuário.

Agora precisamos verificar como os algoritmos de RL efetivamente resolvem os problemas. Existem dois principais métodos: os métodos baseados em Políticas e os métodos baseados em Valor.

Os métodos baseados em política e baseados em valor são duas abordagens fundamentais na aprendizagem por reforço (RL), cada uma com suas próprias estratégias e técnicas distintas. Os métodos baseados em política focam diretamente na aprendizagem da política de decisão ótima do agente, ou seja, na estratégia para selecionar ações em cada estado para maximizar a recompensa acumulada.

Esses métodos buscam aprender a própria política, representando-a de forma explícita ou implícita, e iterando sobre ela para melhorar seu desempenho ao longo do tempo. Um exemplo comum de método baseado em política é o algoritmo de Monte Carlo, que estima a qualidade de uma política através da avaliação do retorno médio de episódios completos.




Figura 7 – Métodos baseados em Política
Fonte: HuggingFace (2024)

Por outro lado, os métodos baseados em valor visam aprender a função de valor, que avalia a qualidade de cada estado ou ação em relação à recompensa acumulada esperada. Esses métodos buscam calcular a função de valor ótima, que atribui um valor a cada estado ou ação com base em suas perspectivas de recompensa futura.

Um exemplo notável de método baseado em valor é o algoritmo de aprendizagem Q (Q-Learning), que estima a função de valor Q, representando a qualidade de tomar uma determinada ação em um determinado estado. Essa abordagem permite ao agente tomar decisões informadas selecionando ações com base nos valores Q mais altos. Veremos mais adiante em detalhes como funciona esse algoritmo.




Figura 7 – Métodos baseados em Valor
Fonte: HuggingFace (2024)

Embora os métodos baseados em política e baseados em valor abordem a aprendizagem por reforço de maneiras diferentes, ambos têm o objetivo final de capacitar o agente a tomar decisões inteligentes em seu ambiente. Enquanto os métodos baseados em política se concentram na aprendizagem da estratégia de ação direta, os métodos baseados em valor se concentram em avaliar as consequências de ações específicas em relação aos objetivos de longo prazo.

A escolha entre essas abordagens depende do problema em questão, das características do ambiente e das restrições computacionais disponíveis, sendo essencial compreender suas diferenças e aplicações para a implementação eficaz de soluções de aprendizado por reforço.

EMENDADO

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, exploramos a ideia fundamental de que aprendemos interagindo com o ambiente, desde as primeiras experiências de uma criança até as complexas interações que enfrentamos ao longo da vida.

Vimos também que o aprendizado por reforço é uma abordagem poderosa que se destaca no vasto campo da aprendizagem de máquina, permitindo que agentes aprendam a tomar decisões sequenciais para alcançar objetivos específicos através da interação direta com o ambiente.

Durante nossa discussão, exploramos os principais elementos do aprendizado por reforço, incluindo o papel do agente, do ambiente, das ações, dos estados, das recompensas e da política. Esses elementos formam a base para entender como os agentes aprendem e se adaptam ao ambiente ao longo do tempo, buscando maximizar as recompensas ao alcançar seus objetivos.

Ao longo das próximas aulas, continuaremos a explorar como esses elementos interagem e como podemos calibrá-los para melhorar o desempenho dos agentes em uma variedade de tarefas desafiadoras.

REFERÊNCIAS

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and Tensorflow**: Concepts, Tools, and Techniques to Build Intelligent Systems. 3. ed. Sebastopol: O'Reilly Media, 2022.

HUGGING FACE. **Deep Reinforcement Learning Course**. 2024. Disponível em: <<https://huggingface.co/learn/deep-rl-course>>. Acesso em: 18 jun. 2024.


MARCHESANO, B. **Fundos de investimento são como jogo de damas**: o tempo muda, as regras, não. 2021. Disponível em: <<https://www.seudinheiro.com/2021/colunistas/exile-on-wall-street/exile-on-wall-street-28-05/>>. Acesso em: 18 jun. 2024.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning**: An Introduction. 2. ed. Cambridge: MIT Press, 2018.

PALAVRAS-CHAVE

Palavras-chave: Aprendizagem por Reforço. Aprendizagem de Máquina. Recompensa.

EMSE



POSTECH