

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS.....	12

EMSE

O QUE VEM POR AÍ?

Neste capítulo, vamos explorar mais a fundo os métodos baseados em política, uma abordagem alternativa e amplamente utilizada para resolver problemas de aprendizado por reforço. Primeiro, definiremos o conceito de "política" (policy) no contexto de RL, entendendo como ela serve como uma estratégia que determina a próxima ação do agente com base em seu estado atual. Veremos como as políticas podem ser determinísticas ou estocásticas e as implicações de cada uma.

Em seguida diferenciaremos os métodos baseados em política dos métodos tradicionais de RL, como a função de Q-Value, que foca em aprender uma função de valor. Abordaremos as vantagens dos métodos baseados em política, como a eficiência na escolha de ações e a capacidade de lidar com espaços de ação contínuos, e suas desvantagens, como a potencial lentidão na convergência para a melhor política.

Discutiremos as duas categorias principais de métodos baseados em política: políticas iterativas e políticas de gradiente. Examinaremos como as políticas iterativas avaliam e melhoram repetidamente uma política através da Avaliação da Política e do Aprimoramento da Política. Veremos também como os métodos de políticas de gradiente estimam o gradiente da função objetivo e fazem pequenas atualizações para maximizar a recompensa.

Além disso, apresentaremos alguns dos algoritmos mais conhecidos baseados em políticas, como o REINFORCE, que utiliza métodos de Monte Carlo para estimar retornos esperados, e o framework Actor-Critic, que combina elementos de avaliação e ação. Exploraremos algoritmos avançados como Proximal Policy Optimization (PPO), Trust Region Policy Optimization (TRPO), Deep Deterministic Policy Gradient (DDPG), e Soft Actor-Critic (SAC), discutindo suas aplicações em ambientes complexos e de alta dimensionalidade.

HANDS ON

Neste aula mergulharemos nos métodos baseados em política para aprendizado por reforço, explorando como eles diferem dos métodos tradicionais. Definiremos o que é uma política e discutimos suas versões determinísticas e estocásticas.

Você descobrirá as vantagens dessas abordagens, especialmente em espaços de ação contínuos, e conhecerá os algoritmos mais populares, como REINFORCE, Actor-Critic, PPO, TRPO, DDPG e SAC.

Também veremos como essas técnicas estão revolucionando os Modelos de Linguagem de Grande Escala (LLMs), permitindo respostas mais precisas e interações mais naturais através do feedback humano.

SAIBA MAIS

Os métodos baseados em política são uma forma alternativa e muito utilizada para o tratamento de problemas de aprendizado por reforço. Para compreendê-los, precisamos definir primeiramente o que entendemos por "política" (policy) nesse contexto.

Como visto anteriormente, a política é uma estratégia que o agente usa para determinar a próxima ação com base em seu estado atual. Pode ser tanto determinística, em que ações claras são determinadas para cada estado possível, quanto estocástica, quando existe uma distribuição de probabilidade sobre as possíveis ações.

Os métodos baseados em política diferem dos métodos tradicionais de aprendizado por reforço, tais como a função de Valor-Q e o Temporal Difference Learning, que tentam aprender uma função de valor que informa o quanto uma determinada ação é boa ou ruim. Em vez disso, os métodos baseados em política tentam aprender a política ótima diretamente, ou seja: a sequência de ações que maximiza a recompensa ao longo do tempo.

Esses métodos têm várias vantagens. Por exemplo: eles permitem a escolha das ações sem a necessidade de selecionar a melhor ação a cada instante, como nos métodos baseados em valor. Isso permite que o processo de tomada de decisão seja mais eficiente. Além disso, os métodos baseados em política funcionam bem com espaços de ação contínua, em que a escolha ótima pode ser um valor real — por exemplo, selecionar a velocidade de um veículo.

A principal desvantagem dos métodos baseados em política é que eles podem ser lentos para convergir para a melhor política, pois exploram o espaço de políticas possíveis.

Existem duas categorias de métodos baseados em políticas: políticas **iterativas** e políticas de **gradiente**.

As políticas iterativas avaliam e melhoram repetidamente uma política. A avaliação da política estimará a recompensa esperada sob a política atual, enquanto a melhoria da política fará uma pequena mudança para uma nova política que é garantida ser melhor que a política atual, se tal política existir. Tal abordagem é

composta por dois processos principais: avaliação da política e aprimoramento da política.

- **Avaliação da Política (Policy Evaluation):** a avaliação da política é a fase em que estimamos a função valor para uma política específica π . Em outras palavras, queremos determinar a qualidade de cada estado no ambiente, dado que seguimos a política π . Em geral, usa-se uma abordagem iterativa de cálculo, começando com uma função de valor inicial arbitrária e, então, iterativamente atualizando as estimativas do valor até que elas convirjam para a função de valor da política.
- **Aprimoramento da Política (Policy Improvement):** após a avaliação da política, sabemos a qualidade esperada de cada ação em cada estado. Assim, podemos aprimorar nossa política tomando a ação que parece ser a melhor em cada estado, com base na função de valor que calculamos na etapa de avaliação da política. Portanto, para cada estado, a política é atualizada para escolher a ação que maximiza o retorno esperado.

O algoritmo básico de Políticas Iterativas segue os seguintes passos:

- Inicialize a política π aleatoriamente.
- Execute o Processo Iterativo repetidamente:
 - **Avaliação da Política:** avalie a função-valor da política π atual.
 - **Aprimoramento da Política:** melhore a política usando a função-valor avaliada.
 - Continue até que a política π convirja, ou seja, não haja nenhuma mudança entre os valores de função sucessivos ou a mudança seja muito pequena (menos que um pequeno valor ϵ predefinido).

O aspecto mais atrativo deste método é que ele garante a convergência para a política ótima, pelo menos teoricamente. No entanto, ele pode ser computacionalmente intensivo na prática, especialmente para espaços de estado-ação muito grandes.

Os métodos de políticas de gradiente, por outro lado, estimam o gradiente da função objetivo sobre os parâmetros da política e realizam pequenas atualizações na direção que maximiza a recompensa. Esse gradiente pode ser estimado usando a técnica de retorno esperado ou via gradiente determinado por uma técnica denominada de "Reinforce". Diversos algoritmos foram desenvolvidos em cima desta linha e a imensa maioria dos algoritmos mais utilizados hoje são métodos de políticas de gradiente:

- **REINFORCE (Monte Carlo Policy Gradient):** este é um algoritmo básico baseado em políticas de gradiente que usa o método de Monte Carlo para estimar os retornos esperados. Ele atualiza os pesos da política proporcionalmente ao gradiente da recompensa total com relação aos parâmetros da política.
- **Actor-Critic Methods:** este é um framework que combina elementos de avaliação (critic) e ação (actor) em um único modelo. O ator (policy network) determina a ação a ser tomada, assumindo a posição de agente, e o crítico (value network) avalia a ação tomada pelo ator. Exemplos incluem A2C (Advantage Actor-Critic) e A3C (Asynchronous Advantage Actor-Critic).

Este framework é largamente utilizado para diversos problemas de RL e combina um método de valor semelhante ao DQN, que comentamos anteriormente, com um método de política.




Figura 1 - A2C-Advantage Actor Critic
Fonte: Khandelwal (2023)

- **Proximal Policy Optimization (PPO):** o PPO é uma abordagem de aprendizado por reforço que otimiza uma política parametrizada usando uma forma objetiva que impõe uma restrição de proximidade aos parâmetros anteriores. Isso ajuda a evitar grandes atualizações na política, o que pode ocasionar instabilidade.




Figura 2 - Utilização de PPO no jogo Doom
Fonte: Peng (2018)

Uma das aplicações lúdicas que são largamente testadas usando PPO é o jogo Doom, em que o agente e o crítico recebem do ambiente um conjunto de frames, a imagem do jogo mesmo, que é interpretada por uma rede neural convolucional (especialista na interpretação de imagens) juntamente com informações de munição e vitalidade do agente.

- **Trust Region Policy Optimization (TRPO):** TRPO é outro algoritmo que visa melhorar a estabilidade das atualizações de política em comparação com métodos mais simples, como REINFORCE. Ele controla a magnitude das atualizações de política para garantir que a nova política não se desvie muito da antiga.
- **Deep Deterministic Policy Gradient (DDPG):** o DDPG estende métodos de políticas determinísticas para espaços de ação contínuos. Ele combina elementos de DPG (Deterministic Policy Gradient) com redes neurais profundas para aprendizado em ambientes complexos.
- **Soft Actor-Critic (SAC):** SAC é um algoritmo de aprendizado por reforço que visa maximizar tanto a recompensa esperada quanto a entropia da política, promovendo exploração em ambientes de aprendizado.

Uma utilização bem recente, do nosso cotidiano, de RL baseado em políticas tem sido uma abordagem promissora para aprimorar Modelos de Linguagem de Grande Escala (LLMs), como os modelos de GPT da OpenAI e Gemini do Google. Métodos como o Proximal Policy Optimization (PPO) e o Trust Region Policy Optimization (TRPO) são usados para ajustar as políticas dos modelos, permitindo que eles aprendam e melhorem a partir do feedback recebido.

Esses métodos ajudam a otimizar a tomada de decisões dos modelos, ajustando suas respostas para maximizar uma função de recompensa definida, que pode incluir critérios como coerência da resposta, relevância e utilidade para o usuário. O uso de RL baseado em políticas é particularmente útil para treinar LLMs em tarefas complexas nas quais a supervisão direta não é viável ou eficaz, promovendo uma aprendizagem mais dinâmica e adaptativa.

Além disso, a aplicação de RL em LLMs permite a incorporação de feedback humano no loop de treinamento, conhecido como Human-in-the-Loop (HITL) learning.

Neste processo, as respostas geradas pelo modelo são avaliadas por humanos e usadas para refinar as políticas de decisão do modelo.

Isso é essencial para alinhar melhor LLMs com expectativas humanas, especialmente em áreas sensíveis, como atendimento ao cliente, em que a precisão e a empatia são cruciais. Ao integrar métodos de RL baseados em políticas, os LLMs não apenas melhoram sua performance técnica como também se tornam mais alinhados com os valores e necessidades dos usuários, resultando em interações mais naturais e satisfatórias.

EUROPE

O QUE VOCÊ VIU NESTA AULA?

Os métodos baseados em política são uma abordagem alternativa e bastante utilizada em problemas de aprendizado por reforço. Esses métodos se concentram em aprender a política ótima diretamente, ou seja, a sequência de ações que maximiza a recompensa ao longo do tempo.

Diferentemente dos métodos tradicionais, como os métodos baseados em valor que aprendem uma função de valor para determinar a qualidade de uma ação, os métodos baseados em política permitem que o processo de tomada de decisão seja mais eficiente e funcione bem com espaços de ação contínua. No entanto, uma desvantagem é a lentidão na convergência para a melhor política.

Esses métodos se dividem em duas categorias principais: políticas iterativas, que avaliam e melhoram repetidamente uma política, e políticas de gradiente, que estimam o gradiente da função objetivo sobre os parâmetros da política e fazem pequenas atualizações para maximizar a recompensa.

Entre os algoritmos mais conhecidos baseados em políticas estão o REINFORCE, que utiliza métodos de Monte Carlo para estimar retornos esperados, e o Actor-Critic, que combina elementos de avaliação e ação em um único modelo. Além disso, métodos como o Proximal Policy Optimization (PPO) e o Trust Region Policy Optimization (TRPO) são amplamente utilizados para melhorar a estabilidade das atualizações de política.

O Deep Deterministic Policy Gradient (DDPG) e o Soft Actor-Critic (SAC) são também exemplos de algoritmos avançados utilizados em ambientes complexos. Recentemente, esses métodos têm sido aplicados para aprimorar Modelos de Linguagem de Grande Escala (LLMs), como os modelos GPT da OpenAI e Gemini do Google.

O uso de RL baseado em políticas permite que os LLMs aprendam e melhorem a partir do feedback recebido, otimizando suas respostas e alinhando-se melhor com as expectativas humanas através do processo de Human-in-the-Loop (HITL) learning.

REFERÊNCIAS

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and Tensorflow**: Concepts, Tools, and Techniques to Build Intelligent Systems. 3. ed. Sebastopol: O'Reilly Media, 2022.

HUGGING FACE. **Deep Reinforcement Learning Course**. 2024. Disponível em: <<https://huggingface.co/learn/deep-rl-course>>. Acesso em: 18 jun. 2024.

KHANDELWAL, R. **Unlocking the Secrets of Actor-Critic Reinforcement Learning: A Beginner's Guide**. 2023. Disponível em: <<https://arshren.medium.com/unlocking-the-secrets-of-actor-critic-reinforcement-learning-a-beginners-guide-3c5953b13551>>. Acesso em: 18 jun. 2024.


PENG, C.; ZHANG, J.; HUI, P. **A survey of network pricing for smart grid**. In: 2018 IEEE Power & Energy Society General Meeting (PESGM). Anais... Portland: IEEE, 2018. Disponível em: <<https://ieeexplore.ieee.org/document/8490423>>. Acesso em: 18 jun. 2024.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning**: An Introduction. 2. ed. Cambridge: MIT Press, 2018.

PALAVRAS-CHAVE

Palavras-chave: Aprendizagem por Reforço. Aprendizagem de Máquina. Recompensa.

EMAP



POSTECH