

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	13
REFERÊNCIAS.....	14

EMSE

O QUE VEM POR AÍ?

Prepare-se para mergulhar em uma abordagem inovadora e poderosa para a resolução de problemas complexos de tomada de decisão sequencial. Agora, exploraremos os métodos de Aprendizado por Reforço (RL) baseados em modelo, que se destacam por construir um modelo explícito do ambiente.

Diferentemente dos métodos tradicionais, essa abordagem permite que o agente simule diferentes ações e antecipe suas consequências antes de implementá-las no mundo real, otimizando suas estratégias com maior eficiência.

Os métodos baseados em modelo oferecem uma vantagem significativa: a capacidade de planejamento. Com técnicas avançadas, esses métodos permitem que o agente preveja e avalie os resultados de suas ações futuras, acelerando o processo de aprendizado e aumentando a precisão das decisões.

No entanto, a eficácia desses métodos depende da construção de um modelo preciso do ambiente, um desafio contínuo que exige adaptação e atualização constante.

Além disso, exploraremos a aplicação dos modelos multi-agente em RL, uma extensão significativa das abordagens tradicionais. Em um cenário multi-agente, vários agentes aprendem e tomam decisões simultaneamente em um ambiente compartilhado. Esses agentes podem cooperar, competir ou agir de maneira independente, resolvendo problemas mais complexos e escaláveis, como a gestão de tráfego e redes de telecomunicações.

A interação entre agentes permite a exploração de estratégias emergentes, resultando em comportamentos complexos e adaptáveis. Embora desafiadora, a coordenação eficaz entre agentes apresenta um potencial imenso para enfrentar problemas reais com maior eficiência e especialização.

HANDS ON

Nesta aula navegaremos nos métodos de Aprendizado por Reforço baseados em modelo, uma abordagem poderosa que permite ao agente simular ações e planejar estrategicamente antes de executá-las no ambiente real.

Exploraremos como a construção de modelos precisos do ambiente possibilita um aprendizado mais eficiente e eficaz, destacando técnicas avançadas como Dyna-Q, MCTS, AlphaZero e MBPO. Além disso, veremos aplicações práticas incríveis, desde a otimização de consumo de energia em data centers do Google até a condução autônoma e sistemas de negociação financeira.

Prepare-se para descobrir como o RL baseado em modelo está revolucionando a tomada de decisão sequencial e elevando o potencial da inteligência artificial a novos patamares!

SAIBA MAIS

Os métodos de Aprendizado por Reforço (RL) baseados em modelo representam uma abordagem poderosa e distinta para resolver problemas de tomada de decisão sequencial. Diferentemente dos métodos baseados em valor e baseados em políticas, o RL baseado em modelo envolve a construção de um modelo explícito do ambiente que o agente está tentando otimizar.

Esse modelo pode prever as transições de estado e as recompensas futuras, permitindo que o agente simule diferentes ações e escolha a melhor estratégia antes mesmo de executá-las no ambiente real. A construção e utilização de um modelo interno do ambiente permitem ao agente planejar suas ações de maneira mais informada, aumentando potencialmente a eficiência e eficácia do processo de aprendizado.

Uma das principais vantagens dos métodos baseados em modelo é a capacidade de planejamento. Com um modelo do ambiente, o agente pode usar técnicas de planejamento como a busca em árvore (por exemplo, MCTS - Monte Carlo Tree Search) para prever e avaliar as consequências de suas ações futuras.

Isso contrasta com os métodos baseados em valor, que costumam aprender diretamente a partir das interações com o ambiente e podem necessitar de muitas experiências para convergir para uma política ótima. Os métodos baseados em modelo, ao utilizar simulações, podem explorar diferentes estratégias em um espaço de busca menor, acelerando o processo de aprendizado.

No entanto, a eficácia dos métodos baseados em modelo depende fortemente da precisão do modelo do ambiente. Um modelo impreciso ou enviesado pode levar a previsões erradas, resultando em políticas subótimas. Portanto, um desafio crucial é a construção e atualização contínua de um modelo preciso do ambiente.

Técnicas como o aprendizado dinâmico de modelos, em que o modelo do ambiente é constantemente ajustado com base nas novas experiências do agente, são essenciais para manter a eficácia desses métodos. Além disso, a combinação de métodos baseados em modelo com técnicas de aprendizado por reforço sem modelo pode criar abordagens híbridas robustas, que se beneficiam tanto do planejamento antecipado quanto da adaptação dinâmica.

Aplicações práticas dos métodos de RL baseado em modelo são vastas e variam desde jogos, em que a simulação de ações futuras pode ser explorada intensivamente, até robótica, em que o planejamento e a previsão são críticos para a execução de tarefas complexas em ambientes dinâmicos. Em sistemas de recomendação, por exemplo, um modelo do comportamento do usuário pode prever a satisfação futura com base em sequências de interações passadas, permitindo recomendações mais personalizadas e eficazes.

Os algoritmos de aprendizado por reforço baseados em modelos diferem significativamente das técnicas tradicionais de RL, como os algoritmos baseados em valor e em política. As principais diferenças incluem a forma como cada abordagem utiliza informações do ambiente e a eficiência do processo de aprendizado. Estes algoritmos constroem e utilizam um modelo explícito do ambiente que prevê as transições de estado e recompensas futuras.

Essa modelagem permite que o agente planeje suas ações simulando cenários futuros antes de executá-las no ambiente real. É como se o nosso agente analisasse diversas consequências futuras antes de tomar a ação, como em um jogo de xadrez no qual analisamos as jogadas futuras para a tomada de decisão. Embora seja uma boa coincidência, os algoritmos de RL baseados em modelos são muito utilizados para jogos como o xadrez, algo que seria impossível ser feito por meio de métodos baseados em valor e muito difícil para métodos baseados em política.

Quanto ao processo de aprendizagem, devido ao uso de simulações, esses algoritmos tendem a ser mais sample-efficient, ou seja, podem aprender mais rapidamente com menos interações reais com o ambiente. Ao simular múltiplas trajetórias, eles podem explorar uma gama maior de possíveis ações e resultados, ajustando suas políticas de forma mais informada.

Os principais algoritmos baseados em modelos RL utilizam um modelo explícito do ambiente para prever transições de estado e recompensas, permitindo um planejamento mais eficiente das ações. São eles:

- **Dyna-Q:** combina elementos de RL baseado em modelo e sem modelo. O agente aprende uma política através de interações diretas com o ambiente (aprendizado sem modelo) e, simultaneamente, utiliza um modelo do ambiente para simular experiências adicionais (aprendizado baseado em

modelo). Isso acelera o processo de aprendizado ao usar simulações para reforçar o conhecimento obtido das interações reais, permitindo um aprendizado mais rápido e eficiente.

- **Monte Carlo Tree Search (MCTS):** é um método de busca heurística usado para planejar ações em espaços de estados grandes e complexos, comum em jogos. O MCTS constrói uma árvore de possíveis ações e estados resultantes, utilizando simulações de Monte Carlo para estimar o valor das ações. Ele é eficaz em ambientes nos quais as transições e recompensas podem ser simuladas rapidamente, como em jogos de tabuleiro, oferecendo um equilíbrio entre exploração e exploração.
- **AlphaZero:** é uma extensão avançada do MCTS combinada com redes neurais profundas para avaliar estados e políticas. O AlphaZero aprende a partir de jogos simulados contra si mesmo, utilizando um modelo treinado para prever tanto a política quanto o valor de cada estado. Esse algoritmo demonstrou desempenho superior em jogos complexos como xadrez, Go e Shogi, aprendendo estratégias de alto nível de maneira autodidata.



Figura 1 - Comparativo AlphaZero com outros modelos de RL em ambientes de jogos de tabuleiro com Xadrez, Shogi e Go
Fonte: Silver et al. (2018)

- **Model-Based Policy Optimization (MBPO):** é uma abordagem que utiliza modelos dinâmicos para melhorar a eficiência do aprendizado de políticas. O MBPO envolve a geração de transições simuladas a partir do modelo do ambiente e a otimização da política utilizando essas transições simuladas, além das interações reais. Isso permite um aprendizado de políticas mais sample-efficient, reduzindo a necessidade de interações extensivas com o ambiente real.
- **PETS (Probabilistic Ensembles with Trajectory Sampling):** utiliza ensembles de modelos probabilísticos (combinação de modelos probabilísticos) para capturar a incerteza no ambiente e realizar amostragens de trajetórias. O PETS usa essas trajetórias simuladas para planejar ações otimizadas, ajustando as políticas com base nas previsões probabilísticas do modelo. Esse algoritmo é eficaz em ambientes estocásticos e incertos, em que a precisão do modelo é crítica para o desempenho do agente.

Uma das aplicações reais mais significativas de aprendizado por reforço baseado em modelo é seu uso pela DeepMind para otimizar o consumo de energia nos data centers do Google. Essa aplicação envolveu a implantação de um sistema de IA que captura instantâneos de dados dos data centers a cada cinco minutos.

O sistema usa esses instantâneos para prever como diferentes combinações de ações afetarão o consumo futuro de energia, identificando ações que minimizam o uso de energia enquanto mantêm padrões de segurança. A implementação deste sistema de IA levou a uma redução de 40% nos gastos com energia nos data centers, demonstrando o potencial do RL baseado em modelo na gestão e otimização de sistemas complexos em tempo real.

Outro exemplo proeminente é a aplicação de RL baseado em modelo na condução autônoma. Empresas como a Wayve estão utilizando esses algoritmos para melhorar as capacidades de tomada de decisão de carros autônomos.

Os modelos preveem os resultados de várias ações de condução em ambientes do mundo real, permitindo que os carros naveguem em cenários complexos de forma mais eficaz. Essa abordagem melhora a segurança e a eficiência, uma vez que os

modelos podem antecipar e responder a mudanças dinâmicas no ambiente de condução.



Figura 2 - Modelo de simulação da Wayve usando RL
Fonte: Wayve (2024)

No setor financeiro, o RL baseado em modelo foi adotado para sistemas de negociação automatizada. Esses sistemas usam modelos preditivos para estimar as condições futuras do mercado e tomar decisões de negociação que otimizam os retornos.

A IBM, por exemplo, desenvolveu uma plataforma sofisticada baseada em RL que automatiza a negociação financeira ajustando continuamente sua estratégia com base no feedback do mercado. Isso permite decisões de negociação mais consistentes e lucrativas em comparação com abordagens tradicionais dirigidas manualmente.

O RL baseado em modelo também tem aplicações significativas na área da saúde, particularmente no desenvolvimento de planos de tratamento personalizados. Algoritmos de RL baseados em modelos podem otimizar regimes de tratamento dinâmico (DTRs) para doenças crônicas, aprendendo com os dados dos pacientes para tomar decisões de tratamento dependentes do tempo.

Essa abordagem tem se mostrado benéfica para melhorar os resultados de saúde a longo prazo, adaptando os tratamentos às necessidades individuais dos pacientes e considerando os efeitos retardados das intervenções médicas.

Além das três estratégias que vimos até agora, métodos baseados em valor, métodos baseados em política e métodos baseados em modelos, temos também os modelos multi-agente.

Os modelos multi-agente em aprendizado por reforço representam uma extensão significativa das abordagens tradicionais de RL, que tipicamente envolvem um único agente interagindo com um ambiente estático ou dinâmico. Em um cenário multi-agente, vários agentes aprendem e tomam decisões simultaneamente em um ambiente compartilhado.

Esses agentes podem cooperar, competir ou agir de maneira independente, conforme os objetivos definidos para cada um. Essa complexidade adicional exige métodos sofisticados de coordenação e comunicação entre os agentes para alcançar resultados desejáveis.



Figura 3 - Vários robôs precisam navegar para carregar e descarregar pacotes
Fonte: Freepik (2024)

Uma das vantagens principais dos modelos multi-agente é a capacidade de resolver problemas mais complexos e escaláveis, que são impraticáveis para um único agente. Em sistemas nos quais a decisão depende de múltiplos fatores ou a divisão de tarefas é necessária, como na gestão de tráfego, redes de telecomunicações e jogos multi-jogador, os agentes podem especializar-se em diferentes subtarefas e colaborar para melhorar a eficiência geral do sistema.

Por exemplo: em um sistema de controle de tráfego, diferentes agentes podem gerenciar sinais de trânsito em diferentes interseções, comunicando-se entre si para otimizar o fluxo de veículos em toda a rede.




Figura 4 - Carro autônomo inteligente dirigindo e fazendo varreduras para observar a distância entre outros veículos para o sistema de frenagem automática
Fonte: Freepik (2024)

Além disso, os modelos multi-agente permitem a exploração de estratégias emergentes através da interação entre agentes. Quando agentes competem ou colaboram, eles podem desenvolver comportamentos complexos que não seriam possíveis em um cenário de agente único. Essa dinâmica é particularmente útil em jogos e simulações de mercado, em que a adaptabilidade e a capacidade de prever as ações de outros agentes são cruciais. Através de interações repetidas, os agentes

podem aprender a antecipar as ações uns dos outros, levando a estratégias mais robustas e adaptáveis.

Contudo, a implementação de modelos multi-agente apresenta desafios significativos. A coordenação eficaz entre agentes requer mecanismos de comunicação e consenso, o que pode ser computacionalmente intensivo e complicado de se ajustar corretamente.

Além disso, o equilíbrio entre exploração e exploração torna-se mais complexo em um ambiente em que múltiplos agentes estão simultaneamente tentando otimizar suas políticas. Ainda assim, as vantagens de se utilizar RL multi-agente em termos de escalabilidade, especialização e comportamento emergente fazem dessa abordagem uma ferramenta poderosa para enfrentar uma ampla gama de problemas reais.

O QUE VOCÊ VIU NESTA AULA?

Os métodos de Aprendizado por Reforço (RL) baseado em modelo representam uma abordagem poderosa para a tomada de decisão sequencial. Ao contrário dos métodos baseados em valor e política, essa técnica constrói um modelo explícito do ambiente, permitindo ao agente simular ações e antecipar suas consequências antes de executá-las.

Isso resulta em um processo de aprendizado mais eficiente e eficaz, visto que o agente pode planejar suas ações com base em previsões de transições de estado e recompensas futuras.

Uma das principais vantagens do RL baseado em modelo é a capacidade de planejamento detalhado, usando técnicas avançadas para prever e avaliar ações futuras. Isso contrasta com os métodos baseados em valor, que requerem muitas interações com o ambiente para aprender.

Contudo, a eficácia desses métodos depende da precisão do modelo do ambiente, que deve ser constantemente ajustado com novas experiências para evitar previsões erradas e políticas subótimas. Abordagens híbridas que combinam métodos baseados em modelo e sem modelo também são exploradas para maximizar a eficiência e adaptação.

Adicionalmente, os modelos multi-agente em RL ampliam significativamente as capacidades das abordagens tradicionais. Em um ambiente compartilhado, vários agentes podem cooperar, competir ou agir de forma independente para resolver problemas mais complexos e escaláveis, como a gestão de tráfego e redes de telecomunicações.

A interação entre agentes permite o desenvolvimento de estratégias emergentes e comportamentos adaptáveis, embora a coordenação eficaz entre eles apresente desafios significativos. No entanto, essa abordagem oferece um potencial imenso para resolver problemas reais com maior eficiência e especialização.

REFERÊNCIAS

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and Tensorflow**: Concepts, Tools, and Techniques to Build Intelligent Systems. 3. ed. Sebastopol: O'Reilly Media, 2022.

HUGGING FACE. **Deep Reinforcement Learning Course**. 2024. Disponível em: <<https://huggingface.co/learn/deep-rl-course>>. Acesso em: 19 jun. 2024.


SILVER, D. et al. **AlphaZero**: Shedding new light on chess, shogi, and Go. 2018. Disponível em: <<https://deepmind.google/discover/blog/alphazero-shedding-new-light-on-chess-shogi-and-go/>>. Acesso em: 19 jun. 2024.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning**: An Introduction. 2. ed. Cambridge: MIT Press, 2018.

PALAVRAS-CHAVE

Palavras-chave: Aprendizagem por Reforço. Aprendizagem de Máquina. Recompensa.

EMAP



POSTECH