

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	18
REFERÊNCIAS.....	19

EMSE

O QUE VEM POR AÍ?

Você sabe quais são as estratégias de validação de diagnósticos de modelos de aprendizado de máquina?

Por meio de diversos tipos de técnicas que você vai conhecer nesta aula, é possível analisar a performance do modelo e mensurar o comportamento a fim de compreender a eficácia do modelo preditivo. Vamos lá?

EMEND

HANDS ON

Nesta videoaula você vai aprender na prática, utilizando o Python, como analisar um diagnóstico de modelo de aprendizado de máquina com as principais técnicas de validação.

EMEND

SAIBA MAIS

Analizando o erro do modelo

Existem formas diferentes de avaliar o erro de modelos de aprendizado de máquina: a forma como avaliamos em modelos supervisionados é diferente de modelos não supervisionados. Quando trabalhamos com modelos supervisionados, sempre vamos ter a base de teste para validar se os dados realmente estão próximos ao valor real esperado, ou seja, conseguir de fato minimizar a função de custo.

Em modelos não supervisionados, normalmente estamos querendo encontrar uma semelhança nos dados com base em similaridades no comportamento dos padrões dos dados. O objetivo de modelos não supervisionados é criar grupos de dados de forma distinta, em que cada grupo criado tenha a sua própria particularidade com base nos padrões dos dados.

A ideia é criar clusters bem definidos e bem distantes uns dos outros. Vou te apresentar as principais ferramentas para analisarmos esses dois mundos!

Avaliando modelos supervisionados

Matriz de confusão

		Valor predito	
		SIM	NÃO
Valor real	SIM	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	NÃO	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Figura 1 - Matriz de confusão
Fonte: Elaborado pela autora (2024)

A matriz de confusão é uma técnica que consiste em organizar resultados obtidos pelo modelo predictor em verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos de acordo com cada target do modelo. Vamos conhecer a fundo o que seria cada uma dessas linhas da matriz:

- **Verdadeiro Positivo (TP):** instâncias que foram corretamente classificadas como positivas pelo modelo.
- **Verdadeiro Negativo (TN):** instâncias que foram corretamente classificadas como negativas pelo modelo.
- **Falso Positivo (FP):** instâncias que foram incorretamente classificadas como positivas pelo modelo (quando na verdade são negativas).
- **Falso Negativo (FN):** instâncias que foram incorretamente classificadas como negativas pelo modelo (quando na verdade são positivas).

O grande benefício do uso da matriz de confusão é que ela traz uma forma visual de analisar os resultados do modelo preditivo, identificando o resultado das classes verdadeiras versus as preditas e colocando os números totais de instâncias preditas pelo modelo para cada classe. A matriz de confusão nos ajuda também a extrair as métricas do classification report, que será a próxima métrica que conheceremos!

Classification Report

O classification report traz de fato um relatório de métricas, contendo cada uma das principais métricas e sua atribuição por classe. Dentro do classification report podemos encontrar as seguintes:

- **Acurácia:** é uma das métricas mais simples e básicas utilizadas para avaliar o modelo. Ela representa a proporção total de previsões corretas feitas pelo modelo em todas as classes. É calculada como o número de verdadeiros positivos (TP) mais os verdadeiros negativos (TN) dividido pelo número total de instâncias no conjunto de dados de teste (TP + TN + FP + FN). Por exemplo: se eu estou testando 1000 instâncias e meu modelo acertou 800 delas, minha acurácia é de 80%.

- **Precisão:** indica quantos dos itens que identificamos foram relevantes e o cálculo é $TP/(TP+FP)$. Por exemplo: imagine que o modelo está classificando imagens de gatos e cachorros. A precisão para a classe "gato" seria a porcentagem de imagens previstas como "gato" que realmente são gatos.
- **Recall:** indica a proporção de instâncias reais de uma classe que o modelo conseguiu prever corretamente e o cálculo é $TP/(TP+FN)$. Continuando o exemplo anterior, o recall para a classe "gato" seria a porcentagem de imagens que realmente são gatos que o modelo conseguiu prever corretamente como "gato".
- **F-Score:** também conhecida como "F1-Score", é uma métrica que combina a precisão e a recuperação (recall) para fornecer uma pontuação única. É definida como a média harmônica da precisão e revocação.

Analise o seguinte exemplo para compreendermos melhor esse relatório:

	precision	recall	f1-score	support
gato	0.80	0.75	0.77	100

Figura 2 - Classification Report
Fonte: Elaborado pela autora (2024)

Isso significa que para a classe "gato" temos a seguinte análise:

- A precisão é de 80%, ou seja: 80% das imagens previstas como "gato" realmente são gatos.
- O recall é de 75%, ou seja: o modelo conseguiu prever corretamente 75% das imagens que realmente são gatos.
- O F1-Score é de 77%, representando um equilíbrio entre precisão e recall.
- O Support é 100, indicando que havia 100 imagens de gatos no conjunto de dados de teste.

Ao analisar o relatório de classificação completo para todas as classes, você obtém uma visão abrangente do desempenho do modelo em cada classe

individualmente. Isso permite identificar potenciais problemas de classificação e tomar decisões sobre como melhorar o modelo.

Curvas ROC e AUC

A curva ROC e a AUC ajudam a entender a habilidade do modelo em distinguir entre classes, independentemente dos critérios de classificação empregados (limiares de decisão). Vamos inicialmente entender a curva ROC, que significa “Receiver Operating Characteristic”, pois a AUC (“Area Under the Curve”) é uma derivada da curva ROC que nos mostra a área dessa curva; seria uma medida resumida do desempenho do classificador, variando de 0 (classificação aleatória) a 1 (classificação perfeita).

A curva ROC é uma ferramenta muito comum utilizada com classificadores binários. Esse tipo de curva só pode ser usada para avaliar classificadores que retornam uma pontuação (ou probabilidade) de previsão entre as classes. A curva ROC mostra de forma gráfica a taxa de verdadeiros positivos versus a taxa de falsos positivos e podemos dizer que ela evidencia a sensibilidade do modelo (revocação) versus a especificidade.

Antes de visualizar a curva ROC, é necessário ter em mãos os verdadeiros positivos e os falsos positivos. Quanto mais próximo de 1, e conseqüentemente longe de 0.5, melhor o ajuste da curva ROC. Observe a figura 3 para compreender melhor sobre a curva ROC e a AUC (área da curva):




Figura 3 - Curva ROC e AUC
Fonte: Elaborado pela autora (2024)

Observe que a curva ROC está distante ao limiar (threshold 0.5), ou seja: podemos concluir que o modelo possui um equilíbrio entre sensibilidade e especificidade. Também é possível concluir que o modelo é preciso em ranquear exemplos positivos acima de exemplos negativos. Quanto maior o valor da curva ROC, melhor o modelo está ranqueando.

Quando temos um modelo muito próximo de 0.5, significa que ele não possui um poder preditivo. Uma maneira de comparar classificadores é medir a área abaixo da curva (AUC). Um classificador perfeito terá uma ROC AUC igual a 1, enquanto um classificador puramente aleatório terá um ROC AUC igual a 0,5. Lembrando que a

AUC resume a curva ROC agregando todos os limiares da ROC, calculando a “área sob a curva”.

Curva de aprendizagem

Além de analisar todas as métricas aprendidas até o momento, também existe a curva de aprendizagem, que é uma técnica visual para analisar o desempenho de modelos durante o processo de treinamento. Essa técnica fornece um insight para mapear o quanto o modelo se comporta em diferentes tamanhos de conjunto de dados, auxiliando na identificação de problemas como overfitting, underfitting e otimização insuficiente.

Na curva de aprendizagem é plotada no eixo “y” alguma medida de validação do modelo, tal como a acurácia ou outra medida de erro, sendo analisada pelo eixo “x” que contém o tamanho da amostra de dados. Observe a figura a seguir:




Figura 4 - Curva de aprendizagem
Fonte: Elaborado pela autora (2024)

Como podemos analisar a curva de aprendizagem?

Observe que temos duas linhas representando o aprendizado. Em azul, para treinamento, e em laranja, para teste. Vamos analisar o gráfico e comentar alguns pontos importantes! A linha azul (treinamento) se mantém constante ao longo da aprendizagem, independentemente do tamanho da amostra da base de dados. Uma curva ascendente indica que o modelo está aprendendo efetivamente com os dados, enquanto uma curva estagnada ou decrescente sugere um overfitting.

A linha laranja (validação) representa o desempenho do modelo no conjunto de dados de teste com o objetivo de validar a generalização do modelo. Uma curva de validação ascendente indica boa generalização, enquanto uma curva que diverge significativamente da curva de treinamento pode levar o modelo a underfitting ou overfitting. A **distância entre as duas curvas indica a generalização do modelo**. Uma curva de teste próxima à curva de treino indica boa generalização, enquanto uma curva de teste significativamente acima da curva de treino indica overfitting.

Nesse exemplo da figura 4, o modelo não conseguiu generalizar muito bem os dados. No entanto, há espaço para aprimoramento e a exploração de outras métricas, modelos e técnicas de regularização pode ser útil para otimizar o desempenho do modelo.

Observe na figura 5 o teste realizado com um modelo classificador Bayes ingênuo. Ela mostra bem o comportamento de um modelo em um conjunto de dados mais complexos, em que a acurácia do treinamento é muito alta e com poucas amostras, e diminui ao aumentar o número de amostras, enquanto a amostra de teste é mais baixa no começo, mas aumenta com mais dados de amostra.

Na outra curva de aprendizagem realizada no modelo de SVM com Kernel, a acurácia de treinamento permanece alta independentemente do tamanho do conjunto de dados. A acurácia do conjunto de teste aumenta com o tamanho do conjunto de treinamento (aumenta até um ponto em que atinge um patamar, ou seja: o modelo não obteve mais desempenho de generalização, por mais que se aumente a amostra de dados).




Figura 5 - Curva de aprendizagem: exemplos de dois algoritmos diferentes
Fonte: Scikit Learn (2024)

Que tal dar uma olhadinha na biblioteca do sklearn? É só clicar [aqui](#).

Feature Importance

Você já imaginou uma ferramenta para nos mostrar **quais são as features (colunas) mais relevantes da base de dados para serem utilizadas no modelo?** A técnica de Feature Importance auxilia na compreensão das features que são mais impactantes e discriminantes para os modelos de aprendizado de máquina. Essa técnica pode até mesmo auxiliar na interpretação dos resultados do modelo. Observe a figura 6.




Figura 6 - Feature Importance
Fonte: Scikit (2024)

Na figura 6, o eixo “x” representa as features do conjunto de dados, identificadas por números (feature 0, feature 1, etc.). O eixo “y” indica a importância de cada feature, sendo calculada por mean decrease in impurity (essa medida está sendo utilizada apenas como um exemplo para um modelo de random florest). Valores mais altos indicam features mais importantes.

Com base na importância relativa, podemos considerar a remoção de features com baixa relevância para simplificar o modelo e evitar problemas de overfitting. A visualização da feature importance pode ser útil para comunicar de forma clara e transparente como o modelo toma decisões e quais fatores contribuem para as previsões.

Lembrando que a Feature Importance é uma ferramenta valiosa, mas não deve ser usada como única base para tomar decisões sobre o modelo. A análise crítica e a interpretação dos resultados em conjunto com outras técnicas são essenciais para construir modelos de aprendizado de máquina robustos e confiáveis.

Visualização de clusters

Passamos por muitos exemplos de como trabalhar com métricas de validação de modelos de classificação, mas e os modelos não supervisionados? Em modelos não supervisionados não temos a separação dos dados em treino e teste; isso porque nos modelos supervisionados queremos buscar uma relação entre os dados disponíveis em um conjunto de dados e encontrar uma similaridade em comum entre as instâncias que possa distinguir grupos. Dentro das métricas de desempenho de um cluster, podemos considerar dois tipos de avaliação: interno e externo.

- **Avaliação interna:** avaliamos o quão bom é meu agrupamento “por si só”.
- **Avaliação externa:** quão semelhante foram duas técnicas de agrupamento?

Tipo externo

Na avaliação do tipo externa, normalmente executamos dois ou mais modelos de agrupamento para avaliar **quão parecidos estão os modelos**. E por que preciso validar se meus modelos são parecidos? Vou te apresentar um exemplo:

Vamos supor que eu executei um modelo de K-means e outro modelo do tipo DBSCAN para validação do tipo externo. Se eu aplicar um modelo de k-means e comparar com o modelo de DBSCAN sobre uma base de segmentação de clientes em shoppings, eu poderia ter o seguinte resultado:




Figura 7 - K-means aplicado na base de segmentação de clientes
Fonte: Elaborado pela autora (2024)




Figura 8 - DBSCAN aplicado na base de segmentação de clientes
Fonte: Elaborado pela autora (2024)

Comparando as duas técnicas, percebe-se que para o K-means os dados foram separados em cinco grupos ($k=5$) de acordo com a proximidade dos dados (distância euclidiana). No modelo do DBSCAN, esses pontos em roxo são considerados “ruídos” nos dados, ou seja, outliers. Nesse caso, o modelo identificou que esses dados não são tão densos como os demais, deixando-os de fora do agrupamento. Qual modelo agrupou melhor os dados?

Veja que, pela nossa percepção, o modelo k-means se comportou melhor em questão de agrupamento nesse cenário. Mas como eu posso comprovar isso de forma estatística?

Aí entram as métricas de **validação externa**! Como, por exemplo, o adjusted rand index, que compara o desempenho quando são fornecidos datasets com labels (grupos) geradas de forma aleatória. Quando essas labels (grupos) estão muito diferentes, o valor se aproxima de 0, o que sugere um resultado negativo, ou seja, clusters não próximos. Quanto temos grupos idênticos o resultado é igual a 1.

Veja o resultado do nosso exemplo no Python:

Comparação entre K-Means e DBSCAN:

```
[ ] adjusted_rand_score(kmeans_labels,dbscan_labels)

0.7151933782093212
```

Figura 9 - Comparação do modelo k-means com DBSCAN utilizando adjusted rand index
Fonte: Elaborado pela autora (2024)

Perceba que o algoritmo k-means e o DBSCAN possuem uma similaridade de 0.71, ou seja, estamos longe de 1. Isso significa que os dois modelos são distintos.

Ainda utilizando nosso exemplo, podemos aplicar a métrica de Silhouette, que é uma estratégia de validação interna. Essa métrica mede o formato do cluster obtido (avalia a distância entre os centros dos clusters; nesse caso, queremos maximizar as distâncias). Valores próximos a -1 significam clusters ruins e próximos a 1 clusters bem separados.

KMEANS:

```
[ ] silhouette_score(dados[['Annual Income (k$)','Spending Score (1-100)']],kmeans_labels)

0.553931997444648
```

DBSCAN:

```
[ ] silhouette_score(dados[['Annual Income (k$)','Spending Score (1-100)']],dbscan_labels)

0.36328873885121793
```

Figura 10 - Comparação do modelo k-means com DBSCAN utilizando Silhouette
Fonte: Elaborado pela autora (2024)

Analisando a validação com os dois algoritmos, podemos concluir que o k-means separa melhor os dados que o DBSCAN.

EMAP

O QUE VOCÊ VIU NESTA AULA?

Nessa aula você aprendeu quais são as principais técnicas de validação de diagnóstico de modelos tanto supervisionados quanto não supervisionados.

Compreender as possibilidades e utilidades é importante para auxiliar a construção de modelos seguros e que consigam generalizar bem os dados.

EMBA

REFERÊNCIAS

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow**. 2. ed. [s.l.]: O'Reilly Media, Inc., 2019.

SCIKIT LEARN. **Feature importances with a forest of trees**. 2024. Disponível em: <https://scikit-learn.org/stable/auto_examples/ensemble/plot_forest_importances.html#sphx-glr-auto-examples-ensemble-plot-forest-importances-py>. Acesso em: 19 jun. 2024.

SCIKIT LEARN. **learning_curve**. 2024. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.learning_curve.html>. Acesso em: 19 jun. 2024.

SCIKIT LEARN. **Plotting Learning Curves and Checking Models' Scalability**. 2024. Disponível em: <https://scikit-learn.org/stable/auto_examples/model_selection/plot_learning_curve.html#sphx-glr-auto-examples-model-selection-plot-learning-curve-py>. Acesso em: 19 jun. 2024.

SCIKIT LEARN. **scikit-learn Machine Learning in Python**. 2024. Disponível em: <<https://scikit-learn.org/stable/>>. Acesso em: 19 jun. 2024.

PALAVRAS-CHAVE

Palavras-chave: DBSCAN. Diagnóstico de modelo. Curva ROC. Curva AUC.

EMAP



POSTECH