



SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS.....	12

EMSE

O QUE VEM POR AÍ?

Aprendemos a como utilizar as métricas de diagnóstico de modelos para evitar o tão temido overfitting. Mas como podemos nos resguardar desse tipo de situação nos modelos? Como podemos criar estratégias para evitar que o modelo decore os dados ou simplesmente caia no underfitting?

Vem comigo que nesta aula eu vou te explicar algumas possíveis técnicas chaves para solucionar esse problema!

EMAN

HANDS ON

Nesta aula você vai aprender na prática utilizando o Python como aplicar as técnicas de regularização de modelos para evitar as situações de overfitting e quais são as possibilidades quando lidamos com underfitting. Vamos lá?

EMSE

SAIBA MAIS

Entendendo a motivação da regularização

Treinar um modelo preditivo não é tão trivial quanto parece e não funciona como em um simples passo de magia, em que você conecta seus dados ao seu modelo preditivo e tudo estará perfeito! O treinamento de modelos pode envolver alguns desafios e vou passar um breve resumo para você sobre os principais motivos que podem levar um modelo a não funcionar bem: **algoritmos ruins ou dados ruins**.

Em se tratando de **dados ruins**, podemos ter alguns fatores:

- **Quantidade insuficiente de dados:** com uma amostra de dados muito pequena existirá um "ruído de amostragem" e se houver uma amostra muito grande com dados não representativos o método de amostragem também pode ser falho (viés de amostragem).
- **Dados de treinamento não representativos:** o objetivo de um bom modelo de aprendizado de máquina é generalizar bem a partir dos dados de treinamento. Sendo assim, é importante buscar uma base de dados representativa. Será que sua base de dados consegue generalizar?
- **Dados de baixa qualidade:** aqui é preciso se dedicar à limpeza dos dados: uma base não consistente pode impactar na detecção de padrões.
- **Características irrelevantes:** entra lixo, sai lixo. Atenção aos dados que entram no seu modelo! A dica aqui é a dedicação na etapa de feature engineering ou técnicas de redução de dimensionalidade.

Agora, vamos falar um pouquinho sobre algoritmos ruins:

- **Sobreajuste nos dados (overfitting):** ocorre quando seu modelo funciona muito bem com os dados de treinamento mas não generaliza bem novos dados de entrada. Isso pode acontecer quando o modelo é muito complexo em relação ao ruído e quantidade. Como solução podemos pensar aqui em:

- Simplificar o modelo.
- Coletar mais dados.
- Reduzir o ruído (por exemplo: remover outliers).
- Regularização: chamamos de regularização quando restringimos um modelo para simplificar e reduzir o risco de reajuste dos dados. A regularização pode ajudar a generalizar melhor o modelo em novos exemplos de dados (nesta aula, vamos focar neste tópico).
- **Subajuste dos dados (underfitting):** Nesse caso seu modelo ficou muito simples ao ponto de não aprender corretamente os dados. Algumas soluções:
 - Selecionar um modelo mais poderoso.
 - Feature engineering.
 - Reduzir as regularizações.

Técnicas de regularização de modelos




Figura 1 - Impacto da regularização no aprendizado do modelo
Fonte: Naveen (2022)

A Regularização pode ser considerada como um conjunto de técnicas que visam reduzir o overfitting e melhorar a generalização dos modelos. A regularização aplica uma “penalidade” sobre os dados de treinamento, tornando a função de custo menos complexa. Vamos conhecer quais são as principais técnicas de regularização de modelos.

Regularização L1 (LASSO)

Essa técnica adiciona uma penalidade à função de custo que é proporcional à soma dos valores absolutos dos parâmetros do modelo. Essa aplicação de penalidade auxilia o modelo a encontrar soluções com menos parâmetros (o que reduz sua complexidade).

Regularização L2 (RIDGE)

Essa técnica adiciona uma penalidade à função de custo que é proporcional à soma dos quadrados dos valores dos parâmetros do modelo. Esse tipo de penalidade evita que os parâmetros dos modelos assumam valores muito grandes (o que previne o overfitting).

Elastic Net (combinação de L1 e L2)

Esse tipo de técnica realiza a combinação das regularizações L1 e L2, fornecendo assim flexibilidade na seleção de features e na redução da complexidade do modelo.

Dropout

Dropout é uma das técnicas de regularização mais utilizadas em redes neurais e seu funcionamento é muito simples: em cada etapa de treinamento, os neurônios possuem uma probabilidade de serem temporariamente “descartados”, ou seja: totalmente ignorados durante o treinamento da rede. Essa probabilidade é chamada de taxa de dropout aplicada na rede. A técnica de remover neurônios aleatórios da rede pode inclusive ajudar na performance da rede neural.




Figura 2 - Técnica de Dropout
Fonte: Géron (2019)

Early Stopping

Com essa técnica, o modelo é interrompido quando começa a ter uma degradação de performance. Funciona como um tipo de “monitoramento” do modelo, em que o treinamento é interrompido quando o desempenho no conjunto de validação começa a diminuir, evitando que o modelo se adapte excessivamente aos dados de treinamento.




Figura 3 - Técnica Early Stopping
Fonte: Gençay (2001)

A regularização é uma ferramenta poderosa para combater o overfitting, mas deve ser utilizada com cuidado para evitar que o modelo fique subajustado e perca a capacidade de aprender com os dados de treinamento. A combinação de diferentes técnicas de regularização e outras estratégias de prevenção do overfitting pode levar a modelos mais robustos e generalizáveis.

Quando pensamos no cenário de **underfitting** (o modelo não aprendeu os padrões dos dados), podemos considerar técnicas de modelos mais robustos, como os modelos de **ensembles** por exemplo.

Utilizando modelos mais poderosos para lidar com o underfitting

O underfitting ocorre quando um modelo de aprendizado de máquina não consegue capturar as complexidades dos dados de treinamento e, consequentemente, apresenta um desempenho ruim em dados de teste ou validação.

Modelos de ensemble, como Random Forest, Gradient Boosting e Bagging, combinam vários modelos fracos para criar um modelo mais robusto e preciso. No entanto, mesmo modelos de ensemble podem sofrer underfitting, especialmente em cenários com pouca quantidade de dados ou features irrelevantes.




Figura 4 - Modelo de ensemble
Fonte: Anwar (2021)

Sabendo utilizar os parâmetros certos, os modelos de ensembles podem ajudar muito a solucionar casos em que o modelo não aprendeu a encontrar os padrões nos dados de forma eficiente. Então se pensarmos, por exemplo, nos modelos de Random Forest e Gradient Boosting, eles possuem hiperparâmetros que controlam o número de árvores ou estimadores utilizados. Aumentar esses valores pode permitir que o modelo capture mais complexidades nos dados e reduza o underfitting.

A chave para combater o underfitting é **fornecer ao modelo informações suficientes e relevantes para aprender as complexidades dos dados**, sem permitir que ele se ajuste demais aos dados de treinamento. Ao combinar técnicas de aumento de dados, seleção de features, ajuste de hiperparâmetros e escolha do algoritmo de ensemble adequado, você pode criar modelos de ensemble robustos e precisos que generalizam bem os dados.

O QUE VOCÊ VIU NESTA AULA?

Nessa aula você aprendeu quais são as principais técnicas de regularização de modelos de aprendizado e como utilizá-las para penalizar os parâmetros e criar modelos mais robustos em generalização.

Além das técnicas para reduzir o overfitting, você também aprendeu quais são as formas de solucionar o underfitting.

EMEND

REFERÊNCIAS

ANWAR, A. **What are Ensemble methods in Machine Learning?** 2021. Disponível em: <<https://towardsdatascience.com/what-are-ensemble-methods-in-machine-learning-cac1d17ed349>>. Acesso em: 19 jun. 2024.

GENÇAY, R. **Early Stopping.** 2001. Disponível em: <<https://paperswithcode.com/method/early-stopping>>. Acesso em: 19 jun. 2024.

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow.** 2. ed. [s.l.]: O'Reilly Media, Inc., 2019.


NAVEEN. **What is L1 and L2 regularization in Deep Learning?** 2022. Disponível em: <https://www.nomidl.com/deep-learning/what-is-l1-and-l2-regularization-in-deep-learning/#google_vignette>. Acesso em: 19 jun. 2024.

SCIKIT LEARN. **scikit-learn Machine Learning in Python.** 2024. Disponível em: <<https://scikit-learn.org/stable/>>. Acesso em: 19 jun. 2024.

PALAVRAS-CHAVE

Palavras-chave: Overfitting. Underfitting. Regularização.

EMSE



POSTECH