

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	18
REFERÊNCIAS.....	19

EMSE

O QUE VEM POR AÍ?

Ao explorar territórios desconhecidos, muitas vezes somos guiados(as) pelo que é popular, pelos locais que atraem atenção e entusiasmo. Esta inclinação natural em direção ao que é amplamente aceito nos leva a ponderar: por que confiamos na escolha da maioria e como essa popularidade se traduz em recomendações confiáveis para nós?

Em nossa jornada pelo tema de Recomendação por Popularidade, percebemos que cada interação, cada curtida, vai além de um simples incremento numérico. Ela se entrelaça em uma rede de matrizes revelando preferências ocultas e tendências, decifradas não pelos olhos, mas pela precisão dos algoritmos. Ao entender essas nuances, começamos a apreciar como nossas próprias avaliações contribuem para um sistema que, em retorno, busca nos conhecer melhor e aprimorar as sugestões que nos faz.

HANDS ON

Neste segmento prático da nossa aula, vamos mergulhar de cabeça no fascinante mundo dos sistemas de recomendação, com um foco especial em Recomendação por Popularidade. Preparamos uma série de videoaulas nas quais não só discutiremos os conceitos-chave por trás desses sistemas, mas também colocaremos a teoria em prática. Você vai acompanhar, passo a passo, como os dados são transformados em recomendações, vivenciando o verdadeiro significado de “aprender fazendo”.

SAIBA MAIS

Através de exemplos interativos e exercícios práticos, vamos explorar como os sistemas de recomendação utilizam as contagens e avaliações para identificar tendências e preferências. Prepare-se para aplicar comandos e códigos que darão vida aos algoritmos e permitirão que você mesmo(a) teste e valide o poder das recomendações baseadas na popularidade. A seguir, você encontrará os códigos e comandos que utilizaremos:

```
# Código para calcular a popularidade dos itens baseado em
contagem de avaliações
item_counts = data.groupby(
    'item_id'
).size().sort_values(
    ascending=False
)
# Comando para extrair as top recomendações
top_recommendations = item_counts.head()

# Instruções para reclassificar avaliações com feedback do
usuário
updated_ratings = update_ratings_matrix(data, user_feedback)
```

Código-fonte 1 – Exemplo de código-fonte para ordenação de popularidade
Fonte: Elaborado pelo autor (2024)

Em sistemas de recomendação por popularidade, a essência é captar e analisar os dados gerados pelas interações de usuários para identificar itens que são tendências, ou seja, aqueles que têm um maior volume de interações positivas. Este processo de identificação é crucial e requer um sistema de dados robusto e sensível às mudanças no comportamento do usuário.

As interações, como avaliações e compras, são geralmente reorganizadas em matrizes que facilitam o reconhecimento de padrões emergentes, ajustando continuamente as recomendações para refletir as preferências atuais dos usuários. Um balanceamento entre a exploração de novos itens e a exploração de itens já conhecidos é vital para manter a relevância e a diversidade nas recomendações, mantendo assim o sistema atraente e valioso para usuários.

Além disso, a validação constante e a atualização do sistema de recomendação são fundamentais para garantir a precisão e a confiabilidade das recomendações. O sistema deve estar atento às mudanças nas tendências globais, adaptando-se para

incorporar novas categorias de itens e responder às evoluções nas gerações de usuários. Este monitoramento contínuo assegura que o sistema de recomendação por popularidade se mantenha atualizado e em sintonia com as preferências em constante mudança de seu público-alvo.

Ao longo desta aula, aprenderemos como implementar e validar um sistema parecido com o seguinte:

```
import pandas as pd
import numpy as np

# Simulação de dados de interação dos usuários com itens
data = pd.DataFrame({
    'user_id': np.random.randint(1, 100, 1000),
    'item_id': np.random.randint(1, 20, 1000),
    'interaction': np.random.randint(1, 5, 1000) # 1-4 scale ratings
})

# Contagem de interações para identificar popularidade
item_popularity = data.groupby('item_id')['interaction'].sum().sort_values(ascending=False)
top_items = item_popularity.head(10) # Top 10 itens populares

# Simulação de um feedback do usuário para atualizar recomendações
feedback = {
    'item_id': 15,
    'interaction_increase': 10 # Aumento artificial na contagem de interações
}

# Atualiza as recomendações com o feedback do usuário
if feedback['item_id'] in item_popularity.index:
    item_popularity[feedback['item_id']] += feedback['interaction_increase']

# Reordenar após feedback
item_popularity = item_popularity.sort_values(ascending=False)
updated_top_items = item_popularity.head(10)

print(updated_top_items)
```

Código-fonte 2 – Exemplo de sistema de recomendação por popularidade

Fonte: Elaborado pelo autor (2024)

Este exemplo de código simula um conjunto de dados de interações de usuários, calcula os itens mais populares com base na contagem de interações e

atualiza as recomendações com base em um feedback fictício, exemplificando o processo de reclassificação das avaliações com feedback do usuário e a manutenção da atualidade do sistema.

Nos sistemas de recomendação por popularidade, o principal conceito teórico é a hipótese de que se um item é frequentemente escolhido ou avaliado positivamente por um grande número de usuários é provável que seja relevante para outros. Isto é medido através da contagem de características como, por exemplo, o número de vezes que um produto é comprado ou uma música é reproduzida. Essas contagens são usadas para identificar tendências globais, refletindo o que é amplamente aceito ou apreciado dentro de uma determinada comunidade ou contexto.

A seleção e a ponderação dessas características são processos críticos que determinam a eficácia do sistema de recomendação. Em sistemas baseados em conteúdo, características como palavras-chave, metadados e descrições são extraídas e ponderadas para representar os itens. Por exemplo: a importância relativa de um ator em um filme pode ser maior do que uma palavra da sinopse, exigindo uma ponderação diferenciada. Este processo pode ser tanto heurístico, baseado no conhecimento do domínio, quanto automatizado, conhecido como ponderação de características.

Um exemplo real de aplicação deste conceito pode ser encontrado em plataformas de streaming de vídeo, em que filmes e séries populares são destacados na página inicial. Essa prática é eficaz porque novos usuários são apresentados a conteúdos que já são bem-sucedidos entre um amplo público, aumentando as chances de satisfação do usuário e engajamento com a plataforma.

Na construção de sistemas de recomendação baseados em popularidade, identificar características contadas é crucial. Este processo envolve o uso de dados de comportamento do usuário para inferir interesses e capturar tendências que possam direcionar as recomendações. A confiança e o suporte são métricas que ajudam a determinar a força das regras de associação dentro dos conjuntos de dados, auxiliando na identificação de padrões significativos de consumo ou de avaliação pelos usuários.

Um exemplo prático disso pode ser encontrado no varejo online. Por exemplo, se um item como "pão" é frequentemente comprado com "leite", esses itens têm alta confiança dentro de suas transações conjuntas. No entanto, é essencial que também haja um suporte significativo, o que implica um número substancial de ocorrências dessa combinação para evitar conclusões baseadas em coincidências.

Além disso, as abordagens de filtragem colaborativa muitas vezes levam em conta a similaridade entre usuários ou itens. Medidas como a similaridade de Jaccard são utilizadas para identificar o quão similares são dois itens com base nas interações dos usuários com eles. Lembrando que a similaridade de Jaccard é uma métrica usada para avaliar a semelhança entre conjuntos de dados.

No contexto de sistemas de recomendação, ela pode ser usada para comparar a semelhança entre os gostos dos usuários ou entre os itens que eles preferem. O coeficiente de Jaccard é definido como o tamanho da interseção dividido pelo tamanho da união dos conjuntos que estão sendo comparados.

Para ilustrar, considere dois usuários de um serviço de filmes online, em que cada um tem um conjunto de filmes que avaliaram positivamente. Para calcular a similaridade de Jaccard entre esses dois usuários, você contaria o número de filmes que ambos avaliaram positivamente (a interseção) e dividiria esse número pelo total de filmes únicos que ambos os usuários juntos avaliaram positivamente (a união). Matematicamente, a similaridade de Jaccard J entre dois conjuntos A e B é calculada como:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Em sistemas de recomendação, essa métrica pode ser usada, por exemplo, para recomendar novos filmes a um usuário com base nos filmes que usuários similares gostaram. Se o coeficiente de Jaccard entre dois usuários é alto, isso sugere que eles têm gostos semelhantes e filmes que um usuário gostou podem ser recomendados ao outro. Por exemplo: em um site de filmes, pode-se calcular a similaridade entre dois filmes contando quantas vezes ambos foram classificados positivamente pelos mesmos usuários. Essa similaridade é crucial para recomendar filmes que provavelmente serão do interesse do usuário com base em suas ações anteriores.

Outro conceito importante é a aplicação de características meta-nível, que são derivadas da matriz de avaliações e outras fontes, como o número de avaliações que um usuário fez ou quantas vezes um item foi avaliado. Estas características podem ser usadas para ajustar algoritmos de recomendação ou para a construção de sistemas híbridos que levam em conta múltiplas fontes de informação.

Na exploração de sistemas de recomendação baseados em popularidade, a identificação e seleção de características de meta-nível a partir de matrizes de avaliações são fundamentais. Estas características são derivadas de dados agregados de interações de usuários, como frequências de avaliações, médias de pontuações de itens e popularidade de itens.

Para garimpar essas características, é essencial começar com uma Análise Exploratória de Dados (EDA) robusta para entender as distribuições e correlações no conjunto de dados. Isso envolve examinar como as interações dos usuários se distribuem entre os itens e identificar tendências ou padrões como sazonalidade ou itens que frequentemente são avaliados juntos.

Por exemplo: em uma plataforma de filmes, pode-se explorar quantos usuários avaliaram cada filme e como essas avaliações se distribuem ao longo do tempo, revelando tanto lançamentos populares quanto clássicos perduráveis.

A seleção de características de meta-nível envolve escolher aquelas que têm um impacto significativo na precisão do sistema de recomendação. Métodos como análise de componentes principais (PCA) e técnicas de seleção automática de características podem ser usados para identificar as características mais informativas. Por exemplo: a frequência de avaliações de um usuário pode ser uma característica valiosa para entender seu engajamento e influenciar as recomendações apresentadas a ele.

A matriz de avaliações é uma representação crucial em sistemas de recomendação, geralmente organizada como uma matriz em que cada linha representa um usuário e cada coluna um item. As células dessa matriz podem ser preenchidas com valores que representam a avaliação de um usuário para um item específico. Matematicamente, podemos descrever a matriz de avaliações como R em que r_{ui} representa a avaliação do usuário u para o item i . Muitas dessas matrizes são esparsas, pois nem todos os usuários avaliam todos os itens disponíveis.

A fatoração desta matriz pode ser usada para prever avaliações não observadas e descobrir características latentes dos usuários e itens. Estes conceitos são apoiados pelo material revisado nas páginas 35 a 47 do livro "Practical Recommender Systems" de Kim Falk, no qual se discutem métodos para coletar e analisar comportamentos dos usuários que são essenciais para construir características de meta-nível e implementar recomendações eficazes.

Os sistemas de recomendação são amplamente utilizados em diferentes mercados, aplicando uma variedade de técnicas para personalizar a experiência do usuário e aumentar a relevância das sugestões oferecidas. Empresas líderes em e-commerce como a Amazon utilizam sistemas que combinam a filtragem colaborativa com algoritmos baseados no conteúdo dos produtos. Esses sistemas não apenas analisam o comportamento passado de compra dos usuários, mas também as características dos produtos para recomendar itens semelhantes, enriquecendo assim a experiência de compra ao sugerir produtos que refletem interesses anteriores dos consumidores (SHETTY, 2023).

Na indústria do entretenimento, plataformas como Spotify e Netflix demonstram a eficácia dos sistemas de recomendação em ambientes de streaming de música e vídeo. O Spotify utiliza predominantemente a filtragem colaborativa para sugerir músicas, baseando-se no que usuários com gostos similares ouviram. A Netflix, por outro lado, emprega uma abordagem mais complexa que integra filtragem colaborativa, algoritmos baseados em conteúdo e aprendizado de máquina para prever os interesses dos usuários.

Isso permite que a Netflix ofereça recomendações altamente personalizadas que consideram não apenas as atividades passadas dos usuários, mas também o comportamento de usuários com perfis semelhantes, garantindo assim sugestões mais precisas e satisfatórias (SHETTY, 2023; SEVERT, 2023).

Redes sociais como Facebook e LinkedIn também aplicam técnicas de recomendação para melhorar a interação, sugerindo conexões, conteúdos e oportunidades de emprego com base nas atividades e interesses dos usuários. Esses sistemas analisam uma vasta quantidade de dados contextuais e interações para fornecer recomendações que potencialmente aumentam a rede e o engajamento do usuário dentro dessas plataformas (SHETTY, 2023).

Técnicas avançadas discutidas nas seções 2.3, 2.6 e 2.7 do livro de Charu C. Aggarwal incluem a utilização de modelos de regressão em vizinhança e modelos baseados em grafos, que ajudam a explorar relações complexas entre usuários e itens. Estas abordagens não só melhoram a precisão das recomendações como também proporcionam uma personalização mais profunda ao considerar a proximidade e a interação entre variáveis e os padrões de comportamento dos usuários.

A implementação desses sistemas em variados contextos de mercado demonstra um objetivo comum: melhorar a experiência do usuário através de recomendações personalizadas e precisas. Isso não só aumenta a satisfação do cliente como também fortalece a fidelidade à marca, mostrando o potencial dos sistemas de recomendação em transformar interações simples em experiências de usuário enriquecedoras e engajadoras.

Dentre os diferentes métodos de definição de recomendações, os métodos baseados na vizinhança para a previsão de avaliações são os mais simples e populares, principalmente modelos de vizinhança baseados em usuário e em item.

Os modelos baseados em usuário operam identificando usuários que compartilham preferências similares com o usuário alvo e utilizam as avaliações desses usuários "vizinhos" para prever as avaliações do usuário alvo. A similaridade entre usuários é geralmente calculada usando métricas como a correlação de Pearson ou a distância cosseno. Por exemplo: se dois usuários deram avaliações altas para os mesmos filmes, eles são considerados semelhantes e é provável que tenham opiniões parecidas sobre outros filmes.

Já os modelos baseados em item focam em encontrar itens semelhantes com base nas avaliações de todos os usuários que interagiram com esses itens. Se um usuário gostou de um item, é provável que goste de itens semelhantes que outros usuários com gostos parecidos também gostaram. Este método tende a ser mais estável e escalável do que o modelo baseado em usuário, pois o número de itens é geralmente menor que o número de usuários e as preferências dos itens mudam menos frequentemente do que as preferências dos usuários.

No entanto, ambos os métodos enfrentam limitações. A filtragem colaborativa baseada em usuário pode se tornar computacionalmente cara e menos eficaz quando

há um grande número de usuários devido à complexidade de calcular a similaridade entre todos os pares de usuários. Além disso, ambos os modelos sofrem do problema de esparsidade, em que muitos usuários ou itens têm poucas avaliações, dificultando a previsão precisa das preferências.

Esses insights sobre modelos de vizinhança baseados em usuário e em item são essenciais para entender como os sistemas de recomendação modernos operam, adaptando-se e escalando conforme necessário para fornecer recomendações personalizadas em uma variedade de aplicações.

Em termos de complexidade computacional, a filtragem baseada em item é geralmente mais eficiente. Isto ocorre porque a similaridade entre itens pode ser pré-calculada e reutilizada para múltiplos usuários. Contudo, em ambientes dinâmicos nos quais novos itens são frequentemente adicionados, este método requer atualizações regulares das similaridades para manter a eficácia.

Na análise de sistemas de recomendação baseados em vizinhança, a complexidade computacional é uma consideração crítica tanto para modelos baseados em usuário quanto para modelos baseados em item. A abordagem escolhida impacta diretamente no desempenho e escalabilidade do sistema, particularmente em ambientes com grandes volumes de dados.

Nos modelos baseados em usuário, a similaridade entre usuários é calculada para identificar quais usuários têm preferências semelhantes. Supondo que temos U usuários e I itens, cada usuário u tem um vetor de avaliação de itens r_u na matriz de avaliações R de dimensão $U \times I$.

Calcular a similaridade entre todos os pares de usuários requer a comparação de cada par de vetores de usuário, resultando em uma complexidade de $O(U^2 \times I)$. Essa complexidade se deve ao fato de que cada cálculo de similaridade entre dois usuários leva $O(I)$, considerando que cada usuário avaliou todos os I itens, algo que raramente ocorre na prática devido à esparsidade típica dessas matrizes.

Por outro lado, os modelos baseados em item consideram a similaridade entre os itens em si, o que pode ser mais eficiente em cenários nos quais o número de itens I é muito menor que o número de usuários U . Aqui, a complexidade para calcular todas as similaridades é $O(I^2 \times U)$. Em cada comparação de itens i e j , examinamos

todos os U usuários para ver como eles avaliaram ambos os itens, o que demanda uma complexidade de $O(U)$ por par de itens.

Além disso, a análise de complexidade não termina apenas no cálculo de similaridades. Armazenar esses valores também requer significativa alocação de memória, especialmente em sistemas grandes. Para cada modelo, a matriz de similaridade S precisa ser mantida, em que S é $U \times U$ para o modelo baseado em usuário e $I \times I$ para o modelo baseado em item. Isso pode se tornar proibitivo com o crescimento de U e I .

Técnicas de identificação de recomendações

Para mitigar essas questões, técnicas como a decomposição em valores singulares (SVD) são aplicadas para reduzir a dimensionalidade da matriz de avaliações, mantendo as informações mais relevantes e reduzindo a complexidade de operações subsequentes. Tais técnicas permitem uma representação mais compacta da informação original, facilitando o cálculo e o armazenamento de similaridades sem uma grande perda de informação.

A Decomposição em Valores Singulares (SVD) é uma técnica matemática fundamental utilizada para redução de dimensionalidade e identificação de estruturas latentes em sistemas de recomendação. A SVD decompõe uma matriz R em três componentes distintas: V , Σ , e V^T .

Aqui, V representa uma matriz ortogonal contendo os vetores singulares à esquerda, Σ é uma matriz diagonal com os valores singulares e V^T é a transposta de V , contendo os vetores singulares à direita. Esta decomposição é representada matematicamente pela fórmula $R = U\Sigma V^T$, facilitando a análise por revelar as relações latentes nos dados e melhorar a precisão das previsões em sistemas de recomendação.

Embora a SVD seja amplamente empregada, existem alternativas como a Decomposição em Valores Singulares Truncada (Truncated SVD), que conserva apenas os k maiores valores singulares para simplificar a matriz resultante e reduzir custos computacionais. A Análise de Componentes Principais (PCA) é outra técnica relacionada, utilizada para maximizar a variância nos dados. Diferente da SVD, a PCA é aplicada em dados centrados, subtraindo a média antes da decomposição, o que é ideal para análises estatísticas tradicionais.

A Análise de Componentes Principais (PCA) é uma técnica estatística poderosa usada para redução de dimensionalidade em dados, explorando padrões estruturais para simplificar a complexidade sem perder informações críticas. Formalmente, a PCA transforma um conjunto de variáveis possivelmente correlacionadas em um conjunto de valores de variáveis linearmente não correlacionadas chamadas componentes principais. Este processo é feito calculando os autovalores e autovetores da matriz de covariância dos dados originais.

Suponha que temos uma matriz de dados X de dimensão $n \times p$, em que n é o número de amostras e p é o número de variáveis. A PCA começa com a centralização dos dados subtraindo a média de cada variável. A matriz de covariância C é então calculada como:

$$C = \frac{1}{n-1} X^T X$$

O próximo passo é calcular os autovalores λ e os autovetores V de C . Os componentes principais são então obtidos projetando X nos autovetores de C . Estes componentes são as direções nos dados que maximizam a variância quando projetamos os dados sobre esses eixos. Em sistemas de recomendação, a PCA pode ser usada para lidar com a alta dimensionalidade dos dados de usuários ou itens, especialmente em matrizes de avaliação que são tipicamente esparsas.

A aplicação de PCA ajuda a descobrir as dimensões latentes que explicam as preferências dos usuários ou as características dos itens, facilitando assim a predição de avaliações faltantes e melhorando a qualidade das recomendações.

A utilização de PCA em sistemas de recomendação oferece algumas vantagens, como a capacidade de descobrir padrões complexos e reduzir o ruído nos dados, o que pode levar a recomendações mais precisas e robustas. No entanto, a técnica também tem desvantagens, incluindo a perda de algumas informações devido à redução da dimensionalidade e a dificuldade em interpretar os componentes resultantes em termos concretos de características de itens ou preferências de usuários.

Outra técnica alternativa é a Fatoração de Matriz Não-negativa (NMF), que divide a matriz R em duas matrizes W e H , ambas com a restrição de serem não-negativas, o que é particularmente útil para dados que não admitem valores negativos,

como contagens. Por fim, os Autoencoders, que utilizam redes neurais para aprender e comprimir dados em uma representação de baixa dimensão, retratam uma abordagem moderna para a redução de dimensionalidade em grandes conjuntos de dados, sendo especialmente valorizados em aplicações de aprendizado profundo.

Cada uma dessas técnicas apresenta vantagens e desafios específicos e a escolha entre elas deve considerar tanto as características dos dados quanto os objetivos específicos do sistema de recomendação. A escolha da técnica mais adequada pode significar o equilíbrio entre eficiência computacional e a precisão das recomendações, crucial para o sucesso de sistemas de recomendação em ambientes dinâmicos e com grandes volumes de dados.

Exploração VS Exploração

No contexto dos sistemas de recomendação, os conceitos de exploração e exploração são fundamentais para entender como os algoritmos balanceiam a introdução de novos itens aos usuários e o aproveitamento de itens conhecidos para maximizar a relevância das recomendações. Esses conceitos são especialmente pertinentes em sistemas de recomendação por popularidade, nos quais o desafio é não apenas recomendar os itens mais populares, mas também descobrir novos itens que poderiam ser interessantes para o usuário.

Exploração refere-se ao processo de introduzir novos itens aos usuários, itens sobre os quais o sistema tem pouca informação ou que são menos conhecidos dentro do conjunto de dados. O objetivo da exploração é descobrir novas preferências do usuário e expandir a base de conhecimento do sistema. Isso é particularmente importante em ambientes dinâmicos em que novos produtos são frequentemente introduzidos ou o gosto dos usuários pode evoluir com o tempo.

Em sistemas de recomendação por popularidade, a exploração pode ajudar a identificar itens emergentes que ainda não alcançaram um alto nível de popularidade, mas que têm o potencial de ser altamente relevantes para segmentos específicos de usuários.

Exploração, por outro lado, envolve o uso de informações já conhecidas para maximizar a utilidade das recomendações. Em sistemas de recomendação por popularidade, isso geralmente significa sugerir itens que já são populares entre a base de usuários e têm alta probabilidade de agradá-lo. A exploração tira proveito das

informações acumuladas sobre as preferências dos usuários e as popularidades dos itens para fazer recomendações seguras que são mais propensas a serem bem recebidas.

A chave para um sistema de recomendação eficaz é encontrar o equilíbrio certo entre exploração e exploração. Dependendo demais da exploração pode levar a uma experiência de usuário monótona e estagnada, em que novos itens raramente são introduzidos. Por outro lado, focar excessivamente na exploração pode diminuir a precisão das recomendações e frustrar os usuários com sugestões que não correspondem aos seus interesses conhecidos.

Em sistemas de recomendação por popularidade, este equilíbrio pode ser alcançado através de técnicas como o uso de bandit algorítmicos, em que estratégias como epsilon-greedy ou Upper Confidence Bound (UCB) são aplicadas para ajustar dinamicamente a taxa de exploração versus exploração baseada na resposta do usuário às recomendações anteriores. Além disso, métodos híbridos que combinam recomendações baseadas em popularidade com entradas personalizadas baseadas em preferências específicas do usuário podem ajudar a personalizar as sugestões enquanto introduzem novos itens.

Este balanceamento não só melhora a satisfação e o engajamento do usuário como também enriquece a base de dados do sistema com novas informações que podem ser utilizadas para refinar futuras recomendações, criando um ciclo de feedback positivo que aprimora continuamente a eficácia do sistema de recomendação.

Atualizando previsões com base nos usuários

A reclassificação de avaliações com base no feedback dos usuários é um conceito crucial nos sistemas de recomendação que influencia diretamente a maneira como as preferências dos usuários são interpretadas e incorporadas ao modelo. Este processo não só ajusta as recomendações existentes, mas também ajuda a refinar os modelos de predição de preferências futuras.

Este processo envolve a atualização das avaliações de itens em uma matriz de recomendação com base no feedback contínuo dos usuários. Por exemplo: se um usuário classifica um item positivamente que inicialmente tinha uma avaliação mais baixa, o sistema ajusta não apenas a avaliação desse item, mas pode reavaliar itens

semelhantes ou relacionados. Esse processo ajuda a refletir mais precisamente as preferências atuais do usuário.

Neste contexto, é fundamental entender como o feedback contínuo de usuários e a reclassificação de avaliações são essenciais para a evolução e eficácia desses sistemas. Os sistemas de recomendação não são estáticos; eles aprendem e se adaptam com base nas interações e preferências de usuários. Cada avaliação ou feedback que um usuário fornece não é apenas uma informação isolada, mas um ponto de dados que pode influenciar muitas outras recomendações.

Quando usuários interagem com o sistema — seja classificando um produto, assistindo a um filme ou ouvindo uma música — eles fornecem dados valiosos que podem ser usados para ajustar e melhorar as recomendações futuras. Esse processo de reclassificação não só ajusta as avaliações de itens específicos como também pode afetar itens relacionados ou similares. Esta abordagem dinâmica garante que o sistema permaneça relevante e personalizado para as necessidades e gostos em constante mudança dos usuários.

A convergência de matrizes em técnicas de redução de dimensionalidade, embora complexa em sua execução, é crucial para manter a eficiência computacional e a precisão das recomendações. À medida que os dados são ajustados com base no feedback do usuário, os modelos subjacentes — seja através de decomposição de matrizes ou outras técnicas de aprendizado de máquina — devem ser atualizados para refletir essas mudanças. Isso não apenas melhora a precisão das recomendações, mas também enriquece a experiência do usuário, oferecendo sugestões que são verdadeiramente personalizadas e adaptativas.

Portanto, a capacidade de um sistema de recomendação de adaptar e evoluir com seu público é crucial. Um sistema bem projetado não apenas entende o que usuários gostaram no passado, mas também se antecipa às suas necessidades futuras, ajustando-se para oferecer recomendações que os mantêm engajados e satisfeitos. Isso é essencial para empresas que buscam não apenas manter, mas também expandir sua base de usuários, promovendo um ciclo de engajamento e satisfação que alimenta tanto o crescimento do usuário quanto o sucesso do negócio.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, exploramos o fascinante mundo dos sistemas de recomendação, abordando desde os fundamentos até estratégias específicas que ajudam esses sistemas a serem mais eficientes e personalizados. Discutimos como técnicas como PCA (Análise de Componentes Principais) e NMF (Fatoração de Matriz Não-Negativa) desempenham um papel crucial na redução da dimensionalidade e na interpretação de grandes conjuntos de dados, permitindo que os sistemas de recomendação processem informações de maneira mais eficaz e ofereçam sugestões mais precisas aos usuários.

Falamos também sobre o equilíbrio vital entre exploração e exploração em sistemas de recomendação. Exploração envolve descobrir novos itens ou preferências, enquanto exploração foca em utilizar o conhecimento existente para recomendar itens que já sabemos ser do agrado do usuário. Algoritmos como epsilon-greedy e UCB (Upper Confidence Bound) foram destacados como métodos para gerenciar esse equilíbrio, cada um com suas próprias vantagens e contextos de aplicação, e serão melhores avaliados na próxima aula.

Por fim, abordamos a importância de adaptar e evoluir continuamente os sistemas de recomendação através do feedback dos usuários. Isso não apenas melhora a precisão das recomendações como também assegura que os sistemas permaneçam relevantes e personalizados para as necessidades dos usuários.

Na próxima aula, vamos mergulhar nas técnicas de fatoração de matrizes, um componente chave nos sistemas de recomendação modernos. Exploraremos em detalhes como essas técnicas ajudam a descobrir as relações subjacentes entre usuários e itens, e como elas podem ser aplicadas para prever avaliações faltantes e aprimorar as recomendações. Prepare-se para um estudo aprofundado sobre SVD (Decomposição em Valores Singulares), NMF e outras abordagens de fatoração que são essenciais para o sucesso dos sistemas de recomendação. Até lá, continue explorando e aplicando o que aprendeu hoje para ter uma base sólida nesses conceitos complexos!

REFERÊNCIAS

AO, S.; RIEGER, B. B.; AMOUZEGAR, M. (ed.). **Machine learning and systems engineering**. [s.l.]: Springer Science & Business Media, 2010.

CHARU, C. A. **Recommender systems**: The textbook. [s.l.]: Springer, 2016.

FALK, K. **Practical recommender systems**. [s.l.]: Simon and Schuster, 2019.

MURPHY, K. P. **Machine learning**: a probabilistic perspective. [s.l.]: MIT Press, 2012.


SEVERT, N. **An Introduction to Recommender Systems (+9 Easy Examples)**. 2023. Disponível em: <<https://www.iteratorshq.com/blog/an-introduction-recommender-systems-9-easy-examples/>>. Acesso em: 01 jul. 2024.

SHETTY, B. **An In-Depth Guide to How Recommender Systems Work**. 2023. Disponível em: <<https://builtin.com/data-science/recommender-systems>>. Acesso em: 01 jul. 2024.

PALAVRAS-CHAVE

Palavras-chave: Sistemas de Recomendação. Popularidade. Redução de Dimensionalidade.

EMSE



POSTECH