

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	22
REFERÊNCIAS.....	23

EMSE

O QUE VEM POR AÍ?

Nesta aula sobre Fatoração de Matrizes, exploraremos como esta poderosa ferramenta de Álgebra Linear pode desvendar as informações ocultas nas interações dos usuários com sistemas de recomendação. Você já se perguntou como plataformas como Netflix e Amazon conseguem prever com tanta precisão o que você gostaria de assistir ou comprar a seguir? A resposta muitas vezes reside no que chamamos de espaços latentes — dimensões ocultas de dados que capturam aspectos não observados das interações dos usuários.

Abordaremos também a Fatoração de Matrizes Não-Negativas (NMF), uma técnica que permite decompor uma matriz de dados em componentes que são exclusivamente não-negativos, revelando padrões inerentemente positivos como gostos e preferências. Como avaliamos e escolhemos a melhor estratégia de fatoração? Entre a exploração de novos fatores e a exploração de padrões conhecidos, qual abordagem traz os melhores resultados? Estas são perguntas que guiaram nossa investigação e discussão. Como esses conceitos podem ser aplicados no mundo real e quais desafios eles apresentam na prática? Venha descobrir e aprofundar seu conhecimento sobre estes fascinantes tópicos.

Para aprofundar nos tópicos discutidos nesta aula, você pode consultar os seguintes materiais de referência anexados anteriormente. A "Breve introdução à Álgebra Linear" e "Espaços latentes" podem ser explorados detalhadamente no livro de John A. Lee e Michel Verleysen, "Nonlinear Dimensionality Reduction", particularmente útil para entender as bases matemáticas necessárias.

Para "Fatoração de Matrizes Não-Negativas", o texto de Kim Falk, "Practical Recommender Systems", oferece uma explanação prática da implementação dessa técnica em sistemas de recomendação. Além disso, a discussão sobre "Avaliando estratégias de fatoração: Exploração vs Exploração" pode ser enriquecida com os insights de Charu C. Aggarwal em "Recommender Systems: The Textbook", que aborda várias estratégias de fatoração e seus impactos nos sistemas de recomendação. Essas leituras complementarão sua compreensão dos conceitos introduzidos e ajudarão na aplicação prática dessas teorias.

HANDS ON

Vamos discutir exemplos práticos para cada um dos conceitos discutidos nesta aula. Iniciamos com uma breve introdução à Álgebra Linear, na qual entenderemos as bases que suportam os métodos de fatoração. Em seguida, exploraremos os espaços latentes, que revelam informações não observadas nas interações dos usuários, essenciais para entender o comportamento em sistemas de recomendação.



SAIBA MAIS

Observe o código-fonte a seguir, que traz um exemplo de operações matriciais com Python e Numpy:

```
import numpy as np
# Definindo duas matrizes
A = np.array([[1, 2], [3, 4]])
B = np.array([[2, 0], [1, 2]])
# Multiplicando as matrizes
C = np.dot(A, B)
print("Resultado da Multiplicação de Matrizes:\n", C)
```

Código-fonte 1 – Exemplo de Operações Matriciais com Python e Numpy
Fonte: Elaborado pelo autor (2024)

Prosseguiremos com a Fatoração de Matrizes Não-Negativas, um método poderoso para decompor uma matriz em componentes que capturam a estrutura dos dados de maneira eficiente e intuitiva:

```
from sklearn.decomposition import NMF
# Dados exemplo
V = np.array([[1, 2], [3, 4], [5, 6]])
model = NMF(n_components=1, init='random', random_state=0)
W = model.fit_transform(V)
H = model.components_
print("Matriz W (Base):\n", W)
print("Matriz H (Coeficientes):\n", H)
```

Código-fonte 2 – Implementando Fatoração de Matrizes com Scikit-Learn
Fonte: Elaborado pelo autor (2024)

Também vamos explorar os mecanismos de exploração e exploração através de exemplos de código em Python. Esses conceitos são cruciais para otimizar os sistemas de recomendação, balanceando entre descobrir novos itens (exploração) e recomendar os melhores conhecidos (exploração):

```
import numpy as np
import random

# Definindo um simples conjunto de recomendações
recomendacoes = [1, 2, 3, 4, 5] # Representa ids de itens recomendáveis
epsilon = 0.1 # 10% de chance de explorar

# Escolha entre explorar ou explorar
if random.random() < epsilon:
    # Explorar: escolher um item aleatório
    item_recomendado = random.choice(recomendacoes)
```

```
else:
    # Explotar: escolher o melhor item, assumindo que o item 5
    # é o melhor
    item_recomendado = 5

print("Item Recomendado:", item_recomendado)
```

Código-fonte 3 – Implementando o método Epsilon-Greedy com Python

Fonte: Elaborado pelo autor (2024)

Finalmente, vamos avaliar as estratégias de fatoração, focando em como balancear exploração e exploração para melhorar a performance dos sistemas de recomendação. Ao aplicar esses conceitos na prática, você será capaz de ver como as teorias são transformadas em soluções reais que podem ser implementadas em sistemas de recomendação.

Tendo isso em mente, agora vamos mergulhar mais profundamente na teoria por trás dos sistemas de recomendação, com um foco especial em técnicas de fatoração de matrizes e suas aplicações. Exploraremos os fundamentos matemáticos e estatísticos que sustentam os algoritmos de recomendação. Iremos discutir como diferentes métodos de fatoração, como SVD (Decomposição em Valores Singulares) e NMF (Fatoração de Matrizes Não-Negativas), são aplicados para descobrir padrões latentes em grandes conjuntos de dados, facilitando assim recomendações mais precisas e personalizadas.

Para aqueles indivíduos interessados em aprofundar seus conhecimentos, recomendo consultar o capítulo específico sobre técnicas de fatoração de matrizes no livro de Charu C. Aggarwal, "Recommender Systems: The Textbook". Este texto oferece uma exploração detalhada dos algoritmos, valor e inovação nos sistemas de recomendação, com exemplos práticos e teóricos que ilustram como essas técnicas são implementadas na prática.

Além disso, para uma visão prática de como essas técnicas são aplicadas no mundo real, o livro "Practical Recommender Systems" de Kim Falk é uma leitura essencial. Ele não só aborda a implementação de sistemas de recomendação como também discute a importância de entender o usuário e personalizar a experiência de recomendação com base em interações de dados reais.

Finalmente, para quem se interessa por explorações mais técnicas, o livro "Nonlinear Dimensionality Reduction" por John A. Lee e Michel Verleysen oferece insights sobre técnicas avançadas de redução de dimensionalidade que podem ser

aplicadas em sistemas de recomendação para lidar com a complexidade e a escala dos dados envolvidos.

Para que servem Sistemas de Recomendação?

No universo dos sistemas de recomendação, estamos diante de um complexo problema de otimização de portfólio que empresas enfrentam ao tentar maximizar a satisfação do cliente enquanto minimizam a assimetria de informação entre o que clientes realmente desejam e o que a empresa oferece. Esse dilema não é apenas uma questão de marketing, mas uma questão estratégica central para negócios que operam com um vasto portfólio de produtos ou serviços. As empresas precisam não só entender as preferências de seus clientes em tempo real, mas também prever essas preferências de forma eficiente e eficaz para aprimorar suas estratégias de engajamento e retenção.

A natureza desse problema envolve entender profundamente o que um agente prefere dentre as opções disponíveis que estão sendo recomendadas. Isso é crucial porque, em um cenário com milhares de produtos ou serviços, não é viável para clientes explorarem cada opção individualmente. Tal tarefa seria extremamente demorada e esmagadora, levando a uma parálise de decisão ou a uma experiência de usuário insatisfatória. Assim, o problema central dos sistemas de recomendação é como reduzir essa carga de informação e apresentar aos usuários opções que são mais relevantes e atraentes para seus gostos e necessidades individuais.

Consideremos, então, as estratégias que as empresas podem adotar para mitigar essa assimetria de informação. Uma abordagem é através da coleta e análise de dados sobre interações anteriores dos clientes com os produtos. Isso inclui, mas não se limita, a compras anteriores, itens navegados, avaliações fornecidas e até mesmo o comportamento de navegação no site. Estes dados, quando corretamente analisados, podem revelar padrões significativos que ajudam a prever as preferências futuras do cliente, permitindo que a empresa ajuste seu portfólio de recomendações de maneira mais assertiva e direcionada.

Essa análise leva ao coração dos sistemas de recomendação modernos, que se utilizam de técnicas sofisticadas como a fatoração de matrizes e a aprendizagem profunda para criar modelos preditivos. Esses modelos são capazes de processar e sintetizar grandes volumes de dados para identificar as preferências latentes dos

usuários, que podem não ser imediatamente óbvias. Assim, um sistema de recomendação eficaz não apenas simplifica a descoberta de produtos pelos consumidores, mas também enriquece a experiência do usuário ao garantir que cada recomendação seja altamente relevante e personalizada.

Finalmente, a otimização da relação entre itens e indivíduos através de sistemas de recomendação não é apenas uma questão de conveniência, mas uma estratégia crucial para a sobrevivência e o sucesso de empresas em ambientes altamente competitivos. As recomendações personalizadas não só aumentam a satisfação do cliente, mas também potencializam as vendas e a lealdade à marca.

Assim, o estudo e a implementação de estratégias eficazes de recomendação são essenciais e é por isso que dedicamos tempo para explorar e entender essas tecnologias. Esta aula visa fornecer as ferramentas e o conhecimento necessários para apreciar e aplicar esses conceitos avançados em contextos práticos, preparando você para desafios e oportunidades no campo dos sistemas de recomendação.

Os sistemas de recomendação são ferramentas essenciais em uma variedade de contextos, não apenas por oferecerem conveniência, mas também por permitirem personalização em ambientes nos quais a diversidade de usuários e de preferências pode criar desafios significativos. Por exemplo, imagine uma pessoa negra procurando produtos específicos para cabelos crespos em um centro comercial que predominantemente oferece produtos para cabelos lisos ou alisados. Neste caso, um sistema de recomendação eficaz pode direcionar o usuário imediatamente para as opções que atendem às suas necessidades específicas, melhorando significativamente sua experiência de compra.

Similarmente, um entusiasta de carros esportivos pode se encontrar em um mercado dominado por veículos utilitários esportivos. Um sistema de recomendação bem afinado poderia identificar suas preferências únicas e sugerir modelos que alinham com seu interesse, mesmo que sejam menos comuns na seleção geral disponível. Esses exemplos ilustram como os sistemas de recomendação não apenas melhoram a eficiência da busca, mas também reforçam a inclusão e a personalização no atendimento ao cliente.

Estes casos podem parecer extremos, mas a aplicação de sistemas de recomendação se estende a situações muito mais comuns e cotidianas. Considere,

por exemplo, a escolha de um limão em um supermercado. Dependendo do uso — seja para fazer um suco ou uma torta — os atributos desejados do limão podem variar significativamente. Um sistema de recomendação pode ajudar a identificar qual variedade de limão seria mais adequada para cada finalidade com base em informações previamente coletadas sobre preferências de outros usuários com intenções semelhantes.

Essa capacidade de discernir e recomendar com precisão se baseia em uma compreensão profunda das duas dimensões chave em qualquer mercado: os produtos e as pessoas. Cada produto tem atributos distintos e cada pessoa tem preferências que podem ou não ser bem conhecidas pela empresa. A incerteza sobre o que cada pessoa prefere em termos de atributos de cada item introduz uma complexidade que é intrinsicamente estocástica, necessitando de técnicas estatísticas sofisticadas para sua análise.

Uma das maneiras de representar e analisar essas relações complexas é através de matrizes, em que as dimensões representam usuários e itens e os valores representam as interações ou preferências. No entanto, devido à natureza não uniforme do consumo e à frequente ausência de interação (ou seja, a maioria dos usuários não interage com a maioria dos itens), estas matrizes tendem a ser extremamente esparsas. Esse desafio de esparsidade exige técnicas avançadas de redução de dimensionalidade para simplificar os dados sem perder informações críticas.

A implementação de técnicas de aprendizagem de máquina em sistemas de recomendação permite às empresas não apenas entender melhor os padrões de consumo, mas também antecipar tendências e preferências futuras. Por exemplo: ao analisar históricos de compra e avaliações de produtos, um sistema de recomendação pode identificar quais características de produtos estão mais alinhadas com as preferências de grupos específicos de consumidores.

Além disso, em um mercado globalizado, a diversidade dos consumidores é imensa. Sistemas de recomendação que utilizam PCA ou SVD podem ajustar suas recomendações para adequar-se a contextos culturais, regionais ou mesmo individuais específicos, garantindo que cada usuário sinta que suas necessidades e desejos são compreendidos e atendidos de maneira personalizada.

Outra consideração importante é a capacidade desses sistemas de lidar com a nova introdução de produtos. Em mercados dinâmicos, novos produtos são lançados frequentemente e podem rapidamente se tornar relevantes para certos segmentos de consumidores. Sistemas de recomendação eficazes são capazes de integrar rapidamente esses novos produtos em suas recomendações, utilizando as técnicas de redução de dimensionalidade para ajustar as matrizes de dados sem a necessidade de reprocessar toda a informação do zero.

Esse aspecto é crucial especialmente para startups e empresas de tecnologia que operam em ciclos rápidos de inovação. A habilidade de se adaptar e responder rapidamente às mudanças no mercado pode ser o diferencial que permite a uma empresa se destacar da concorrência. Sistemas de recomendação que podem eficientemente processar e incorporar novas informações são, portanto, indispensáveis.

No contexto de mercados altamente competitivos, os sistemas de recomendação também desempenham um papel estratégico em campanhas de marketing e vendas. Eles permitem que as empresas segmentem suas campanhas para públicos específicos com alta precisão, baseando-se em dados analíticos robustos extraídos através de técnicas como PCA e SVD.

A análise desses dados não apenas ajuda a personalizar a comunicação e as ofertas para consumidores, mas também otimiza os recursos das empresas ao direcionar esforços de marketing para os canais e públicos que provavelmente trarão o maior retorno sobre o investimento. Esse alinhamento entre as preferências dos consumidores e as estratégias de marketing e vendas é o que muitas vezes define o sucesso no mercado atual.

Ademais, sistemas de recomendação são essenciais para plataformas online, em que a experiência do usuário pode ser diretamente influenciada pela capacidade do sistema de apresentar produtos e ofertas relevantes. Uma navegação intuitiva e recomendações personalizadas aumentam significativamente a probabilidade de conversão de visitas em vendas.

Fundamentos de Álgebra Linear

Álgebra linear é um ramo fundamental da matemática que trata de vetores, espaços vetoriais (também conhecidos como espaços lineares), transformações

lineares e sistemas de equações lineares. Em particular, as matrizes, que são arranjos retangulares de números, desempenham um papel central na álgebra linear, pois facilitam a manipulação de grandes conjuntos de equações lineares.

Uma matriz é definida por suas linhas (horizontais) e colunas (verticais), cada entrada na matriz sendo um elemento que pode ser um número real ou complexo. Formalmente, Uma matriz é uma representação retangular de elementos arranjados em linhas e colunas. Assim, uma matriz A de dimensão $m \times n$ sobre o conjunto dos números reais $\mathbb{R}$ é uma coleção ordenada de números reais dispostos em m linhas e n colunas. Isso é denotado como:

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$$

Vetores reais são casos especiais de matrizes e podem ser considerados como matrizes com apenas uma coluna (vetores coluna) ou uma linha (vetores linha), elemento de um espaço vetorial $\mathbb{X}$, que pode ser pensado como um objeto que possui magnitude e direção. Em um contexto matemático mais formal, um vetor pode ser representado como uma matriz de uma coluna com n elementos, em que cada elemento pertence a um campo, como os números reais $\mathbb{R}$. A notação geral para um vetor é:

$$\begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$$

A matriz identidade, por sua vez, é um tipo especial de matriz quadrada na qual todos os elementos na diagonal principal são iguais a 1 e todos os outros elementos são 0. Ela atua como um elemento neutro na multiplicação de matrizes, de modo que qualquer matriz multiplicada pela matriz identidade não é alterada:

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Finalmente, dada uma matriz A , se existe uma matriz B tal que $A \times B = I$, dizemos que B é a **matriz inversa** de A e a representamos como $B := A^{-1}$.

Os conceitos de **autovetor** e **autovalor** são fundamentais na álgebra linear e têm aplicações significativas em várias áreas, incluindo análise de sistemas dinâmicos, otimização, e, como vimos, na decomposição de matrizes em sistemas de

recomendação. Um autovalor de uma matriz quadrada A é um escalar λ que satisfaz a equação

$$(A - \lambda I)v = 0$$

em que I é uma matriz identidade e v um vetor não nulo. Este vetor v é chamado de **autovetor** associado a λ . A equação mostra que, ao aplicar a matriz A ao vetor v , o resultado é um novo vetor que é um múltiplo escalar de v . Os autovalores e autovetores têm um significado profundo em termos da estrutura da matriz. Eles são usados para entender as propriedades fundamentais da matriz, como estabilidade e tipo de transformações que a matriz pode representar. Em termos práticos, eles são essenciais no estudo de sistemas dinâmicos, em que os autovalores podem indicar a estabilidade do sistema, e em computação gráfica, para transformações e redimensionamento de objetos.

Matrizes diagonais são outro tipo importante de matriz, nas quais todos os elementos fora da diagonal principal são zero. As matrizes diagonais são particularmente interessantes porque suas propriedades simplificam muitas operações matemáticas, especialmente no contexto de transformações lineares e autovalores. Uma matriz diagonal é uma matriz quadrada na qual os elementos fora da diagonal principal são todos zero. Formalmente, uma matriz A de tamanho $n \times n$ é diagonal se $A_{ij} = 0 \forall i \neq j$ e pode ser representada como:

$$A = \begin{bmatrix} a_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & a_{nn} \end{bmatrix}$$

sendo que a_{ii} são os elementos da diagonal principal, que podem ser qualquer número real ou complexo. Uma matriz A é dita diagonalizável se existir uma matriz invertível P e uma matriz diagonal D tais que:

$$A = PDP^{-1}$$

Neste caso, as colunas de P são formadas pelos **autovetores** de A e a matriz D contém os correspondentes **autovalores** na diagonal principal. A diagonalização é especialmente poderosa porque simplifica muitos cálculos matemáticos, permitindo representar a matriz A em uma forma mais simples.

Vetores são ditos ortogonais se o seu produto interno é zero. Formalmente, dois vetores $u \in \mathbb{R}^n$ e $v \in \mathbb{R}^n$ são ortogonais se

$$\mathbf{u} \cdot \mathbf{v} = \sum_{i=1}^n u_i v_i = 0$$

Por outro lado, uma matriz Q é dita **ortogonal** se suas colunas (ou linhas) formam um conjunto de vetores ortogonais unitários. Matematicamente, isso significa que Q deve satisfazer:

$$Q^T Q = Q Q^T = I$$

em que Q^T é a transposta de Q e I é a matriz identidade. A condição $Q^T Q = I$ implica que o **produto interno de qualquer par de colunas distintas é zero** (ortogonalidade) e o produto interno de qualquer coluna consigo mesma é um (normalidade). Quando se trata de matrizes ortogonais, os **autovetores associados a autovalores distintos são necessariamente ortogonais**. Esta propriedade deriva do teorema espectral, que afirma que qualquer matriz simétrica A pode ser diagonalizada por uma matriz ortogonal Q , ou seja:

$$A = Q \Lambda Q^T$$

sendo que Λ é uma matriz diagonal contendo os autovalores de A e as colunas de Q são os autovetores de A . Esse teorema não apenas facilita a compreensão das propriedades das matrizes simétricas, mas também fornece uma base teórica para técnicas como PCA, que busca reduzir a dimensionalidade de dados através da identificação das direções de maior variação nos dados.

Todos estes conceitos são aplicados na Decomposição em Valores Singulares (SVD) e na Análise de Componentes Principais (PCA), casos especiais da Fatoração de Matrizes, que são usadas para reduzir a dimensionalidade de dados grandes, melhorando assim a eficiência de algoritmos em machine learning e sistemas de recomendação. Essas técnicas permitem que grandes conjuntos de dados sejam simplificados, preservando as características mais significativas e apontando a relevância entre pares (x_i, y_i) , sendo x_i uma pessoa qualquer e y_i um item qualquer do portfólio de recomendação.

O Problema da Alta dimensão dos Dados

Matrizes de dados de alta dimensão frequentemente apresentam desafios significativos em tarefas de inferência e análise devido à complexidade e ao volume de dados envolvidos. Essas matrizes podem ser problemáticas por várias razões,

como a "maldição da dimensionalidade", que pode levar a um aumento exponencial no volume de espaço necessário para armazenar os dados, tornando os métodos de análise computacionalmente inviáveis e menos eficazes.

A alta dimensionalidade também pode diluir a importância de cada característica, dificultando a identificação de correlações significativas e aumentando o risco de overfitting em modelos preditivos

A maldição da dimensionalidade descreve a exponencialização do volume do espaço geométrico com o aumento do número de dimensões. Formalmente, se considerarmos um espaço euclidiano $\mathbb{R}^n$ com cada dimensão tendo um comprimento de intervalo L , o volume do espaço é dado por L^n . À medida que n aumenta, o volume do espaço cresce exponencialmente, o que implica que uma quantidade enorme de dados é necessária para manter uma densidade de amostra representativa.

Uma abordagem eficaz para lidar com a maldição da dimensionalidade é a Fatoração de Matrizes Não Negativas (NMF). A NMF é uma técnica de redução de dimensionalidade que transforma uma matriz de dados de alta dimensão em componentes de menor dimensão, mantendo a natureza não negativa dos dados, o que é especialmente útil em contextos em que os dados são inerentemente positivos, como imagens e informações de consumo.

A NMF funciona decompondo a matriz original V de dimensão $m \times n$ em duas matrizes menores W e H , sendo que $V \approx W \times H$. Aqui, W é uma matriz de dimensão $m \times k$ e H uma matriz de dimensão $k \times n$, com k sendo tipicamente muito menor do que m e n . Essa decomposição não apenas reduz a complexidade dos dados como também ajuda a revelar as características latentes subjacentes aos dados, facilitando a interpretação e a análise.

O principal benefício da NMF é que ela permite que as características extraídas mantenham uma interpretação física ou quantitativa, sendo particularmente útil em aplicações como análise de texto, agrupamento de genes em bioinformática e recomendação de sistemas, em que a interpretabilidade dos componentes é crucial.

A redução da dimensionalidade por meio da NMF além de melhorar a eficiência dos cálculos também ajuda a identificar as características mais relevantes dos dados, mitigando problemas como ruído e redundância em matrizes de grande escala.

Portanto, a Fatoração de Matrizes Não Negativas é uma ferramenta valiosa para enfrentar os desafios impostos por dados de alta dimensão, proporcionando uma abordagem robusta e eficiente para a descoberta de padrões significativos e a realização de inferências precisas em grandes conjuntos de dados.

Decomposição em Valores Singulares

A Decomposição em Valores Singulares (SVD) é uma técnica matemática poderosa utilizada em muitas áreas da ciência e engenharia para análise de dados, redução de dimensionalidade, processamento de sinais e muito mais. Vamos explorar detalhadamente como o SVD funciona, suas limitações e alguns casos de uso relevantes.

O SVD é uma técnica que decompõe uma matriz A de dimensão $m \times n$ em três outras matrizes denominadas U , Σ , e V^T , sendo que U é uma matriz ortogonal $m \times m$, Σ é uma matriz diagonal $m \times n$ com elementos não negativos na diagonal, conhecidos como valores singulares, e V^T é a transposta de uma matriz ortogonal $n \times n$. A relação é expressa matematicamente como:

$$A = U\Sigma V^T$$

Os valores singulares em Σ são os comprimentos dos eixos do elipsoide formado pela transformação de A aplicada à esfera unitária. Estes valores são fundamentais porque indicam a "força" ou impacto de cada direção nos dados originais.

Limitações do SVD

Embora o SVD seja uma ferramenta extremamente versátil e poderosa, ele tem algumas limitações:

- **Custo Computacional:** o SVD pode ser computacionalmente caro, especialmente para matrizes de grandes dimensões, o que pode limitar sua aplicabilidade em tempo real ou em sistemas com recursos limitados.
- **Sensibilidade a Alterações nos Dados:** pequenas alterações nos dados podem às vezes resultar em grandes mudanças nos valores singulares, o que pode afetar a estabilidade das soluções dependentes de SVD.

Casos de Uso

- **Reconhecimento de Padrões e Imagens:** no processamento de imagens, o SVD é usado para compressão de imagem e melhoria da qualidade.
- **Análise Semântica Latente:** em processamento de linguagem natural, o SVD é usado para reduzir a dimensionalidade de matrizes de termos por documentos, ajudando a identificar contextos e tópicos semelhantes.
- **Sistemas de Recomendação:** o SVD ajuda a decompor matrizes de usuários e itens para prever itens que um usuário pode gostar, baseando-se em suas atividades anteriores.

Análise de Componente Principal

A Análise de Componentes Principais (PCA) é uma técnica fundamental na estatística multivariada e na ciência de dados, amplamente utilizada para redução de dimensionalidade e análise exploratória de grandes conjuntos de dados. A PCA transforma um conjunto original de variáveis correlacionadas em um novo conjunto de variáveis, chamadas componentes principais, que são ortogonais entre si e capturam a maior parte da variabilidade dos dados.

Antes de aplicar a PCA, os dados devem ser centralizados. Isso envolve subtrair a média de cada variável de todas as observações para garantir que cada variável tenha média zero. Se X é uma matriz de dados $n \times p$ (em que n é o número de observações e p o número de variáveis), a média de cada coluna é subtraída de seus respectivos valores.

A matriz de covariância C é calculada como:

$$C = \frac{1}{n-1} X^T X$$

Esta matriz $p \times p$ representa as covariâncias entre cada par de variáveis nos dados. A PCA procura os autovalores e autovetores da matriz de covariância C . Os autovalores $\lambda_1, \lambda_2, \dots, \lambda_p$ fornecem a variância explicada por cada componente principal e os autovetores associados representam as direções desses componentes no espaço original.

Os componentes são ordenados por magnitude de seus autovalores, em ordem decrescente. A seleção de quantos componentes principais manter é geralmente

baseada na proporção acumulada da variância explicada, que é a soma dos autovalores dos componentes selecionados dividida pela soma total dos autovalores.

Limitações da PCA

- **Sensibilidade a Outliers:** a PCA é altamente sensível a outliers, pois eles podem distorcer significativamente a média e a matriz de covariância, levando a uma representação errônea das principais direções de variabilidade.
- **Perda de Informação:** ao descartar componentes com menor variância há uma inevitável perda de informação, que pode ser crítica se as variáveis descartadas contiverem aspectos importantes dos dados.
- **Dificuldade de Interpretação:** os componentes principais são combinações lineares das variáveis originais e podem ser difíceis de interpretar, especialmente quando as variáveis originais são numerosas e complexas.

Aplicações da PCA

- **Visualização de Dados Complexos:** em genômica, a PCA é frequentemente usada para visualizar padrões complexos de expressão gênica em amostras biológicas, ajudando a identificar agrupamentos de amostras com características fenotípicas semelhantes.
- **Sistemas de Recomendação:** a PCA é aplicada para reduzir a dimensionalidade em grandes conjuntos de preferências, facilitando tarefas como a identificação de padrões de consumo e escolha de produtos.
- **Finanças:** na análise de risco e retorno de portfólios de investimento, a PCA pode decompor as flutuações do mercado em fatores principais, ajudando analistas a entender melhor as fontes de risco e a otimizar as estratégias de investimento.

Fatoração de Matrizes Não-Negativas

A Fatoração de Matrizes Não-Negativas (NMF, do inglês Non-Negative Matrix Factorization) é uma técnica de redução de dimensionalidade e aprendizado de características que tem ganhado popularidade em diversos campos, como análise de

imagem, mineração de texto e bioinformática. Vamos explorar como o NMF funciona, detalhar seus cálculos, discutir suas limitações e apresentar alguns casos de uso.

Funcionamento do NMF

Como apresentado anteriormente, o NMF é uma técnica que decompõe uma matriz de dados V de dimensão $m \times n$ (em que cada elemento $v_{ij} \geq 0$) em duas matrizes de baixa dimensão, W e H , sendo que W é de dimensão $m \times k$ e H de dimensão $k \times n$, com a propriedade de que todos os elementos dessas duas matrizes são também não-negativos. A ideia é que $V \approx WH$, em que k é tipicamente menor que tanto m quanto n , e representa o número de características latentes.

Cálculos do NMF

A implementação do NMF envolve a minimização da função de custo, que mede o erro entre a matriz original V e a matriz reconstruída WH . Um exemplo comum de função de custo é o erro quadrático:

$$\|V - WH\|^2 = \sum_{i,j} (v_{ij} - x_{ij})^2, x_{ij} \in WH$$

O processo de otimização ajusta iterativamente as matrizes W e H para minimizar essa função de custo, tipicamente usando métodos baseados em gradiente ou algoritmos de multiplicação de atualização:

$$\min_x \sum_{i,j} (v_{ij} - x_{ij})^2 := \frac{d \sum_{i,j} (v_{ij} - x_{ij})^2}{dx_{i,j}} = 0, \forall i, j$$

Exemplo Prático de Solução

Suponha uma matriz de dados V de tamanho 4×5 representando cinco características de quatro amostras. Aplicando NMF, escolhemos reduzir as características para $k = 2$. Inicializamos W e H com valores aleatórios positivos e aplicamos um algoritmo de otimização para ajustar essas matrizes. Após a convergência, W conterá a base das características latentes e H terá os coeficientes que combinam essas bases para aproximar V .

Limitações do NMF

- **Dependência de Inicialização:** o resultado do NMF pode variar significativamente dependendo da inicialização das matrizes W e H , o que pode levar a minimizações locais no processo de otimização.
- **Interpretabilidade das Características:** embora o NMF geralmente forneça uma base compreensível para as características, a interpretação física ou significativa das matrizes W e H nem sempre é direta ou possível.
- **Seleção do Número de Componentes:** determinar o número apropriado de componentes k não é trivial e geralmente depende de critérios externos ou experimentação.

Casos de Uso

- **Análise de Texto:** o NMF é usado para identificar tópicos em grandes coleções de documentos, sendo que cada documento é representado como uma combinação de tópicos e cada tópico é uma combinação de palavras.
- **Reconhecimento de Imagens:** na visão computacional, o NMF pode ser aplicado para extrair partes características de faces ou outros objetos em imagens.
- **Bioinformática:** o NMF tem sido utilizado para analisar padrões de expressão genética, ajudando a identificar grupos de genes que compartilham padrões de expressão similares em diferentes amostras ou condições.

Limite de confiança superior e a seleção de itens para pessoas

O Método Upper Confidence Bound (UCB) é uma abordagem popular para o problema do bandido multi-braço, que é um modelo de decisão utilizado em muitas aplicações práticas, como otimização de campanhas publicitárias, sistemas de recomendação e alocação de recursos. O UCB visa equilibrar a exploração (testar novas opções) e a exploração (capitalizar as opções conhecidas) para maximizar as recompensas ao longo do tempo.

O UCB baseia-se na ideia de "otimismo frente à incerteza", ou seja, dá preferência às ações sobre as quais temos menos informação ou que têm potencial

para serem ótimas. A lógica é que, explorando as ações que poderiam ter altas recompensas, mas ainda não foram suficientemente testadas, o algoritmo pode descobrir e explorar a melhor ação de um agente mais rapidamente.

Cálculo do UCB

O valor UCB para cada ação é calculada usando a fórmula:

$$UCB = \bar{X}_j + \sqrt{\frac{2 \log(n)}{n_j}}$$

em que:

- $\bar{X}_j$ é a média das recompensas recebidas pela ação.
- n é o número total de vezes que todas as ações foram tomadas.
- n_j é o número de vezes que a ação j foi executada.

A ideia é que cada ação tem seu valor de recompensa média aumentado por um termo que cresce mais lentamente à medida que a ação é mais frequentemente tomada. Este termo representa a incerteza ou variabilidade na estimativa da recompensa da ação; quanto menos vezes uma ação foi testada, maior é a incerteza e, portanto, maior é o potencial de aumento de seu UCB.

Exemplo Prático

Suponhamos que temos três ações em um problema de agente, cada um com um número diferente de execuções e recompensas médias. Após 100 tentativas totais, os braços A , B e C foram executados 30, 50 e 20 vezes, respectivamente, com recompensas médias de 1.0, 1.5 e 1.3. As recompensas UCB para cada ação seriam calculados como segue, assumindo que estamos na 101ª tentativa:

- $UCB_A = 1.0 + \sqrt{\frac{2 \log 100}{30}}$
- $UCB_B = 1.5 + \sqrt{\frac{2 \log 100}{50}}$
- $UCB_C = 1.3 + \sqrt{\frac{2 \log 100}{20}}$

A ação com maior UCB será escolhida na próxima tentativa, permitindo um equilíbrio entre exploração e exploração. Ademais, o UCB pode ser visto como uma

recompensa potencial por uma tomada de ação menos frequente, facilitando a exploração de novas possibilidades quando o ambiente de retorno é fixo.

Limitações do UCB

- **Desempenho em Ambientes Não Estacionários:** o UCB pode não se adaptar bem a ambientes nos quais as probabilidades de recompensa das ações mudam ao longo do tempo, uma vez que depende de uma acumulação histórica de recompensas.
- **Dependência do Parâmetro de Exploração:** a taxa de exploração no UCB é controlada pelo coeficiente do termo de exploração na fórmula UCB. A escolha deste parâmetro pode afetar significativamente o desempenho do algoritmo.

Casos de Uso

- **Sistemas de Recomendação:** o UCB pode ser usado para equilibrar entre recomendar artigos que são conhecidos por serem populares versus explorar novos artigos.
- **Alocação de Recursos:** em ambientes de nuvem, o UCB pode ajudar a alocar recursos entre diferentes tarefas, maximizando a utilização eficiente dos recursos.
- **Publicidade Online:** o UCB é ideal para otimizar a seleção de anúncios em campanhas publicitárias, maximizando os cliques ou conversões.

O QUE VOCÊ VIU NESTA AULA?

Na jornada de desvendar os segredos dos sistemas de recomendação, os algoritmos de fatoração de matrizes emergem como ferramentas cruciais. Eles são empregados para identificar e extrair características latentes dos dados, que facilitam a compreensão das afinidades entre usuários e itens. Essa abordagem permite que o sistema descubra os aspectos subjacentes que aumentam a similaridade entre uma pessoa e um item, facilitando recomendações precisas e personalizadas.

A validação dessas recomendações é realizada por meio de métricas e estratégias como o Upper Confidence Bound (UCB), que equilibra eficazmente a exploração de novas possibilidades com a exploração de escolhas conhecidas por serem benéficas.

Entretanto, o universo dos sistemas de recomendação não se limita apenas a técnicas de fatoração de matrizes. Existem inúmeras outras estratégias que podem ser exploradas para aprimorar a relação entre produtos e pessoas. Algoritmos mais complexos, incluindo aqueles baseados em árvores de decisão e estruturas de grafos, são utilizados para realizar tarefas sofisticadas de regressão e classificação.

Essas abordagens oferecem caminhos alternativos e potencialmente mais robustos para analisar as interações de usuários, ajustar recomendações em tempo real e lidar com a dinâmica sempre mutante das preferências dos consumidores.

Para aqueles interessados em aprofundar seus conhecimentos nos sistemas de recomendação e explorar diversas técnicas e suas aplicações, uma série de leituras complementares é recomendada. Além das referências compartilhadas, como os trabalhos de Charu C. Aggarwal e Kim Falk, blogs especializados e artigos acadêmicos disponíveis na internet proporcionam uma rica fonte de aprendizado e inspiração.

Esses recursos não apenas ampliam o entendimento teórico como oferecem insights práticos sobre como essas tecnologias estão sendo implementadas em diferentes indústrias para resolver problemas reais de negócios.

REFERÊNCIAS

AO, S.; RIEGER, B. B.; AMOUZEGAR, M. (ed.). **Machine learning and systems engineering**. [s.l.]: Springer Science & Business Media, 2010.

CHARU, C. A. **Recommender systems**: The textbook. [s.l.]: Springer, 2016.

FALK, K. **Practical recommender systems**. [s.l.]: Simon and Schuster, 2019.

MURPHY, K. P. **Machine learning**: a probabilistic perspective. [s.l.]: MIT Press, 2012.

LEE, J. A.; VERLEYSEN, M. **Nonlinear Dimensionality Reduction**. [s.l.]: Springer, 2007.

PALAVRAS-CHAVE

Palavras-chave: Sistemas de Recomendação. Fatoração de Matrizes. Aprendizagem de Máquina.

EMENDAS



POSTECH