

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	24
REFERÊNCIAS.....	25

EMSE

O QUE VEM POR AÍ?

Na aula sobre "Filtragem Colaborativa", mergulharemos profundamente nos mecanismos que possibilitam os sistemas de recomendação modernos a entender e prever as preferências dos usuários de maneira eficaz e eficiente. Vamos explorar como a filtragem colaborativa utiliza dados de interações passadas para formar padrões preditivos e como essas informações são essenciais para recomendar novos produtos que provavelmente interessarão aos usuários.

Você já se perguntou como as plataformas online parecem conhecer tão bem suas preferências? Bom, veremos os segredos por trás dessa personalização inteligente, abordando desde a formação de matrizes de utilidade, que mapeiam as preferências dos usuários, até a aplicação de métodos estatísticos e de aprendizado de máquina para classificar a relevância dos itens.

Além disso, discutiremos técnicas avançadas como a aplicação de deep learning para processar e recomendar conteúdos de forma multimodal, integrando dados de texto, imagem e som. Como essas tecnologias podem transformar a experiência de navegação em algo totalmente personalizado? Quais são os desafios associados a esses avanços, especialmente em termos de custos computacionais e implementação prática?

Ao adentrarmos o mundo da análise de agrupamentos e da regressão para identificar similaridades, veremos como essas estratégias não só melhoram a precisão das recomendações como também como moldam o futuro das interações entre consumidores e plataformas digitais. Prepare-se para uma jornada fascinante através do complexo, mas incrivelmente recompensador, campo dos sistemas de recomendação.

HANDS ON

Na aula prática sobre "Filtragem Colaborativa", exploraremos detalhadamente como esses métodos são aplicados em sistemas de recomendação modernos através de videoaulas interativas. Cada sessão irá focar em um aspecto específico da filtragem, combinando teoria com exemplos práticos de código em Python e C++ para ilustrar a implementação de cada conceito.



SAIBA MAIS

Continuando a nossa aula, discutiremos o que é a filtragem colaborativa e como ela utiliza dados de interações passadas para fazer recomendações. Os alunos e alunas aprenderão como as características das compras anteriores podem ser analisadas para prever futuras compras. Por exemplo: vamos explorar como implementar um sistema básico de recomendação usando a correlação de Pearson para calcular a similaridade entre os usuários. O código em C++ poderá ser algo como:

```
#include <vector>
#include <cmath>

// Função para calcular a correlação de Pearson entre dois usuários

double pearsonCorrelation(const std::vector<double>& ratingsA,
const std::vector<double>& ratingsB) {
    double sumX = 0, sumY = 0, sumXY = 0, sumX2 = 0, sumY2 = 0;
    int n = ratingsA.size();

    for (int i = 0; i < n; i++) {
        sumX += ratingsA[i];
        sumY += ratingsB[i];
        sumXY += ratingsA[i] * ratingsB[i];
        sumX2 += ratingsA[i] * ratingsA[i];
        sumY2 += ratingsB[i] * ratingsB[i];
    }

    double numerator = n * sumXY - sumX * sumY;
    double denominator = sqrt((n * sumX2 - sumX * sumX) * (n *
sumY2 - sumY * sumY));
    return numerator / denominator;
}
```

Código-fonte 1 – Correlação de Pearson em C++

Fonte: Elaborado pelo autor (2024)

A seguir, vamos nos aprofundar na ideia de matrizes de utilidade que representam as preferências dos usuários. Aprenderemos a definir e utilizar essas matrizes para modelar escolhas econômicas em um contexto de filtragem colaborativa. O código poderá envolver a criação e a manipulação de matrizes para representar essas utilidades:

```
#include <iostream>
#include <vector>
```

```
// Função para imprimir uma matriz de utilidade
void printUtilityMatrix(const std::vector<std::vector<double>>&
matrix) {
    for (const auto& row : matrix) {
        for (double val : row) {
            std::cout << val << " ";
        }
        std::cout << std::endl;
    }
}

int main() {
    // Exemplo de matriz de utilidade
    std::vector<std::vector<double>> utilityMatrix = {
        {4.5, 0, 3.5, 0},
        {0, 3.5, 4, 5},
        {5, 4.5, 0, 3.5}
    };

    printUtilityMatrix(utilityMatrix);
    return 0;
}
```

Código-fonte 2 – Composição de Matrizes em C++
Fonte: Elaborado pelo autor (2024)

Também exploraremos como algoritmos de agrupamento, como o k-means, podem ser utilizados para classificar usuários com base em suas preferências. Vamos implementar um exemplo prático do algoritmo k-means em Python. Este exemplo ajudará a entender como configurar e aplicar clusters para agrupar usuários em um contexto de filtragem colaborativa:

```
from sklearn.cluster import KMeans
import numpy as np

# Exemplo de dados de usuários, onde cada linha representa um
usuário
# e cada coluna representa uma característica de preferência
data = np.array([
    [5.0, 3.0, 0, 0],
    [4.0, 0, 4.5, 3.5],
    [0, 5.0, 4.0, 4.5],
    [0, 3.5, 4.0, 0]
])

# Configurando o KMeans com um número desejado de clusters
kmeans = KMeans(n_clusters=2, random_state=0)

# Ajustando o modelo aos dados
kmeans.fit(data)
```

```
# Saída dos centróides dos clusters e das etiquetas de cada ponto
print("Centroids:")
print(kmeans.cluster_centers_)
print("\nLabels:")
print(kmeans.labels_)

# Prever o cluster para um novo conjunto de dados
new_data = np.array([
    [0, 4.0, 3.0, 3.0],
    [5.0, 3.5, 0, 0]
])
print("\nNew Data Labels:")
print(kmeans.predict(new_data))
```

Código-fonte 3 – Implementação do K-Means em Python
Fonte: Elaborado pelo autor (2024)

Neste script, inicializamos o KMeans com dois clusters. Os dados são fictícios e representam as preferências dos usuários em quatro diferentes categorias de produtos. Após o ajuste do modelo aos dados, o script imprime os centróides de cada cluster, que representam as características médias das preferências dentro de cada grupo, e as etiquetas atribuídas a cada usuário. Também demonstramos como prever os clusters de um novo conjunto de dados, que é uma prática comum para testar a generalização do modelo.

A filtragem colaborativa é uma metodologia central nos sistemas de recomendação modernos, fundamentando-se no princípio de que usuários com preferências similares em um passado comum tendem a ter gostos semelhantes no futuro. Esta técnica utiliza o poder das avaliações coletivas para fazer previsões personalizadas sobre o que um usuário pode gostar baseando-se nas preferências de outros usuários dentro de um banco de dados compartilhado.

A abordagem pode ser dividida em dois métodos principais: baseado em memória, que considera as interações diretas dos usuários com os itens, e baseado em modelo, que envolve a construção de modelos preditivos a partir dos dados de avaliação.

Na prática, a filtragem colaborativa é exemplificada em várias plataformas digitais conhecidas por suas recomendações personalizadas. Por exemplo: a Amazon utiliza este método para sugerir produtos aos usuários baseando-se nas compras e avaliações de outros usuários que compraram itens similares. Da mesma forma, serviços de streaming como a Netflix utilizam algoritmos de filtragem colaborativa para

recomendar filmes e séries baseados no histórico de visualizações e preferências expressas por um vasto grupo de usuários.

Esses exemplos práticos demonstram como a filtragem colaborativa facilita uma experiência de usuário altamente personalizada e eficaz, destacando-se como uma ferramenta essencial para empresas que buscam melhorar a satisfação do cliente e otimizar suas estratégias de marketing.

A filtragem colaborativa estrutura-se logicamente através de um processo de implementação claro, que se inicia com a coleta de avaliações de usuários sobre itens específicos, formando uma matriz de interação. Esta matriz é fundamental para o algoritmo, pois as recomendações são baseadas em padrões descobertos através das relações entre usuários e itens.

Primeiramente, o sistema identifica usuários com padrões de avaliação semelhantes e utiliza essa informação para prever a preferência de itens ainda não avaliados pelo usuário alvo. Este processo pode ser realizado de duas formas principais: filtragem colaborativa baseada em usuário, que foca nas relações entre usuários, e filtragem colaborativa baseada em item, que se concentra nas relações entre os itens avaliados.

A filtragem colaborativa pode ser justificada pelo uso de funções de utilidade, um conceito central na teoria da escolha. Neste contexto, as funções de utilidade representam o valor ou satisfação que um usuário obtém de um item e o objetivo é maximizar essa utilidade através das recomendações.

Este método reflete a abordagem de maximização de utilidade encontrada na teoria econômica, em que os indivíduos (ou usuários, neste caso) tomam decisões que maximizam seu bem-estar percebido, baseando-se nas preferências reveladas por comportamentos passados e similaridades com outros usuários. A implementação prática desse conceito ajuda a personalizar as recomendações de maneira eficaz, aumentando a probabilidade de satisfação do usuário com os itens sugeridos.

A matriz de dados em filtragem colaborativa, conhecida como matriz de utilidade ou matriz de interação, contém as avaliações que os usuários dão aos itens. Formalmente, essa matriz é denotada como R de dimensões $m \times n$, sendo que m representa o número de usuários e n o número de itens (como visto na aula anterior). Cada elemento $r_{u,i}$ da matriz R representa a avaliação dada pelo usuário u ao item i .

No entanto, muitos desses elementos serão desconhecidos, refletindo o fato de que nem todos os usuários avaliam todos os itens.

Para lidar com essa esparsidade, as técnicas de decomposição de matrizes discutidas na aula anterior são aplicadas para transformar a matriz original em espaços latentes que capturam as preferências subjacentes e características dos itens.

Essa estrutura matricial também se relaciona diretamente com teorias econômicas, especialmente através da aplicação de funções de utilidade. Na filtragem colaborativa, cada entrada da matriz pode ser vista como uma expressão da utilidade que um usuário deriva de um item. A hipótese fundamental é que usuários com preferências similares proporcionarão utilidades similares aos mesmos itens, o que justifica o uso de técnicas de aproximação para prever classificações não observadas.

Essa abordagem é formalmente estruturada pela definição de uma função de utilidade $U(u, i)$, em que u e i representam usuários e itens, respectivamente. O objetivo é maximizar U ao prever as classificações faltantes, o que em termos matemáticos envolve resolver um problema de otimização que minimiza a diferença entre as classificações observadas e as previsões, frequentemente usando métodos como gradiente descendente ou outros algoritmos de otimização.

Buscando Escolhas ótimas

O problema de otimização de utilidades na filtragem colaborativa pode ser formalizado de maneira matemática utilizando conceitos de álgebra linear e otimização. Vamos definir formalmente o problema e explorar como ele é estruturado e resolvido.

Formulação do Problema

Seja R uma matriz de dimensões $m \times n$, em que m representa o número de usuários e n o número de itens. Cada entrada r_{ui} da matriz R representa a avaliação (ou utilidade) que o usuário u atribui ao item i . Muitas dessas entradas são desconhecidas, o que leva à necessidade de prever essas avaliações faltantes.

A função de utilidade $U(u, i)$ representa o valor ou satisfação que o usuário u obtém ao consumir o item i . O objetivo do sistema de recomendação é prever as

entradas desconhecidas da matriz R de modo a maximizar a utilidade geral percebida pelos usuários.

Formulação Matemática da Otimização

O problema de otimização pode ser formulado como a minimização do erro entre as avaliações conhecidas e as avaliações preditas. Uma abordagem comum é minimizar a soma dos erros quadráticos, o que é conhecido como minimização do erro quadrático médio (MSE). Matematicamente, o problema pode ser descrito como:

$$\min_{\hat{R}} \sum_{(u,i) \in \Omega} (r_{ui} - \hat{r}_{ui})^2$$

em que:

- $\hat{R}$ é a matriz de avaliações preditas.
- Ω é o conjunto de todos os pares de usuário-item para os quais as avaliações são conhecidas.
- r_{ui} é a avaliação real dada pelo usuário u ao item i .
- $\hat{r}_{ui}$ é a avaliação predita.

Técnicas de Otimização

Para resolver este problema de otimização, frequentemente empregam-se algoritmos como o gradiente descendente, que ajusta iterativamente os parâmetros do modelo para minimizar a função de custo. No contexto de fatoração de matrizes, por exemplo, $\hat{R}$ pode ser aproximada como o produto de duas matrizes de fatores latentes U (usuários) e V (itens):

$$\hat{R} = UV^T$$

O gradiente descendente atualiza as matrizes U e V pela subtração de um gradiente da função de custo multiplicado por uma taxa de aprendizado α , ajustando assim os fatores latentes para aproximar melhor as avaliações conhecidas.

Esta abordagem não só proporciona uma base sólida para recomendações personalizadas, mas também se alinha com teorias econômicas que modelam o comportamento do consumidor como um processo de maximização de utilidade. Ao

entender e implementar essa estrutura de otimização, sistemas de recomendação podem prever preferências de forma mais precisa e fornecer insights sobre o comportamento de consumo dos usuários.

Escolhas ótimas em matrizes transformadas: PCA

Ao aplicar a Análise de Componentes Principais (PCA) para transformar a matriz de usuários e itens na filtragem colaborativa, alteramos significativamente a estrutura e o tratamento do problema de otimização original. O PCA é utilizado para reduzir a dimensionalidade dos dados, focando nas direções que maximizam a variância, o que ajuda a destacar as características mais importantes e reduzir o ruído nos dados.

Transformação da Matriz por PCA

Seja R a matriz original de dimensões $m \times n$ (usuários por itens). Ao aplicar PCA, transformamos R em uma nova matriz R' de dimensões reduzidas $m \times k$, em que k é o número de **componentes principais** escolhidos. A matriz R' é obtida por:

$$R' = RV_k$$

sendo que V_k contém os k primeiros vetores próprios (componentes principais) da matriz de covariância de R , que são as direções que capturam a maior variância dos dados.

Formulação do Problema de Otimização com PCA

O objetivo continua sendo minimizar o erro entre as avaliações conhecidas e avaliações preditas, mas agora sobre a matriz transformada R' . A função objetivo modificada pode ser descrita como:

$$\min_{\hat{R}'} \sum_{(u,i) \in \Omega} (r'_{ui} - \hat{r}'_{ui})^2$$

em que:

- $\hat{R}'$ é a matriz de avaliações preditas na dimensão reduzida.
- r'_{ui} é a avaliação transformada pelo PCA.
- $\hat{r}'_{ui}$ é a avaliação predita na dimensão transformada.

- Ω é o conjunto de todos os pares de usuário-item para os quais as avaliações são conhecidas na matriz transformada.

Solução do Problema de Otimização

Utilizando técnicas como o gradiente descendente, podemos atualizar os parâmetros do modelo na dimensão reduzida:

$$\hat{R}' = U'V'^T$$

sendo que U' e V' são matrizes de fatores latentes ajustadas na nova dimensão. A atualização ocorre de maneira similar ao problema original, ajustando-se para minimizar o erro na matriz transformada.

Interpretação dos Novos Resultados e Importância da Validação

Os novos resultados obtidos através do PCA e da subsequente otimização devem ser interpretados como uma visão mais limpa e essencial das preferências de usuários e características dos itens. Esta transformação ajuda a remover redundâncias e ruído dos dados, o que pode melhorar a precisão das previsões e a eficiência computacional.

A validação desses resultados é crucial para garantir que a redução de dimensionalidade não descarte informações críticas para as recomendações. Isso geralmente envolve comparar o desempenho do sistema de recomendação antes e depois da transformação, utilizando métricas como precisão, recall ou F1-score, para garantir que a integridade e a utilidade das recomendações sejam mantidas ou até melhoradas.

Este processo não apenas simplifica o problema de recomendação, mas também alinha a filtragem colaborativa com práticas robustas de limpeza de dados, fundamentais para manter a qualidade e confiabilidade dos sistemas de recomendação modernos.

Escolhas ótimas em matrizes transformadas: NMF

Ao aplicar a Fatoração de Matrizes Não Negativas (NMF) ao problema de otimização em filtragem colaborativa, transformamos o processo pelo qual a matriz R é aproximada. Ao contrário da decomposição típica que pode incluir valores negativos

nos fatores latentes, a NMF restringe todos os elementos das matrizes fatoradas U (usuários) e V (itens) a serem não negativos. Essa abordagem é particularmente útil quando lidamos com dados como classificações ou outras quantidades que são intrinsecamente não negativas.

Formulação do Problema com NMF

Ao integrar a NMF, a matriz de utilidades R é aproximada pelo produto de duas matrizes U e V^T , ambas com restrições de não negatividade:

$$\min_{\{U,V\}} \|R - UV^T\|^2 \text{ sujeito a } U \geq 0, V \geq 0$$

Aqui, U e V são matrizes de fatores latentes com dimensões $m \times k$ e $n \times k$ respectivamente, em que k é o número de fatores latentes, m o número de usuários e n o número de itens. O objetivo é minimizar a norma quadrada do erro entre a matriz original R e sua aproximação UV^T , mantendo todas as entradas das matrizes fatoradas como não negativas.

Solução do Problema de Otimização

Para resolver este problema de otimização, pode-se aplicar técnicas como o método de multiplicação de atualizações alternadas, que iterativamente atualiza U e V para minimizar a função de custo. Em cada etapa, mantêm-se fixos U ou V e atualiza-se o outro da seguinte forma:

$$U \leftarrow U \otimes \frac{R V}{U V^T V}$$

$$V \leftarrow V \otimes \frac{R^T U}{V U^T U}$$

sendo que $\otimes$ e $\div$ denotam a multiplicação e divisão elemento a elemento, respectivamente. Essas atualizações são realizadas até que o processo convirja ou até que um número máximo de iterações seja alcançado.

Interpretação dos Resultados e Importância da Validação

Após aplicar NMF, os fatores U e V representam características latentes dos usuários e itens, respectivamente. A interpretação destes resultados oferece insights significativos sobre as preferências dos usuários e características dos itens que não são diretamente observáveis nos dados originais. Por exemplo, cada coluna de U pode ser interpretada como indicativa de um grupo ou categoria de preferência dos

usuários, enquanto cada coluna de V pode representar uma característica agregada dos itens.

Além disso, a validação dos modelos gerados por NMF é crucial para garantir que as recomendações feitas com base nestes modelos sejam confiáveis e úteis. A validação também atua como um processo de limpeza de dados ao identificar e corrigir inconsistências ou tendências anormais nos dados de entrada, garantindo que as previsões sejam baseadas em informações precisas e representativas.

A abordagem da NMF não só melhora a precisão das recomendações ao revelar estruturas sub-representadas nos dados, mas também alinha com teorias econômicas que veem as decisões de consumo como um processo de maximização de utilidade. Assim, os sistemas de recomendação podem se beneficiar significativamente desta metodologia ao fornecer uma experiência mais personalizada e satisfatória para os usuários.

Agrupando preferências e identificando melhores grupos

Ao explorar a aplicação de técnicas de agrupamento para categorizar preferências de usuários e produtos em sistemas de recomendação, é fundamental compreender como as técnicas de fatoração de matrizes como NMF (Fatoração de Matrizes Não-Negativas) e PCA (Análise de Componentes Principais) podem ser utilizadas para revelar fatores latentes que representam características implícitas tanto de usuários quanto de itens.

Estas técnicas transformam os dados originais em espaços latentes nos quais as dimensões representam características abstratas que não são diretamente observadas, mas que influenciam as interações e preferências dos usuários.

A partir dessa transformação, métodos de agrupamento podem ser aplicados para identificar grupos de usuários ou itens com características similares. O agrupamento ajuda a simplificar o modelo ao reduzir a dimensionalidade e ao focar nas relações mais significativas, facilitando assim a identificação de padrões e tendências que podem não ser evidentes em uma análise de alta dimensionalidade.

Por exemplo, ao aplicar a NMF, grupos de usuários que consistentemente classificam certos tipos de produtos de maneira similar podem ser identificados. Essa abordagem não só melhora a precisão das recomendações ao minimizar o ruído e a redundância dos dados, mas também proporciona insights operacionais que são

críticos para a segmentação de mercado e para a personalização de estratégias de marketing.

Do ponto de vista empresarial, entender esses agrupamentos é vital, pois permite às empresas desenvolver estratégias mais direcionadas e eficientes. Identificar grupos de usuários com preferências similares ou produtos com características semelhantes pode facilitar a recomendação de novos produtos que provavelmente serão de interesse, maximizando assim as oportunidades de venda cruzada e de retenção de clientes.

Por exemplo, se um grupo é identificado como consumidores frequentes de produtos tecnológicos de alta performance, estratégias de marketing e promoções podem ser especificamente ajustadas para esse segmento, aumentando a eficácia das campanhas.

Portanto, o uso de técnicas de agrupamento em sistemas de recomendação não apenas otimiza o processo de filtragem e recomendação, mas também alinha as operações de negócio com os padrões de consumo, proporcionando uma base robusta para decisões estratégicas e para a otimização de recursos.

Esta abordagem de agrupamento fundamentada em características derivadas por meio de técnicas avançadas de fatoração de matrizes apresenta uma oportunidade para as empresas não só entenderem melhor seus clientes e produtos, mas também para agirem proativamente na oferta de soluções personalizadas que atendam às expectativas e necessidades específicas de cada segmento de cliente.

O agrupamento entre itens e usuários em sistemas de recomendação é uma estratégia que se baseia em identificar e explorar padrões de comportamento e preferência que facilitam uma segmentação de mercado mais eficaz e direcionada. Por exemplo, considerando uma plataforma de streaming de música, algoritmos de agrupamento podem ser utilizados para identificar grupos de usuários que preferem gêneros musicais similares ou que tendem a ouvir músicas em momentos específicos do dia.

Essas informações permitem que a plataforma personalize não só as recomendações musicais como as campanhas de marketing, como a promoção de shows ou novos lançamentos, direcionadas especificamente para grupos que demonstram interesse prévio em artistas ou gêneros semelhantes. A segmentação

efetiva reduz o custo de aquisição de clientes e aumenta a eficiência das campanhas, convertendo mais usuários em clientes pagantes ou aumentando sua fidelidade. Algoritmos como o Gaussian Mixture Model (GMM) e o Spectral Clustering são particularmente úteis para estas tarefas devido às suas características distintas.

O GMM é eficaz para dados que podem ser naturalmente modelados como uma mistura de várias distribuições gaussianas, permitindo que cada cluster capture a variação nos dados de maneira que cada componente da mistura corresponda a um subgrupo com padrões estatísticos comuns. Isso é especialmente vantajoso em ambientes de recomendação nos quais os padrões de preferência podem variar significativamente e não são uniformemente distribuídos.

Por outro lado, o Spectral Clustering é baseado na ideia de que a conexão entre pontos de dados pode ser melhor representada usando os autovalores e autovetores de uma matriz de similaridade, o que facilita a identificação de clusters que não são necessariamente compactos ou separados por distâncias euclidianas. Este método é particularmente apropriado para situações em que as relações entre itens ou usuários são mais importantes que suas distâncias absolutas, como na formação de comunidades ou grupos de interesse dentro de redes sociais.

A implementação desses algoritmos em sistemas de recomendação não só melhora a precisão das sugestões fornecidas aos usuários como fornece uma base sólida para a tomada de decisões estratégicas em marketing e gestão de produto.

Máquinas de Mistura Gaussiana

Os algoritmos de Mistura Gaussiana, conhecidos como Gaussian Mixture Machines (GMM), são técnicas estatísticas que permitem modelar um conjunto de dados como uma combinação de múltiplas distribuições gaussianas. Cada uma dessas distribuições representa um componente ou cluster dentro do conjunto de dados, com cada ponto de dado tendo uma probabilidade de pertencer a cada um dos componentes gaussianos.

Construção e Base dos Algoritmos de Mistura Gaussiana

Formalmente, um GMM é construído assumindo que os dados são gerados a partir de uma mistura finita de distribuições gaussianas. Cada componente da mistura é definido por sua média μ , covariância Σ e um coeficiente que representa o peso

daquela distribuição na mistura π . A função de densidade de probabilidade de uma mistura gaussiana é então dada por:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x|\mu_k, \Sigma_k)$$

sendo que K é o número de componentes gaussianos, π_k é o peso do k -ésimo componente e $\mathcal{N}(x|\mu_k, \Sigma_k)$ é a densidade de probabilidade gaussiana para o k -ésimo componente.

Estimação dos Parâmetros

Os parâmetros do GMM (μ), (Σ) e (π) são geralmente estimados usando o algoritmo Expectation-Maximization (EM), que itera entre duas etapas:

1. **Expectation (E-step):** calcula-se a probabilidade de cada ponto de dado pertencer a cada um dos componentes gaussianos, dado os parâmetros atuais.
2. **Maximization (M-step):** atualizam-se os parâmetros (μ), (Σ), e (π) para maximizar a verossimilhança dos dados dada a probabilidade estimada de pertencimento aos componentes na E-step.

Implementação em Filtragem Colaborativa e de Conteúdo

Na filtragem colaborativa e de conteúdo, os GMMs podem ser aplicados para segmentar tanto usuários quanto itens em grupos que compartilham características ou preferências similares. Por exemplo, em um sistema de recomendação de filmes, um GMM pode ser utilizado para identificar clusters de usuários com gostos cinematográficos semelhantes ou agrupar filmes que tendem a ser preferidos pelos mesmos segmentos de usuários.

Implementação Prática:

1. **Preparação dos Dados:** os dados de avaliação dos usuários são preparados, sendo que cada linha representa um usuário e cada coluna um filme, com as células contendo as classificações dadas pelos usuários aos filmes.

2. **Aplicação do GMM:** um GMM é ajustado aos dados, com cada componente gaussiano tentando capturar um grupo de usuários com preferências similares.
3. **Utilização para Recomendações:** uma vez identificados os grupos, o sistema pode recomendar filmes que são altamente classificados dentro de um cluster para outros usuários do mesmo cluster que ainda não os viram.

A implementação de GMMs em sistemas de recomendação ajuda a entender as estruturas latentes nas preferências dos usuários e nas características dos itens, facilitando a personalização e melhorando a precisão das recomendações.

Agrupamento Espectral

Os algoritmos de Agrupamento Espectral são técnicas avançadas de agrupamento que utilizam propriedades dos gráficos e a teoria dos espectros de matrizes para identificar comunidades e clusters em dados complexos. Essa abordagem é particularmente útil em contextos nos quais as relações entre os dados são mais informativas que os atributos dos dados em si.

Construção e Base dos Algoritmos de Agrupamento Espectral

Os algoritmos de Agrupamento Espectral baseiam-se em conceitos fundamentais de teoria espectral de grafos e álgebra linear para identificar clusters em dados complexos. A abordagem começa pela representação dos dados em forma de grafo, em que os pontos de dados são tratados como nós, e as relações entre eles são arestas, muitas vezes ponderadas por uma medida de similaridade entre os pontos. Aqui está o passo-a-passo da construção e base teórica dos algoritmos de Agrupamento Espectral.

O primeiro passo é construir um grafo G representando os dados. Cada nó no grafo representa um ponto de dado e cada aresta entre os nós reflete a similaridade entre esses pontos. A similaridade pode ser calculada usando várias métricas, como distância euclidiana, similaridade cosseno ou outras medidas específicas do domínio.

Com o grafo em mãos, o próximo passo é formar a matriz de adjacência A do grafo. Se n é o número de nós, A será uma matriz $n \times n$, sendo que o elemento A_{ij} representa o peso da aresta entre os nós i e j . O peso pode indicar a força da similaridade ou a probabilidade de conexão entre os pontos.

A matriz de graus D é uma matriz diagonal $n \times n$ e cada elemento diagonal D_{ii} é igual à soma dos pesos de todas as arestas conectadas ao nó i . Em outras palavras, D_{ii} é o grau do nó i , que reflete a quantidade total de similaridade que esse nó compartilha com outros nós no grafo.

A matriz Laplaciana do grafo é definida como $L = D - A$. Esta matriz desempenha um papel crucial no agrupamento espectral, pois suas propriedades espectrais (autovalores e autovetores) revelam informações importantes sobre a estrutura do grafo. A matriz Laplaciana é simétrica e semi-definida positiva, o que garante que todos os seus autovalores sejam não negativos.

O próximo passo é calcular os autovalores e autovetores da matriz Laplaciana L . Os autovetores correspondentes aos menores autovalores (excluindo o zero) fornecem a informação necessária para agrupar os nós. Esses autovetores são usados para mapear cada ponto de dado para um ponto em um espaço de dimensão reduzida, em que técnicas de agrupamento tradicionais, como k-means, podem ser aplicadas de forma mais eficaz.

Finalmente, os dados transformados no novo espaço definido pelos autovetores são agrupados utilizando um algoritmo de agrupamento padrão. Este espaço é escolhido porque maximiza a separação entre diferentes grupos de dados conforme indicado pela estrutura do grafo original.

Essa metodologia não só captura a essência das relações entre os dados de forma mais natural e eficaz do que métodos baseados em distância direta como também é particularmente útil em dados nos quais as relações não lineares ou complexas prevalecem.

Implementação em Filtragem Colaborativa e de Conteúdo

Na filtragem colaborativa e de conteúdo, o Agrupamento Espectral pode ser empregado para discernir grupos intrincados de usuários ou itens que não são prontamente aparentes através de métodos convencionais de agrupamento. Isso é particularmente útil quando as interações ou as características dos usuários e itens formam padrões complexos de relacionamento que os métodos baseados em distância podem não capturar eficazmente.

É possível utilizar os clusters identificados para melhorar a precisão das recomendações, agrupando usuários com gostos similares ou itens que

frequentemente coocorrem em preferências de usuários. O Agrupamento Espectral oferece uma maneira robusta de extrair insights profundos sobre as estruturas subjacentes dos dados em sistemas de recomendação.

Esta abordagem não só melhora a relevância das recomendações fornecidas, mas também ajuda a identificar nichos de usuários ou grupos de itens que poderiam ser alvo de estratégias de marketing e produtos mais personalizados.

Classificando a relevância de Itens Recomendados

A aplicação de algoritmos de classificação em sistemas de recomendação, particularmente na filtragem colaborativa, serve para distinguir entre itens "recomendáveis" e "não recomendáveis" para cada usuário. Esta abordagem utiliza informações derivadas de comportamentos anteriores dos usuários, bem como características dos itens para prever a relevância de novos itens para um usuário específico.

Por exemplo, após a aplicação de técnicas de agrupamento para identificar grupos de itens ou usuários com características semelhantes, os algoritmos de classificação podem ser usados para prever a probabilidade de um usuário gostar de um item baseado no agrupamento ao qual o item pertence. Se um usuário consistentemente avalia positivamente itens dentro de um determinado cluster, então novos itens que se encaixam nesse cluster podem ser classificados como "recomendáveis" para esse usuário.

Algoritmos de classificação, como árvores de decisão, são particularmente úteis para esta tarefa porque permitem modelar não-linearidades complexas nas relações entre características dos usuários, dos itens e suas interações. Algoritmos como XGBoost, LightGBM e outros métodos ensemble são reconhecidos por sua alta precisão e eficiência, fazendo deles escolhas populares em ambientes de produção.

O XGBoost, por exemplo, é um algoritmo que emprega a construção de árvores de gradiente boosting de maneira sequencial em que cada nova árvore é construída para corrigir os erros da árvore anterior, melhorando continuamente a precisão das previsões.

O LightGBM, similarmente, é um algoritmo de boosting que utiliza árvores baseadas em gradientes, mas é otimizado para ser mais rápido e eficiente em termos de memória do que muitos de seus concorrentes. Ele alcança isso usando técnicas

de agrupamento de dados e construindo árvores de maneira mais eficiente, o que o torna particularmente adequado para dados com muitos recursos e muitas instâncias.

Esses algoritmos são capazes de lidar com grandes volumes de dados e complexidade, tornando-os ideais para sistemas de recomendação, em que o número de usuários e itens pode ser extremamente grande.

O uso desses algoritmos de árvore em sistemas de recomendação permite a classificação eficaz dos itens como "recomendáveis" ou "não recomendáveis" e fornece insights valiosos sobre os fatores que influenciam as preferências dos usuários. Isso pode ajudar as empresas a afinarem suas estratégias de marketing e de gestão de inventário, assegurando que usuários sejam expostos aos itens que eles são mais propensos a valorizar, aumentando assim as taxas de satisfação do cliente e conversão de vendas.

O processo de classificação

O processo de classificação da relevância de itens em sistemas de recomendação começa com a segmentação eficaz dos usuários com base em seus perfis de consumo e preferências. A primeira etapa é a aplicação de técnicas de agrupamento, como a análise de cluster, para dividir usuários em grupos com características similares.

Esta segmentação pode ser fundamentada em uma variedade de atributos, incluindo comportamento de compra, preferências de gênero ou atividade em plataformas digitais. Uma vez estabelecidos esses agrupamentos, os itens podem então ser avaliados quanto à sua popularidade e relevância dentro de cada grupo, o que é crítico para entender as dinâmicas de consumo específicas de cada segmento.

Definir uma "boa taxa de aceitação" para classificar itens como "recomendáveis" ou "não recomendáveis" em sistemas de recomendação requer uma abordagem metódica e baseada em dados. Essa taxa deve refletir tanto a frequência quanto a qualidade das interações entre os usuários e os itens dentro de cada agrupamento. A seguir, apresentamos uma discriminação formal de como essa taxa pode ser definida:

1. Definição de Parâmetros Iniciais

Inicialmente, é necessário estabelecer quais métricas serão utilizadas para medir a aceitação. Geralmente, incluem-se a frequência de interações (quantas vezes um item foi escolhido) e a positividade das avaliações (qual a média das avaliações recebidas). Ambas as métricas devem ser ponderadas de acordo com a relevância para o negócio.

2. Cálculo da Taxa de Aceitação

Seja τ_A a taxa de aceitação de um item, p o número de interações positivas com o item, T o número total de interações, μ a média das avaliações do item e M a avaliação máxima possível. Tem-se:

$$\tau_a = \left(\frac{p}{T}\right) \times \left(\frac{\mu}{M}\right)$$

Essa fórmula combina a proporção de interações positivas (compras, cliques etc.) com a qualidade dessas interações (avaliadas por meio de ratings ou feedback direto).

3. Estabelecimento de Thresholds

O próximo passo é definir um limiar (threshold) que determine o que é considerado uma "boa" taxa de aceitação. Esse threshold deve ser baseado em benchmarks históricos do grupo específico ou comparado com a média de aceitação para itens semelhantes. Por exemplo, um item pode ser considerado recomendável se a sua taxa de aceitação for pelo menos 20% superior à média do grupo, ou se atingir um recall de 70% dentro de um grupo, indicando que 70% das interações positivas esperadas foram realizadas.

4. Ajuste Dinâmico Baseado em Feedback

A taxa de aceitação deve ser continuamente recalculada e ajustada com base no feedback recebido. Isso significa que o modelo deve ser sensível às mudanças nas preferências do usuário e às tendências do mercado. Sistemas de feedback em loop fechado podem ser utilizados para ajustar os thresholds de aceitação conforme os dados mais recentes são analisados.

5. Validação e Monitoramento

Por fim, a definição de uma boa taxa de aceitação deve ser validada periodicamente através de testes A/B ou análises de regressão para garantir que os

critérios estabelecidos continuam alinhados com os objetivos do negócio e as expectativas dos usuários. Monitorar a eficácia das recomendações em termos de conversão, satisfação do usuário e retenção é crucial para avaliar a precisão do modelo.

Adotar esta abordagem formal e analítica não apenas assegura que os itens recomendados sejam verdadeiramente alinhados com as preferências dos usuários, mas também permite uma adaptação proativa às mudanças no comportamento do consumidor e no ambiente competitivo.

No que tange às métricas de classificação de relevância, é fundamental a adoção de medidas que possam quantificar de maneira eficiente a pertinência de um item para um grupo de usuários. Métricas como precisão, recall e a medida F1 são comumente utilizadas para avaliar a eficácia das recomendações. Estas métricas podem ser ajustadas para servir como thresholds que definem o nível de aceitação de um item como recomendável.

Finalmente, a consistência do consumo de itens por usuários de agrupamentos similares pode ser monitorada através da atribuição de variáveis que capturam a frequência e o padrão de compra ou interação. Tais variáveis são essenciais para ajustar continuamente os modelos de recomendação, garantindo que eles permaneçam dinâmicos e contextualmente relevantes. Utilizando essas variáveis em conjunto com as métricas estabelecidas, os sistemas de recomendação podem não apenas personalizar suas sugestões mais eficazmente, mas também aprimorar continuamente sua precisão ao adaptar-se às mudanças nas tendências de consumo e preferências dos usuários.

O QUE VOCÊ VIU NESTA AULA?

O processo de elaboração de algoritmos de recomendação é um desafio multifacetado que engloba uma gama ampla de técnicas e estratégias. No âmbito dos sistemas de recomendação, a complexidade se eleva à medida que se buscam soluções cada vez mais personalizadas e precisas. Inicialmente, o design de tais sistemas pode incluir o uso de algoritmos de regressão para prever as preferências dos usuários com base em dados históricos, um passo crucial para entender as tendências e as preferências ocultas dentro dos dados coletados.

Além disso, métodos de enriquecimento de dados, como o processamento de linguagem natural (PLN), podem ser aplicados para extrair mais significado e contexto dos dados, especialmente útil em recomendações baseadas em conteúdo, nas quais a análise de sentimentos e a extração de tópicos podem fornecer insights adicionais sobre as preferências dos usuários.

À medida que avançamos, é vital reconhecer a importância de etapas iterativas e validações contínuas dentro do processo de desenvolvimento de sistemas de recomendação. A aplicação de técnicas avançadas como machine learning ensemble, em que múltiplos modelos são combinados para melhorar a precisão das previsões, é um exemplo de como a complexidade pode ser gerida para alcançar resultados superiores.

Por exemplo, algoritmos como XGBoost e VotingEnsemble são frequentemente utilizados para aprimorar a precisão das classificações, aproveitando suas capacidades robustas de modelagem para captar nuances nos dados que modelos mais simples poderiam não detectar. Este processo de refinamento contínuo é essencial para adaptar os sistemas de recomendação às mudanças dinâmicas no comportamento dos usuários e nas tendências do mercado.

Para quem se interessar em aprofundar seus conhecimentos e explorar mais sobre o universo dos sistemas de recomendação, uma série de leituras recomendadas pode ser extremamente útil. Assim, as referências compartilhadas ao longo desta aula fornecem uma base sólida para entender os fundamentos teóricos e as aplicações práticas dos algoritmos de recomendação.

REFERÊNCIAS

AO, S.; RIEGER, B. B.; AMOUZEGAR, M. (ed.). **Machine learning and systems engineering**. [s.l.]: Springer Science & Business Media, 2010.

CHARU, C. A. **Recommender systems: The textbook**. [s.l.]: Springer, 2016.

FALK, K. **Practical recommender systems**. [s.l.]: Simon and Schuster, 2019.


MURPHY, K. P. **Machine learning: a probabilistic perspective**. [s.l.]: MIT press, 2012.

EMAP

PALAVRAS-CHAVE

Palavras-chave: Sistemas de Recomendação. Classificação e Aglomeração. Aprendizagem de Máquina.

EMAP



POSTECH