

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	14
REFERÊNCIAS.....	16

EMSE

O QUE VEM POR AÍ?

Agora, você será levado(a) a explorar os fundamentos essenciais do armazenamento de dados, um dos pilares mais importantes para o sucesso das Feature Stores em ambientes de Machine Learning. Prepare-se para mergulhar em conceitos cruciais como latência, throughput e durabilidade, que são determinantes na construção de sistemas de armazenamento eficientes e escaláveis.

À medida que avançamos, você descobrirá como estruturar e implementar Data Lakes, ferramentas poderosas que permitem o armazenamento e a transformação de grandes volumes de dados, suportando a ingestão e o processamento de maneira otimizada. Vamos também discutir as práticas de segurança e governança de dados, essenciais para proteger a integridade e garantir a conformidade dos dados que alimentam seus modelos de Machine Learning.

HANDS ON

Nesta seção, você terá a oportunidade de aplicar na prática os conceitos essenciais sobre o gerenciamento de dados que foram discutidos nas aulas teóricas. Os vídeos a seguir foram preparados para guiá-lo(a) por todo o processo de design e implementação de sistemas de armazenamento eficientes, com foco na criação e estruturação de Data Lakes, fundamentais para o suporte de Feature Stores em ambientes de Machine Learning.

Durante o hands on, você vai interagir diretamente com ferramentas de modelagem e design de arquitetura de dados, aplicando os conceitos de latência, throughput e durabilidade para criar sistemas que não apenas armazenam, mas também gerenciam dados de forma eficaz e escalável. Explorando casos reais, você aprenderá a implementar um Data Lake, estruturando-o para suportar grandes volumes de dados e assegurando que as operações de ingestão e transformação sejam realizadas de maneira otimizada.

Além disso, você terá a oportunidade de aplicar as práticas de segurança e governança de dados discutidas nas aulas, implementando políticas que garantam a integridade e a conformidade dos dados. As videoaulas também focarão na integração dessas práticas com sistemas de Feature Stores, demonstrando como as decisões tomadas durante o design de armazenamento influenciam diretamente a eficiência dos modelos de Machine Learning.

Ao longo do hands on, você será desafiado(a) a resolver problemas típicos que surgem na implementação de sistemas de armazenamento em ambientes de Machine Learning. Isso inclui otimizar o uso de recursos e garantir que seu Data Lake seja capaz de lidar com a ingestão contínua de dados, mantendo a performance e a escalabilidade necessárias para apoiar Feature Stores em produção.

SAIBA MAIS

O armazenamento de dados, ou “Data Storage”, é um dos pilares fundamentais na arquitetura de sistemas que lidam com grandes volumes de informação, especialmente em projetos de Machine Learning. Esse conceito abrange as estratégias e tecnologias utilizadas para guardar, organizar e disponibilizar dados de forma eficiente e segura.

O gerenciamento eficaz de dados é crucial para assegurar que as informações estejam acessíveis quando necessário, que sejam armazenadas de maneira que suportem tanto o crescimento dos volumes quanto a necessidade de rápida recuperação e que estejam protegidas contra perda ou acesso não autorizado. Em essência, o Data Storage é o que sustenta a infraestrutura de dados de qualquer organização, permitindo que ela transforme dados brutos em insights valiosos.

Existem diferentes tipos de storage, cada um com suas particularidades e aplicações. Os sistemas de armazenamento podem ser amplamente categorizados em armazenamento local, em rede (NAS, SAN) e em nuvem. O armazenamento local refere-se ao uso de dispositivos como discos rígidos e SSDs diretamente conectados a servidores ou máquinas individuais. Esse tipo de storage é muitas vezes usado em ambientes menores ou em situações nas quais a latência extremamente baixa é crucial. No entanto, o armazenamento local apresenta limitações de escalabilidade e gerenciamento centralizado, especialmente quando comparado a soluções mais modernas e distribuídas.

O armazenamento em rede, que inclui Network Attached Storage (NAS) e Storage Area Network (SAN), oferece uma solução mais escalável e centralizada. O NAS fornece armazenamento em nível de arquivo, ideal para compartilhar arquivos entre vários usuários e sistemas, enquanto o SAN oferece armazenamento em nível de bloco, adequado para aplicações que requerem alta performance e baixa latência, como bases de dados transacionais. Estas soluções permitem que grandes volumes de dados sejam armazenados de forma mais eficiente, mas ainda apresentam desafios em termos de escalabilidade horizontal, especialmente quando as demandas de dados crescem exponencialmente.

Com o advento da computação em nuvem, o armazenamento em nuvem tornou-se uma opção cada vez mais popular. Ele oferece escalabilidade praticamente ilimitada, disponibilidade global e modelos de pagamento conforme o uso, o que torna essa opção altamente atraente para empresas que precisam armazenar grandes quantidades de dados sem o investimento pesado em infraestrutura física.

Serviços como Amazon S3, Google Cloud Storage e Azure Blob Storage permitem que organizações armazenem e acessem seus dados de maneira flexível e eficiente, com a capacidade de integrar rapidamente novas tecnologias e serviços de análise de dados. Essa flexibilidade é essencial para suportar as demandas dinâmicas de projetos de Machine Learning, em que o volume de dados pode variar drasticamente ao longo do tempo.

As Feature Stores se encaixam nesse ecossistema como uma solução especializada dentro do armazenamento de dados. Enquanto os sistemas tradicionais de armazenamento lidam com dados de maneira mais geral, uma Feature Store é projetada especificamente para o gerenciamento de features, ou seja, os atributos que alimentam modelos de Machine Learning.

Em vez de simplesmente armazenar dados brutos, uma Feature Store organiza e disponibiliza features pré-processadas e prontas para uso, garantindo que sejam consistentes e facilmente acessíveis por qualquer modelo dentro da organização. Isso reduz significativamente o tempo e o esforço necessários para preparar dados para treinamento e inferência de modelos, tornando o ciclo de desenvolvimento de Machine Learning mais ágil e eficiente.

O armazenamento eficiente dentro de uma Feature Store requer consideração cuidadosa dos princípios de latência, throughput e durabilidade. Latência refere-se ao tempo necessário para acessar dados armazenados; em uma Feature Store, isso deve ser minimizado para garantir que as features possam ser servidas rapidamente aos modelos de Machine Learning, especialmente em aplicações em tempo real.

Throughput refere-se à quantidade de dados que pode ser processada em um dado período; uma Feature Store bem projetada deve ser capaz de suportar altas taxas de ingestão e processamento de dados para acomodar grandes volumes de informações que entram no sistema. Durabilidade, por sua vez, garante que os dados armazenados não sejam perdidos ou corrompidos ao longo do tempo, um aspecto

crucial para manter a integridade das features utilizadas em modelos que podem ser executados por longos períodos.

Esses conceitos se tornam ainda mais relevantes quando aplicados ao design e à implementação de Data Lakes, que são frequentemente usados como backend para Feature Stores. Um Data Lake é uma arquitetura que permite armazenar grandes quantidades de dados em seus formatos nativos, sejam estruturados, semi-estruturados ou não estruturados.

Ao contrário de um Data Warehouse, em que os dados precisam ser transformados e organizados antes de serem carregados, um Data Lake aceita todos os dados como estão, oferecendo uma flexibilidade muito maior em termos de ingestão e análise. Isso o torna ideal para armazenar as vastas quantidades de dados necessários para treinar modelos de Machine Learning, enquanto uma Feature Store construída sobre um Data Lake pode aproveitar essa flexibilidade para extrair, transformar e servir features conforme necessário.

No entanto, com essa flexibilidade vêm desafios, particularmente em termos de governança e segurança. Em um Data Lake, os dados podem ser armazenados de forma bruta e não estruturada, o que pode complicar a garantia de que os dados certos estejam sendo utilizados para o propósito certo. Governança de dados envolve a implementação de políticas e processos que garantem que os dados sejam armazenados, acessados e usados de maneira controlada e conforme as regulamentações aplicáveis.

A segurança de dados, por outro lado, se concentra na proteção dos dados contra acessos não autorizados e outras ameaças. Isso inclui a criptografia dos dados em repouso e em trânsito, o controle de acesso baseado em função (RBAC) e a implementação de mecanismos de auditoria e rastreamento para garantir que todas as atividades relacionadas aos dados sejam registradas e monitoradas.

A implementação eficaz de uma Feature Store dentro de uma arquitetura de Data Lake não apenas suporta a escalabilidade e a flexibilidade necessárias para grandes projetos de Machine Learning, mas também garante que os dados sejam usados de maneira segura e eficiente. Por exemplo: ao projetar um sistema de armazenamento de dados, é importante considerar como os dados serão particionados e indexados para otimizar o acesso às features.

Em uma Feature Store, isso pode significar organizar os dados por timestamp ou por chave de entidade, o que permite consultas rápidas e eficientes, mesmo em grandes volumes de dados. Além disso, a escolha de tecnologias subjacentes, como o uso de sistemas de arquivos distribuídos como HDFS ou S3, pode impactar diretamente a performance e a escalabilidade da Feature Store.

Ao refletir sobre como tudo isso se integra, podemos concluir que a Feature Store se torna uma camada intermediária crítica que conecta a flexibilidade de um Data Lake com a necessidade de consistência e rapidez exigida pelos modelos de Machine Learning. Ela deve ser projetada para suportar não apenas as demandas atuais, mas também para ser adaptável ao crescimento e às mudanças, sempre mantendo a integridade e a qualidade dos dados como prioridade.

Estrutura e Arquitetura de Data Lakes

As estruturas e arquiteturas de Data Lake são fundamentais para o gerenciamento eficiente de grandes volumes de dados em ambientes de Machine Learning, oferecendo a flexibilidade e a escalabilidade necessárias para armazenar e processar informações em seus formatos brutos. Um Data Lake permite que dados estruturados, semiestruturados e não estruturados coexistam em um único repositório, mantendo sua integridade original até que sejam necessários para análises ou outras operações.

A flexibilidade do Data Lake reside em sua capacidade de ingerir dados de diversas fontes sem a necessidade de transformação prévia, o que o diferencia de outras soluções de armazenamento como Data Warehouses. No entanto, para que um Data Lake funcione de maneira eficaz, ele deve ser projetado com uma arquitetura que suporte ingestão, processamento e organização dos dados de forma sistemática e escalável.

A arquitetura de ingestão de dados é um componente crítico em qualquer Data Lake. Ela define como os dados entram no sistema, como são processados (se em tempo real ou em batch) e como são organizados para facilitar o acesso e o uso subsequente. Duas arquiteturas populares para a ingestão de dados são as arquiteturas Lambda e Kappa.

A arquitetura Lambda é conhecida por sua abordagem dual, em que os dados são processados em dois caminhos paralelos: um para processamento em tempo real

e outro para processamento em batch. Essa abordagem permite que as empresas tenham insights rápidos a partir de dados em tempo real enquanto ainda mantêm a capacidade de realizar análises mais profundas e detalhadas em dados históricos. Por outro lado, a arquitetura Kappa simplifica o modelo, processando todos os dados em tempo real e eliminando a necessidade de pipelines de batch separados. Essa simplificação é particularmente útil em casos nos quais a latência deve ser minimizada e a velocidade de processamento é crítica.

As Feature Stores se integram a essas arquiteturas de ingestão como uma camada adicional que organiza e otimiza as features necessárias para os modelos de Machine Learning. Em uma arquitetura Lambda, a Feature Store pode ser atualizada em tempo real com novas features provenientes do pipeline de streaming, enquanto as features derivadas de dados batch são armazenadas e mantidas para uso futuro.

Essa dualidade permite que os modelos de Machine Learning utilizem tanto dados frescos quanto históricos, assegurando que as previsões sejam baseadas nas informações mais atualizadas possíveis. Já em uma arquitetura Kappa, a Feature Store é constantemente atualizada em tempo real, garantindo que os modelos sempre acessem as features mais recentes. Essa integração é crucial para aplicações que exigem respostas rápidas, como sistemas de recomendação ou detecção de fraudes.

Outra dimensão importante na construção de Data Lakes é a orquestração de dados, que envolve a organização e a governança do fluxo de dados dentro do Data Lake, desde a ingestão até o consumo final. Modelos de orquestração como a arquitetura de medalhão e a arquitetura de Data Mesh têm se destacado nesse contexto.

A arquitetura de medalhão organiza os dados em três camadas: bronze, prata e ouro. A camada bronze contém dados brutos, a camada prata contém dados limpos e processados e a camada ouro contém dados prontos para consumo em análises e Machine Learning. Essa abordagem oferece uma trilha clara de transformação dos dados e facilita a governança, assegurando que os dados evoluam de um estado bruto para um estado altamente refinado e útil. A Feature Store em uma arquitetura de medalhão se posiciona na camada ouro, em que as features já passaram por todas as etapas necessárias de limpeza e transformação e estão prontas para serem utilizadas diretamente pelos modelos de Machine Learning.

A arquitetura de Data Mesh, por outro lado, promove uma abordagem descentralizada, em que diferentes domínios ou equipes de uma organização são responsáveis pelo gerenciamento e compartilhamento de seus próprios dados. Cada domínio trata seus dados como um produto, incluindo o design, a implementação e a governança. Essa abordagem permite que as organizações escalem suas operações de dados de forma mais ágil, sem depender de uma equipe centralizada para gerenciar o Data Lake.

Dentro de um Data Mesh, as Feature Stores podem ser distribuídas e gerenciadas por cada domínio, permitindo que as equipes criem e mantenham suas próprias features de forma independente, enquanto ainda compartilham e reutilizam features comuns através de interfaces padronizadas. Essa descentralização é poderosa para grandes organizações que operam em diferentes mercados ou que têm múltiplas linhas de negócios, pois permite que cada equipe ou unidade de negócio otimize suas operações de Machine Learning de acordo com suas necessidades específicas, sem perder a capacidade de colaboração e reutilização de dados.

Em todas essas arquiteturas, um padrão comum que emerge nas Feature Stores é a necessidade de garantir a consistência e a acessibilidade das features, independentemente de como os dados são ingeridos, processados ou orquestrados. Seja em uma arquitetura Lambda, Kappa, Medalhão ou Data Mesh, as Feature Stores desempenham um papel crítico ao garantir que os modelos de Machine Learning acessem dados de alta qualidade e consistentes, de forma eficiente e escalável.

A arquitetura escolhida para a implementação de uma Feature Store deve considerar as necessidades específicas do negócio, o volume de dados, os requisitos de latência e a complexidade operacional para garantir que as soluções de Machine Learning possam ser desenvolvidas e mantidas de forma robusta e eficaz. Assim, ao entender as nuances de cada arquitetura e como as Feature Stores se integram a esses sistemas, as organizações podem otimizar suas operações de dados e maximizar o valor derivado de seus modelos de Machine Learning.

Segurança e Governança de Dados

A governança de dados em Feature Stores é um componente essencial para garantir a segurança, a integridade e a eficácia dos dados que alimentam os modelos de Machine Learning. Uma Feature Store armazena e gerencia features que podem

ser derivadas de informações extremamente sensíveis e estratégicas para o negócio, como dados de comportamento de clientes, transações financeiras ou insights derivados de fontes internas e externas.

O acesso não autorizado a essas features pode resultar em graves problemas, como exposição de dados confidenciais, perda de vantagem competitiva e até mesmo violações de regulamentações de proteção de dados, como o GDPR ou a LGPD. Portanto, a implementação de políticas robustas de governança de dados é crucial para mitigar esses riscos e assegurar que as Feature Stores operem dentro dos padrões éticos e legais exigidos.

Um dos aspectos críticos da governança de dados em Feature Stores é o controle de acesso. Dada a natureza sensível das informações armazenadas, é imperativo que o acesso às features seja rigorosamente gerenciado e monitorado. Isso envolve a implementação de autenticação forte e autorização baseada em função (RBAC), em que diferentes níveis de permissão são concedidos com base na necessidade de cada usuário ou sistema.

Apenas indivíduos ou sistemas devidamente autorizados devem ter acesso a certas features e esse acesso deve ser registrado e auditado continuamente para garantir a conformidade e a segurança. Além disso, é fundamental implementar criptografia dos dados, tanto em repouso quanto em trânsito, para proteger as informações contra acessos indevidos e interceptações.

Outro ponto crítico é a disponibilização de dados. As Feature Stores precisam garantir que os dados estejam disponíveis de maneira eficiente para os modelos de Machine Learning, mas sem comprometer a segurança ou a integridade das informações. Isso exige um balanceamento cuidadoso entre a acessibilidade e a proteção dos dados.

Em muitos casos a disponibilização de dados pode ser segmentada, de modo que diferentes usuários ou sistemas tenham acesso apenas às features necessárias para suas operações específicas, minimizando o risco de exposição desnecessária de dados sensíveis. O uso de técnicas como mascaramento de dados, em que informações sensíveis são substituídas por dados fictícios em determinados contextos, pode ser uma solução eficaz para proteger informações confidenciais enquanto ainda se permite a análise e o uso dos dados em um contexto controlado.

O tratamento de dados dentro de uma Feature Store também requer atenção cuidadosa, especialmente no que diz respeito à qualidade e à conformidade. Os dados que entram na Feature Store devem ser validados e processados conforme padrões estabelecidos, garantindo que sejam precisos, consistentes e relevantes para os modelos de Machine Learning que irão consumi-los.

A implementação de processos de ETL rigorosos e o uso de metadados para rastrear a origem, a transformação e o uso das features são práticas recomendadas que ajudam a manter a qualidade dos dados. Além disso, é essencial que as Feature Stores estejam alinhadas com as políticas de conformidade regulatória, garantindo que todas as operações de dados estejam em conformidade com as leis e regulamentos aplicáveis.

Para assegurar que a governança de dados em Feature Stores seja mantida em um alto padrão, muitas organizações têm investido na criação de um Centro de Excelência de Dados e IA. Este centro atua como um hub centralizado em que as melhores práticas, políticas e ferramentas de governança de dados são desenvolvidas, implementadas e mantidas. Ele também serve como uma estrutura de suporte para garantir que todos os aspectos da governança de dados, desde o controle de acesso até a conformidade regulatória, sejam gerenciados de maneira consistente e eficaz em toda a organização.

O Centro de Excelência de Dados e IA também desempenha um papel crítico na educação e treinamento contínuo das equipes, garantindo que todos os envolvidos no gerenciamento de Feature Stores estejam cientes das políticas de governança e das melhores práticas que devem ser seguidas.

Além disso, o Centro de Excelência pode atuar como um facilitador para a inovação em governança de dados, promovendo a adoção de novas tecnologias e metodologias que podem melhorar a segurança, a eficiência e a conformidade das Feature Stores.

Por exemplo: o centro pode liderar iniciativas para implementar ferramentas avançadas de monitoramento e auditoria, que permitem uma visão mais detalhada das operações de dados e ajudam a detectar e a responder a incidentes de segurança em tempo real. Ele também pode promover a integração de práticas de inteligência artificial na governança de dados, como o uso de algoritmos de Machine Learning para

identificar anomalias nos padrões de acesso ou para automatizar o gerenciamento de políticas de conformidade.

A implementação eficaz de governança de dados em Feature Stores, apoiada por um Centro de Excelência de Dados e IA, não só protege as informações estratégicas do negócio como também garante que os modelos de Machine Learning sejam alimentados com dados de alta qualidade e em conformidade com as exigências legais.

Isso fortalece a confiança nos sistemas de Machine Learning e permite que as organizações maximizem o valor de seus dados, ao mesmo tempo em que minimizam os riscos associados ao seu uso. Portanto, a governança de dados deve ser vista não apenas como uma necessidade regulatória, mas como um componente estratégico essencial para o sucesso a longo prazo das operações de Machine Learning.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, você mergulhou nos conceitos fundamentais de armazenamento de dados, compreendendo a importância crítica que esses sistemas desempenham no suporte às operações de Machine Learning, especialmente no contexto das Feature Stores. Exploramos como os diferentes tipos de armazenamento, desde sistemas locais até arquiteturas em nuvem, influenciam a eficiência e a escalabilidade das operações de dados, destacando como uma Feature Store bem estruturada pode transformar a maneira como os dados são gerenciados e utilizados em modelos de Machine Learning. Entendemos que a escolha da arquitetura de armazenamento impacta diretamente a latência, o throughput e a durabilidade dos dados, todos aspectos essenciais para manter a consistência e a qualidade dos modelos.

Você também aprendeu sobre as diversas arquiteturas de ingestão e orquestração de dados, como as arquiteturas Lambda e Kappa, bem como as abordagens de medalhão e Data Mesh, que ajudam a organizar e gerenciar grandes volumes de dados de maneira eficiente. Foi possível perceber como as Feature Stores se integram nessas arquiteturas, fornecendo uma camada crítica que garante o acesso rápido e seguro às features, permitindo que os modelos de Machine Learning operem de forma eficaz e em tempo real. A capacidade de uma Feature Store de servir features atualizadas e relevantes em diferentes contextos arquitetônicos reforça sua importância como um componente central em qualquer estratégia de dados moderna.

Além disso, discutimos a governança de dados em Feature Stores, enfatizando a necessidade de implementar controles rigorosos de acesso e políticas de segurança para proteger informações sensíveis e estratégicas. A governança não é apenas uma questão de conformidade, mas também uma medida essencial para manter a confiança e a integridade dos dados que alimentam os modelos de Machine Learning. A criação de um Centro de Excelência de Dados e IA foi apresentada como uma estratégia eficaz para garantir que as melhores práticas de governança sejam mantidas, promovendo um ambiente de dados seguro, eficiente e alinhado com as necessidades do negócio.

Por fim, a aula destacou a interconexão entre todos esses aspectos, mostrando como uma abordagem integrada ao armazenamento de dados, à governança e à

arquitetura de Feature Stores pode maximizar o valor que uma organização extrai de seus dados.

Esta aula, não apenas ampliou seu entendimento técnico, mas também reforçou a importância de considerar o impacto estratégico e gerencial das decisões relacionadas a dados, preparando-o(a) para tomar decisões mais informadas e eficazes em seus projetos de Machine Learning.



REFERÊNCIAS

DEVLIN, B. **Data warehouse**: from architecture to implementation. [s.l.]: Addison-Wesley Longman Publishing Co., Inc., 1996.

INMON, W. H.; LINSTEDT, D. **Data architecture**: a primer for the data scientist: big data, data warehouse and data vault. [s.l.]: Morgan Kaufmann, 2014.

INMON, W. H. **Data architecture**: the information paradigm. [s.l.]: QED Information Sciences, Inc., 1992.

MAJCHRZAK, J; BALNOJAN, S; SIWIAK, M. **Data Mesh in Action**. [s.l.]: Simon and Schuster, 2023.

PALAVRAS-CHAVE

Palavras-chave: Arquitetura de Dados. Governança. Feature Store.

EMSE



POSTECH