

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	12
REFERÊNCIAS.....	13

EMSE

O QUE VEM POR AÍ?

Mergulharemos nas estratégias essenciais que moldam a arte e a ciência de lidar com dados, desde sua base até as camadas mais complexas. Vamos começar explorando como identificar e mapear fontes de dados - o alicerce para tudo o que virá a seguir – e aprenderemos a coletar e integrar dados e a aplicar práticas rigorosas de governança e qualidade. Esse conhecimento ampliará sua capacidade de influenciar decisões estratégicas em ambientes empresariais e científicos, tornando-o(a) proficiente na orquestração do ciclo de vida dos dados, desde sua coleta até a análise e o armazenamento, com um foco especial na segurança e conformidade dos dados.

Ao entender como os dados são transformados em insights valiosos, vocês estarão prontos(as) para enfrentar os desafios modernos de dados em grande escala. Preparem-se para transformar dados em decisões, explorando técnicas avançadas que garantem a precisão e a integridade das informações em cada passo do processo. Vocês terão a oportunidade de aplicar essa teoria em estudos de caso reais e simulações que replicam cenários complexos do mundo real.

HANDS ON

Nesta disciplina, exploraremos o universo da gestão de dados, um componente crítico e cada vez mais vital no mundo moderno, em que a informação é tanto uma ferramenta poderosa quanto um recurso abundante. Ao longo destas aulas, vocês serão guiados através das etapas fundamentais do processo de gestão de dados, desde o mapeamento inicial de fontes até as práticas de governança e asseguração da qualidade. Esta jornada é projetada para equipar estudantes com um arsenal de habilidades práticas e teóricas indispensáveis a qualquer profissional que lide com dados em ambientes complexos e dinâmicos.

Nesta aula, nos concentraremos em como identificar e mapear fontes de dados confiáveis, uma habilidade essencial que serve como alicerce para todas as operações de dados subsequentes. Os alunos e alunas aprenderão a classificar e avaliar dados com base em sua relevância e qualidade, o que é crucial para garantir a integridade das informações que fluem para os sistemas de análise. Esta fase inicial é fundamental para estabelecer uma base sólida para as fases mais complexas de manipulação e análise de dados.

Vocês serão introduzidos(as) a métodos e ferramentas que permitem a agregação eficiente de dados de múltiplas fontes e discutiremos estratégias para a manutenção da qualidade dos dados ao longo de seu ciclo de vida. Finalmente, dedicaremos uma atenção especial às práticas de governança de dados, um aspecto muitas vezes subestimado, mas que é crucial.

SAIBA MAIS

Estudaremos as nuances da gestão de dados, explorando conceitos e teorias que formam a espinha dorsal desta disciplina. A gestão de dados é um campo vasto que abrange desde a identificação e o mapeamento de fontes até a complexa governança e manutenção da qualidade dos dados. Cada etapa neste processo é crucial e requer uma compreensão detalhada para garantir a integridade, a segurança e a acessibilidade das informações.

O mapeamento de fontes é o ponto de partida para identificar e catalogar as fontes de dados disponíveis. Este passo é fundamental para estabelecer um entendimento claro do terreno de dados que uma organização possui. A partir daí, a coleta e a integração de dados tomam lugar como processos que não só agregam valor aos dados brutos, transformando-os em formatos úteis e acessíveis, mas que também asseguram que as informações de diferentes origens possam ser combinadas de maneira coerente e eficiente.

Além disso, a governança de dados aborda políticas e práticas que controlam acessibilidade, usabilidade, integridade e segurança dos dados coletados. Este aspecto da gestão de dados é crítico, pois lida com regulamentos e padrões que garantem o uso ético e legal das informações. Paralelamente, a qualidade dos dados é continuamente avaliada para assegurar sua adequação ao propósito, à precisão e à confiabilidade, o que é vital para sustentar decisões informadas em qualquer ambiente operacional.

Cada um desses componentes é interligado e essencial para construir uma estratégia de gestão de dados robusta. Ao entender esses conceitos em detalhes, estudantes e profissionais podem melhor navegar pelos desafios associados à gestão de grandes volumes de dados, assegurando que as informações possam ser transformadas em insights valiosos para a tomada de decisão estratégica. A importância de uma boa gestão de dados transcende os aspectos técnicos, influenciando diretamente a capacidade de inovação e a competitividade no cenário global atual.

O mapeamento de fontes de dados é mais do que apenas identificar e catalogar recursos de informação disponíveis. Ele envolve uma análise profunda para

determinar a relevância, a autenticidade e a utilidade de cada fonte de dados para as necessidades específicas de uma organização. Esta análise é crucial para garantir que o processo de gestão de dados comece com uma base sólida, permitindo que decisões futuras sobre coleta e integração sejam baseadas em informações precisas e confiáveis.

As técnicas utilizadas no mapeamento de fontes variam amplamente dependendo da natureza dos dados e do contexto operacional. Uma abordagem comum envolve a criação de um inventário detalhado que documenta não apenas a localização e o formato dos dados, mas também sua origem, frequência de atualização, pessoa responsável pela manutenção e quaisquer dependências ou restrições legais associadas. Ferramentas de software especializadas podem automatizar parte deste processo, utilizando algoritmos de varredura que identificam e classificam dados em sistemas corporativos.

Estrategicamente, o mapeamento de fontes de dados também deve considerar a integridade e a segurança dos dados desde o início. Isso inclui avaliar a vulnerabilidade das fontes de dados a acessos não autorizados ou corrupção, bem como implementar medidas de proteção adequadas. Essa abordagem proativa não só protege a organização contra riscos de segurança de dados, mas também fortalece a confiança na qualidade e na confiabilidade das informações coletadas.

Além disso, uma análise de custo-benefício é frequentemente realizada para determinar se o valor obtido a partir de uma fonte de dados específica justifica o investimento em sua coleta e manutenção. Esse aspecto é especialmente importante em ambientes nos quais os recursos são limitados e a maximização do retorno sobre o investimento em dados é crucial. A análise pode incluir considerações sobre como a integração de novas fontes de dados pode abrir novas oportunidades de negócios ou melhorar a eficiência operacional.

Identificação e classificação de dados

Prosseguindo na exploração da gestão de dados, após o mapeamento inicial de fontes, o próximo passo é a identificação e a classificação dessas fontes. Esse processo organiza os dados de maneira que suportem eficazmente a tomada de decisões e a análise posterior. A identificação envolve reconhecer e diferenciar as fontes de dados que são essenciais para os objetivos específicos da organização,

enquanto a classificação agrupa esses dados em categorias baseadas em critérios pré-definidos, como tipo de dados, sensibilidade, relevância e frequência de uso.

Uma técnica eficaz na classificação de fontes de dados é a aplicação de metadados, que fornecem informações detalhadas sobre conteúdo, contexto e estrutura dos dados. Os metadados facilitam a localização e a recuperação de dados e ajudam a entender suas inter-relações e dependências. Implementar sistemas de etiquetagem de dados e catalogação digital, em que os metadados são claramente definidos e mantidos atualizados, é essencial para sua gestão e classificação eficiente.

Além disso, a análise de valor dos dados durante a fase de identificação e classificação permite priorizar fontes com base em seu potencial de impacto nos processos de negócios. Técnicas de mineração de dados e análise preditiva podem ser utilizadas para avaliar como diferentes conjuntos de dados influenciam os resultados operacionais e estratégicos. Esta análise orientada por dados auxilia na alocação eficiente de recursos para a manutenção das fontes de dados mais valiosas.

Paralelamente, a estratégia de classificação deve considerar a conformidade com regulamentos de proteção de dados, como GDPR na Europa ou LGPD no Brasil. A categorização dos dados deve refletir suas necessidades de proteção e privacidade, agrupando dados sensíveis de forma que as políticas de segurança possam ser aplicadas de maneira uniforme e eficaz. Isso implica em classificar os dados não apenas pelo tipo de informação que contêm, mas também pelo nível de risco associado ao seu processamento e armazenamento.

Implementar um robusto sistema de classificação e identificação de fontes de dados eleva a gestão de dados de uma organização, assegurando que as informações sejam tratadas de forma eficaz e segura, desde a entrada até a análise final. À medida que avançamos, esses processos de classificação e identificação tornam-se ainda mais cruciais para a integração e o uso estratégico dos dados nas atividades operacionais e decisões de alto nível.

Coleta e pré-processamento de dados

Após a identificação e classificação das fontes de dados, a próxima etapa no ciclo de vida da gestão de dados é sua coleta e pré-processamento. Este processo é essencial para garantir que os dados coletados sejam de alta qualidade, relevantes e

prontos para análise e aplicação em decisões de negócios. A coleta de dados deve ser sistemática e rigorosa, assegurando que todas as informações capturadas sejam precisas e completas.

Técnicas de coleta variam amplamente dependendo da natureza e da fonte dos dados. Em ambientes digitais, por exemplo, APIs (Application Programming Interfaces) são frequentemente utilizadas para extrair dados de maneira programática de redes sociais, sistemas de ERP (Enterprise Resource Planning) ou outras plataformas digitais. Em contextos em que os dados não estão prontamente disponíveis em formatos digitais, técnicas de digitalização e OCR (Optical Character Recognition) podem ser empregadas para converter documentos físicos em dados digitais manipuláveis.

Uma vez coletados, os dados passam pelo pré-processamento, que é vital para sua preparação antes de serem utilizados em qualquer análise. Este estágio inclui uma variedade de técnicas como a limpeza de dados, que envolve corrigir ou remover dados incorretos, incompletos ou irrelevantes. Outras operações de pré-processamento importantes incluem a normalização, que ajusta os valores de dados a uma escala comum, e a transformação, que converte dados brutos em formatos mais úteis ou insights prontos para análise.

Além disso, a imputação de dados é uma prática comum durante o pré-processamento para lidar com valores ausentes. Métodos estatísticos como média, mediana ou modos são utilizados para substituir dados faltantes. Também podem ser empregadas técnicas mais complexas, como imputação multivariada ou algoritmos baseados em machine learning, para estimar os valores ausentes com base em padrões encontrados no conjunto de dados completo.

A integração dos dados coletados e pré-processados também é uma etapa fundamental, especialmente em organizações que operam em múltiplas plataformas ou que requerem uma visão consolidada de dados de diversas fontes. Essa integração muitas vezes envolve a consolidação de dados de vários sistemas em um repositório central, como um data warehouse ou um lago de dados, em que podem ser mais facilmente acessados e utilizados por analistas e outras partes interessadas.

Após a integração, os dados são preparados para serem utilizados em análises mais profundas ou para alimentar sistemas de relatórios e dashboards que suportam

a tomada de decisões estratégicas. A habilidade de transformar eficazmente dados brutos em informações valiosas e acionáveis é uma vantagem competitiva crítica no ambiente de negócios atual. A partir daqui, essa disciplina explorará como esses dados integrados e pré-processados podem ser efetivamente utilizados em contextos de decisão empresarial e científica, estabelecendo a ponte entre a teoria da gestão de dados e sua aplicação prática.

Com os dados coletados e devidamente pré-processados, avançamos para as etapas de integração e armazenamento, que são cruciais para manter a utilidade e a acessibilidade das informações em uma organização. A integração de dados envolve combinar dados de diferentes fontes para criar uma visão unificada, o que facilita a análise e o acesso em toda a organização. Essa tarefa é especialmente desafiadora em ambientes com sistemas heterogêneos e formatos de dados diversos, exigindo uma abordagem metódica para garantir que a integridade e o valor dos dados sejam mantidos.

Técnicas comuns de integração incluem a utilização de ferramentas ETL (Extração, Transformação e Carregamento), que permitem que os dados sejam extraídos de suas fontes originais, transformados para um formato adequado e, em seguida, carregados em um sistema de destino. Esse processo não apenas facilita a migração e a fusão de grandes volumes de dados, mas também ajuda a mantê-los consistentes, atualizados e prontamente disponíveis para uso. Além disso, estratégias como virtualização de dados podem ser empregadas para integrar dados de forma mais dinâmica sem a necessidade de replicação física, proporcionando uma camada de abstração que simplifica o acesso aos dados por usuários finais e aplicações.

Quanto ao armazenamento de dados, a escolha da solução adequada é fundamental para suportar eficientemente as operações de dados e as necessidades analíticas de uma organização. Sistemas de armazenamento podem variar desde bancos de dados relacionais tradicionais, adequados para transações que requerem integridade e segurança de dados, até soluções mais modernas como data lakes e bancos de dados NoSQL, que são mais flexíveis e escaláveis para o manejo de grandes volumes de dados não estruturados e semiestruturados.

A implementação de soluções de armazenamento em nuvem também se tornou uma prática comum, oferecendo escalabilidade, resiliência e eficiência de custos

superiores, além de facilitar a colaboração e o acesso aos dados em uma escala global.

Além disso, a governança de dados desempenha um papel importante na fase de armazenamento, assegurando que as políticas e procedimentos estejam em lugar para gerenciar a acessibilidade, a segurança e a qualidade dos dados armazenados. Isso inclui a implementação de controles rigorosos de acesso para proteger os dados contra acessos não autorizados, assim como a realização de auditorias regulares e a manutenção de logs detalhados de atividades para rastrear o uso e a modificação dos dados.

O próximo passo envolve o desenvolvimento de práticas robustas para a manutenção e o monitoramento contínuo da qualidade dos dados armazenados. Isso é vital para garantir que os dados permaneçam precisos, confiáveis e relevantes ao longo do tempo, apoiando assim todas as decisões operacionais e estratégicas que dependem dessa informação crucial. A integração e o armazenamento eficaz de dados não são apenas componentes técnicos da gestão de dados, mas sim fundamentais para o sucesso organizacional, influenciando diretamente a capacidade de uma organização de responder rapidamente a mudanças de mercado e oportunidades emergentes.

Governança e qualidade de dados

Após a integração e o armazenamento eficazes, a governança e a qualidade dos dados emergem como aspectos fundamentais para sustentar a utilidade e a confiabilidade das informações armazenadas. A governança de dados refere-se ao conjunto de políticas, procedimentos e padrões que definem a gestão responsável dos dados dentro de uma organização. Essas diretrizes são essenciais para garantir que os dados sejam usados de forma apropriada e segura, respeitando todas as regulamentações relevantes e protegendo a privacidade dos indivíduos.

Uma estratégia eficaz de governança de dados começa com a definição clara de quem detém a responsabilidade sobre os diferentes aspectos dos dados, incluindo sua qualidade, segurança e uso. Esse papel é frequentemente atribuído a um gestor de dados ou a um comitê de governança de dados, que trabalha para assegurar a adesão a todas as políticas internas e externas pertinentes.

A implementação de práticas de governança robustas ajuda a prevenir problemas de qualidade de dados, minimiza os riscos legais e melhora a tomada de decisões ao assegurar que os dados sejam precisos e acessíveis para usuários autorizados.

Paralelamente, a qualidade dos dados é uma preocupação contínua que necessita de monitoramento e manutenção regulares. As técnicas para garantir a qualidade dos dados incluem validação, limpeza, deduplicação e enriquecimento dos dados. Ferramentas e sistemas automatizados desempenham um papel crucial nesse processo, oferecendo soluções como a verificação de consistência, a correção de erros e a atualização de informações.

A qualidade é avaliada através de métricas específicas, como precisão, completude, confiabilidade e relevância, que ajudam a determinar a adequação dos dados para os processos de negócio da organização.

Além de manter a qualidade, as organizações devem também focar na transparência da gestão de dados, permitindo que stakeholders entendam como e por que os dados são coletados, processados e armazenados. Isso inclui a documentação adequada de todas as operações de dados e a comunicação clara das políticas de governança para todas as partes interessadas, tanto internas quanto externas.

A prática de governança e garantia de qualidade não termina com a implementação de políticas e sistemas; ela exige uma abordagem iterativa e contínua para adaptar-se às mudanças nas necessidades de negócios e nas regulamentações legais.

Com um foco constante na melhoria da qualidade e governança dos dados, as organizações podem maximizar o valor de seus ativos de dados e sustentar uma vantagem competitiva no mercado dinâmico de hoje. Assim, a governança e a qualidade dos dados não são apenas fundamentais para a gestão operacional, mas também para o alinhamento estratégico e a realização dos objetivos de longo prazo da organização.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, exploramos os fundamentos e as técnicas avançadas que formam a base da gestão de dados eficaz, desde o mapeamento e a identificação de fontes de dados até as práticas rigorosas de integração, armazenamento e governança. Discutimos cada etapa essencial na garantia da integridade, segurança e utilidade dos dados dentro de uma organização.

Revisamos como mapear corretamente as fontes de dados, identificando e catalogando cada uma para garantir que a coleta subsequente seja precisa e relevante. Avançamos para a coleta e o pré-processamento, em que aprendemos a limpar, normalizar e transformar dados para prepará-los para análises futuras. Também abordamos estratégias de integração e armazenamento, enfatizando a importância de sistemas robustos que suportem o acesso e análise eficientes.

Por fim, discutimos a governança e a qualidade dos dados, destacando como a implementação de políticas rigorosas e práticas de manutenção da qualidade são cruciais para a sustentação de decisões estratégicas e operacionais informadas. Esta aula ofereceu uma visão abrangente da gestão de dados, equipando você com o conhecimento necessário para enfrentar os desafios do mundo real e maximizar o valor dos dados em seu ambiente profissional.

REFERÊNCIAS

BRINEY, K. **Data Management for Researchers**: Organize, Maintain and Share Your Data for Research Success. [s.l.]: Elsevier, 2015.

DAMA International. **The DAMA Guide to the Data Management Body of Knowledge (DAMA-DMBOK)**. [s.l.]: Technics Publications, 2009.


LADLEY, J. **Data Governance**: How to Design, Deploy and Sustain an Effective Data Governance Program. [s.l.]: Elsevier, 2012.

EMAP

PALAVRAS-CHAVE

Palavras-chave: ML Hands On. Gestão de Dados. Integração. Armazenamento.

EMSE



POSTECH