

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS.....	12

EMSE

O QUE VEM POR AÍ?

Exploraremos como as Feature Stores revolucionam a preparação de dados, oferecendo soluções ágeis e robustas para o manejo de características necessárias ao treinamento e inferência em modelos de ML. Vamos descobrir como projetar, construir e manter uma Feature Store, integrando-a eficazmente com pipelines de Machine Learning para otimizar a eficiência e a escalabilidade das operações.

O conteúdo desta aula foi cuidadosamente preparado para fornecer insights práticos e técnicos sobre os desafios e soluções relacionados a Feature Stores. Exploraremos métodos de engenharia de features, abordaremos práticas essenciais de monitoramento, manutenção e segurança e aprenderemos como estabelecer uma governança eficaz.

Equiparemos você com as habilidades necessárias para implementar e gerenciar essa poderosa ferramenta no cenário competitivo do Machine Learning moderno. Venha preparada(o) para transformar informação em ação, inovando em seus projetos de ML.

HANDS ON

Nesta sessão Hands On, você terá a chance de explorar como projetar, configurar e operacionalizar uma Feature Store, integrando-a com pipelines de ML existentes. As atividades são projetadas para fornecer uma compreensão profunda e aplicada das funcionalidades e desafios associados à implementação de Feature Stores em ambientes de produção de ML.

Exploraremos os conceitos básicos das Feature Stores, aprendendo sobre a arquitetura desses sistemas e como eles podem ser utilizados para melhorar a eficiência dos pipelines de ML. Depois, nos aprofundaremos nos aspectos técnicos da engenharia de features e nas práticas de armazenamento eficiente em uma Feature Store. Veremos também como integrar uma Feature Store com pipelines de ML existentes e, em seguida, abordaremos a configuração de workflows de dados.

Depois, focaremos no monitoramento e manutenção de Feature Stores. Por fim, discutiremos as práticas de segurança e governança necessárias para operar Feature Stores em ambientes regulados.

SAIBA MAIS

No panorama atual de Machine Learning, as Feature Stores surgem como componentes essenciais, atuando como catalisadoras na transição de modelos experimentais para sistemas de ML robustos e escaláveis em produção. Essas plataformas especializadas não apenas armazenam e gerenciam características de dados, mas também asseguram a consistência e a reutilização de features entre diferentes modelos e processos de ML. A importância das Feature Stores reside na sua capacidade de facilitar o gerenciamento de dados de forma que as features sejam consistentes, versionadas e acessíveis em tempo real para aplicações de treinamento e inferência.

Uma Feature Store eficaz elimina redundâncias na preparação de dados e reduz significativamente o tempo de engenharia necessário para novos projetos de ML, permitindo que cientistas de dados e engenheiros(as) se concentrem mais na experimentação e inovação e menos na logística de dados. Além disso, ao centralizar as features, garantimos que todos os modelos treinados e em produção estejam alinhados usando as mesmas definições de dados, o que reduz erros e melhora a performance dos modelos. Esse aspecto é crucial para operações de ML em grande escala, especialmente em ambientes empresariais em que consistência e precisão são fundamentais.

As Feature Stores também desempenham um papel vital na governança e no compliance de dados, oferecendo ferramentas que ajudam a monitorar, catalogar e controlar o acesso a features. Isso é especialmente importante em indústrias reguladas, como finanças e saúde, em que o manejo correto dos dados é crítico. Com funções avançadas de auditoria e rastreamento de versionamento, as Feature Stores ajudam as organizações a manterem conformidade com regulamentações de privacidade e segurança de dados.

Para quem deseja se aprofundar no estudo das Feature Stores, recomenda-se explorar recursos como o livro "Machine Learning Engineering" de Andriy Burkov, que oferece insights sobre como estruturar sistemas de ML em produção, incluindo o uso de Feature Stores. Artigos e postagens em plataformas como Medium e Towards Data Science também fornecem estudos de caso e tutoriais práticos que podem complementar o aprendizado. Além disso, sites de grandes empresas de tecnologia,

como Google e Amazon, frequentemente publicam whitepapers e guias sobre suas próprias implementações de Feature Stores, oferecendo uma perspectiva valiosa sobre como essas soluções são empregadas em escala.

Com a crescente complexidade e volume de projetos de ML, a necessidade de soluções como as Feature Stores só tende a aumentar. Este segmento do curso não apenas prepara você para entender e implementar essas plataformas, mas também para reconhecer o impacto transformador que elas podem ter na eficiência e eficácia das operações de Machine Learning modernas. Exploraremos as nuances técnicas e estratégicas das Feature Stores, preparando você para utilizar essas ferramentas em seus próprios projetos de ML.

Features

Features, ou características, são elementos cruciais em modelos de Machine Learning, representando informações que são extraídas dos dados brutos e usadas como insumos para modelos preditivos. Essas características permitem que algoritmos identifiquem padrões ou tendências nos dados que são fundamentais para realizar previsões ou classificações eficazes. A criação de features é um processo conhecido como engenharia de features, que envolve várias técnicas para transformar e preparar os dados de maneira que maximizem a performance do modelo.

O processo de criação de features começa com a análise dos dados brutos disponíveis e a identificação de elementos que podem ser úteis para o modelo. Isso pode envolver a extração de novas informações a partir de dados já existentes, como transformar uma data em componentes como dia, mês e ano, ou calcular a média de um conjunto de valores. Além disso, técnicas de transformação são aplicadas para ajustar a escala ou a distribuição das features, como a normalização ou a aplicação de transformações logarítmicas, que ajudam a lidar com variações extremas nos dados e melhoram a capacidade do modelo de aprender eficientemente.

Outro aspecto importante na criação de features é a seleção das mais relevantes. Nem todas as características extraídas ou criadas são úteis para o modelo e algumas podem até degradar a sua performance devido a ruído ou redundância. Técnicas de seleção de features são empregadas para identificar quais características têm a maior correlação com a variável alvo, ou seja, aquelas que são verdadeiramente importantes para a previsão. Isso não só simplifica o modelo, tornando-o mais rápido

e menos propenso a overfitting, como também torna o processo de modelagem mais eficiente e eficaz.

Uma vez que um padrão é identificado e codificado por meio de features, ele pode ser reutilizado. Essa reutilização é vantajosa especialmente em cenários nos quais modelos semelhantes são desenvolvidos ou quando os modelos precisam ser atualizados frequentemente com novos dados. A capacidade de reutilizar padrões economiza tempo e recursos, permitindo que modelos sejam rapidamente adaptados sem a necessidade de redefinir todo o processo de engenharia de features.

A eficácia de reutilizar padrões identificados em features também se estende à manutenção e evolução de sistemas de Machine Learning. À medida que mais dados se tornam disponíveis ou que os padrões de dados mudam, a estrutura base de features bem definida pode ser ajustada e refinada. Isso permite que o modelo evolua sem grandes revisões, garantindo que as decisões baseadas nele se mantenham relevantes e precisas. Portanto, entender e aplicar eficazmente a engenharia de features não é apenas sobre a criação de um bom modelo inicial, mas sobre estabelecer uma fundação sólida que suporte o crescimento e a inovação contínuos no campo do Machine Learning.

Features precisam não apenas ser bem projetadas, mas também bem armazenadas e integradas em pipelines de ML para garantir eficácia operacional. Uma estrutura de armazenamento eficiente para features é vital, pois influencia diretamente a velocidade e a eficiência com que os modelos de ML podem acessar e utilizar esses dados. O armazenamento deve ser projetado para lidar com o volume, a variedade e a velocidade dos dados modernos, garantindo que as features estejam disponíveis em tempo real e em escala.

O armazenamento de features geralmente se dá em sistemas que podem fornecer acesso rápido e eficiente, como bancos de dados especializados ou plataformas de dados distribuídas. Esses sistemas são escolhidos com base na capacidade de realizar operações de leitura e gravação rápidas, suportar consultas complexas e lidar com grandes volumes de dados sem degradar o desempenho. Além disso, a escolha da tecnologia de armazenamento muitas vezes reflete a necessidade de integração com sistemas de ML existentes, facilitando o fluxo de dados entre a engenharia de features e o treinamento de modelos.

A integração de uma estrutura de armazenamento de features com pipelines de ML é um passo crítico que deve ser tratado com uma abordagem sistemática. Essa integração assegura que os dados necessários para treinar e inferir modelos estejam acessíveis de maneira formatada e pronta para uso. Isso é comumente realizado através da implementação de APIs ou interfaces de programação que permitem que os sistemas de ML solicitem e recebam features de forma dinâmica. Essa capacidade de integração permite que as atualizações nas features sejam rapidamente propagadas para os modelos em produção, melhorando a agilidade e a precisão das previsões.

Para garantir que a estrutura de armazenamento e a integração sejam eficazes, é essencial que as features sejam armazenadas de forma que preservem a integridade e a consistência dos dados. Isso envolve práticas como versionamento de features, em que cada mudança em uma feature é rastreada e versionada, permitindo que modelos antigos sejam recriados ou novos modelos sejam treinados com versões consistentes de dados. Essa prática ajuda na reprodução e na auditoria de resultados de modelos, além de cumprir com requisitos regulatórios e de compliance.

Por último, a manutenção da estrutura de armazenamento de features deve ser uma consideração contínua. À medida que os modelos evoluem e novas features são desenvolvidas, o sistema de armazenamento precisa adaptar-se para acomodar essas mudanças. Isso pode envolver desde a expansão da capacidade de armazenamento até a otimização das estruturas de dados para melhorar o desempenho. A manutenção proativa assegura que a infraestrutura de features continue a apoiar as necessidades do negócio e dos modelos de ML, permitindo que as organizações maximizem o valor de seus investimentos em dados e tecnologia.

Governança e conformidade para Feature Stores

Em ambientes de Machine Learning operacional, ou ML Ops, a governança e a conformidade são aspectos críticos que influenciam diretamente a gestão de Feature Stores. As features, que são as variáveis derivadas de dados brutos e utilizadas para treinar modelos de Machine Learning, necessitam de um gerenciamento rigoroso para garantir que atendam aos requisitos regulatórios e de política interna das organizações. A conformidade e a governança em Feature Stores envolvem a implementação de controles que asseguram a integridade, a segurança e

a privacidade das informações, o que é especialmente vital em setores altamente regulados como finanças, saúde e serviços públicos.

O primeiro passo para garantir a conformidade em uma Feature Store é estabelecer um sistema robusto de gerenciamento de metadados. Isso inclui documentar a origem dos dados, os métodos de processamento e as transformações que cada feature sofreu antes de ser armazenada. Essa documentação facilita a rastreabilidade dos dados e ajuda a garantir que todas as operações possam ser auditadas. Além disso, os metadados podem fornecer insights sobre a qualidade dos dados, ajudando a identificar e mitigar quaisquer problemas que possam afetar a precisão dos modelos de Machine Learning.

Além do gerenciamento de metadados, a implementação de políticas de acesso é crucial para a governança de Feature Stores. É preciso controlar quem pode acessar ou modificar as features armazenadas, protegendo contra acessos não autorizados e garantindo que apenas usuários aprovados possam manipular os dados. Isso é geralmente realizado através de sistemas de controle de acesso baseados em roles (papéis), em que diferentes níveis de permissões são atribuídos dependendo do papel do usuário no projeto ou na organização.

Outro aspecto importante da governança em Feature Stores é o monitoramento contínuo da qualidade dos dados. Isso envolve verificar a consistência, a completude e a precisão das features ao longo do tempo. Sistemas de alerta podem ser configurados para notificar administradores quando os dados não cumprirem os critérios de qualidade estabelecidos, permitindo intervenções rápidas para corrigir qualquer desvio antes que afete o desempenho dos modelos de ML. Esse monitoramento ajuda a manter a confiabilidade dos sistemas de Machine Learning e garantir que as decisões baseadas nos modelos sejam fundamentadas em dados de alta qualidade.

Ainda, a conformidade regulatória é assegurada através da implementação de práticas que estão em consonância com as leis de proteção de dados, como GDPR na Europa ou CCPA na Califórnia. Isso inclui técnicas como a anonimização de dados sensíveis, a criptografia de dados em repouso e em trânsito e a realização de auditorias regulares. Adotar essas práticas não só protege a organização contra riscos legais e financeiros como também fortalece a confiança de stakeholders no uso ético e responsável dos dados. Estabelecer e manter um regime de conformidade e

governança eficaz em Feature Stores é, portanto, essencial para operações de ML bem-sucedidas e responsáveis.

EXEMPLO

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, exploramos o conceito fundamental e a operacionalidade das Feature Stores dentro do contexto de Machine Learning. Discutimos como essas plataformas centralizadas não apenas facilitam o armazenamento, o gerenciamento e a reutilização de features, mas também garantem a consistência e a disponibilidade dos dados para treinamento e inferência de modelos em tempo real.

Além disso, abordamos as técnicas de engenharia de features, a importância da integração de Feature Stores com pipelines de ML e as melhores práticas para monitoramento e manutenção desses sistemas.

Discutimos também as práticas de segurança e governança, que são essenciais para manter a integridade e a confidencialidade dos dados dentro de ambientes regulamentados. Por fim, reforçamos a importância de uma Feature Store bem gerida para a eficiência e a escalabilidade das operações de Machine Learning, ressaltando como uma gestão de dados robusta pode impulsionar a inovação e a competitividade no cenário de tecnologia atual.

REFERÊNCIAS

KLEPPMANN, M. **Designing Data-Intensive Applications**. Sebastopol: O'Reilly Media, 2017.

CHAMBERS, B.; ZAHARIA, M. **Spark: The Definitive Guide**. Sebastopol: O'Reilly Media, 2018.


BURKOV, A. **Machine Learning Engineering**. [s.l.]: True Positive Inc., 2020.

KUMAR, J. **Feature Stores for Machine Learning**. Birmingham: Packt, 2021.

PALAVRAS-CHAVE

Palavras-chave: ML Ops. Engenharia de Features. Armazenamento. Gerenciamento. Reutilização.

EMENDAS



POSTECH