

MACHINE LEARNING ENGINEERING

FASE 5 | AULA 01 -

INTRODUÇÃO A MLOPS

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS.....	12

EMSE

O QUE VEM POR AÍ?

Existem várias etapas de desenvolvimento e pontos de atenção quando pensamos em resolver os problemas do negócio utilizando modelos de aprendizado de máquina. Nesta aula, veremos quais são essas etapas e pontos de atenção, assim como sua relevância e importância para a construção de soluções seguras, escaláveis e de fácil manutenção.

Para isso, vamos introduzir o termo da literatura MLOps (do inglês, Machine Learning Operations), que traz definições e explicações sobre esses tópicos.

HANDS ON

Nesta aula vamos aprender sobre o termo MLOps, que compreende todo ciclo de vida que permeia uma solução de aprendizado de máquina.

EMEND

SAIBA MAIS

As soluções de aprendizagem de máquina (ou em inglês, machine learning - ML) normalmente começam a ser prototipadas em um computador local (exemplo: Desktop), e quando provado o valor da solução, começamos a realizar o processo conhecido como implantação (em inglês, deploy), onde disponibilizamos o modelo em um servidor para consumo dos clientes.

Entretanto, esse processo é muito mais complexo do que parece, pois envolve diversas disciplinas da área de TI, como rede de computadores, segurança, engenharia de software e ciência de dados. Não basta disponibilizar esse modelo para o consumo dos clientes, precisamos pensar em como garantir a qualidade das respostas, manutenibilidade do software, atualização do modelo entre vários outros aspectos.

Para lidar com essa complexidade, isto é, orquestrar a solução como um todo, nasceu o termo **MLOps** (do inglês, Machine Learning Operations), o qual pode ser uma função desempenhada por alguém dentro de uma empresa, com a responsabilidade de pensar na solução de forma mais abrangente.

O termo MLOps vem de **DevOps**, o qual consiste em orquestrar um sistema de forma que os ciclos de desenvolvimento sejam menores, e a velocidade de implantação seja maior, garantindo que todas as versões de todos artefatos produzidos nesse processo sejam confiáveis. Entretanto, a principal diferença entre MLOps e DevOps, são os artefatos operados. Enquanto DevOps lida somente com o código fonte, MLOps precisa manusear os dados e modelos, os quais são intrínsecos de sistemas de ML, conforme mostra a Figura 1.




Figura 1 - Artefatos de um sistema de engenharia de software clássico vs um sistema de aprendizagem de máquina

Fonte: Elaborado pelo autor (2024)

Agora, vamos nos aprofundar nessas diferenças: não basta apenas versionar o código, precisamos versionar também os dados utilizados e o modelo selecionado, problemas que, muitas vezes, precisam de ferramentas específicas. Além disso, a resposta dos modelos pode não ser determinística, isto é, a resposta é baseada em probabilidades (um exemplo disso são os modelos de linguagem como o ChatGPT), logo existe um risco de a solução não responder como esperado, algo inexistente em softwares clássicos. A figura a seguir mostra um exemplo de como avaliar esse risco quantitativamente, dependendo da criticidade do problema e da probabilidade do evento inesperado acontecer.

5 x 5 risk matrix

Probability ↑	Highly probable	5 Moderate	10 Major	15 Major	20 Severe	25 Severe
	Probable	4 Moderate	8 Moderate	12 Major	16 Major	20 Severe
	Possible	3 Minor	6 Moderate	9 Moderate	12 Major	15 Major
	Unlikely	2 Minor	4 Moderate	6 Moderate	8 Moderate	10 Major
	Rare	1 Minor	2 Minor	3 Minor	5 Moderate	6 Moderate
		Very low	Low	Medium	High	Very high
		Impact →				

Figura 2 - Tabela que ajuda a tomar decisões quantitativas quanto ao risco do modelo empregado, levando em consideração a probabilidade e o impacto

Fonte: TREVEIL, Mark et al. Introducing MLOps (2020)

Por último, os modelos são treinados em um conjunto de dados que tem uma certa distribuição, porém, a distribuição dos dados está mudando a todo momento, o que significa que mesmo fazendo tudo corretamente, a sua aplicação pode falhar somente pelo fato de que fatores externos e desconhecidos podem estar alterando a distribuição dos dados (para exemplos reais desses cenários, assista a videoaula 1).

Começamos a perceber que um sistema de ML é complexo. Apesar de certa similaridade com software clássico, existem etapas e componentes específicos para lidar com os dados e modelos, conforme mostra a figura a seguir:




Figura 3 - Alguns componentes de um sistema de ML

Fonte: Adaptado de MLOps: pipelines de entrega contínua e automação no aprendizado de máquina (2020)

Vamos visualizar o processo, conforme mostra a próxima figura. Nela, temos um sistema de ML que exemplifica a ordem na qual os artefatos (código, dados e modelos) são gerados e consumidos ao longo do processo de desenvolvimento de uma solução de aprendizado de máquina.




Figura 4 - Exemplo de visão de como os artefatos de MLOps interagem nas etapas de um sistema de ML

Fonte: adaptado de "Continuous Delivery for Machine Learning", (2024)

Inicialmente, no estado de **Construção**, geramos vários modelos usando códigos e dados de treino. Depois, seguimos para um estado de **Validação e Experimentação**, onde selecionamos o melhor modelo utilizando os dados de teste

e métricas de interesse. Em seguida, no estado de **Teste**, construímos um código que vai testar esse modelo utilizando como entrada os mesmos dados de teste do estado de Validação e Experimentação. Dessa forma, é gerado um modelo validado. Esse modelo então passa para a fase de **Implantação**, a qual junta o código da aplicação com o modelo validado, resultando na aplicação que atende aos usuários finais. Finalmente, na fase de **Monitoração e Observabilidade**, os usuários utilizam essa aplicação e geram dados (logs de utilização) que podem ser retroalimentados no estado de Construção, visando melhorar o desempenho da solução como um todo.

A depender do nível de maturidade e momento da empresa (ou projeto), os estados utilizados podem variar, alguns podem ser manuais enquanto outros podem ser automáticos, ou então pode-se não se passar por um estado específico devido alguma restrição do contexto, como prazo ou orçamento, por exemplo. Portanto, em vez de focarmos nos sistemas em si nesta disciplina (os quais podem variar muito), priorizaremos explorar e compreender os princípios de MLOps: **Versionamento, Teste, Automação e Reprodutibilidade**. Novamente, visando facilitar o entendimento, vamos pensar nesses princípios estudando como os artefatos do sistema de ML passam por esses estados:

- Modelo
 - Versionar: pesos do modelo (objeto), hiperparâmetros e pipeline de treino.
 - Testar: especificação de interface (entrada e saída do modelo e respeitada), esteira de treino do modelo e testes não funcionais. Exemplo: segurança, viés, interpretabilidade.
 - Automação: utilização de CI/CD para esteira de treino e seleção de hiperparâmetros.
 - Reprodutibilidade: documentação e validação entre ambientes. Exemplo: desenvolvimento e produção.
- Código:
 - Versionar: código da aplicação, configuração.
 - Testar: teste unitário e integração
 - Automação: utilização de CI/CD no código fonte.

- Reprodutibilidade: utilização de containers ou máquinas virtuais.
- Dados:
 - Versionar: utilização de Feature Store, metadados e código de processamento de dados.
 - Testar: teste unitário e checar desvio de dados (em inglês, data drift).
 - Automação: utilização de CI/CD para processamento de dados.
 - Reprodutibilidade: documentação e Backup.

Vamos ver as etapas comuns dos estados descritos anteriormente. Por enquanto, não vamos nos preocupar com os artefatos já mencionados (não esqueça de assistir a videoaula 1 para obter mais informações das etapas descritas).

Construção

- Coleta de dados: identificar a localização dos dados, obter acesso a eles e determinar o melhor local para armazená-los.
- Processamento de dados: mapear as várias estruturas dos dados (schemas), excluir dados sensíveis, gerar atributos, entre várias outras etapas.
- Aumento de dados: pode ser necessário aumentar a quantidade de dados com marcados (com labels).
- Análise de dados: entender se as premissas do problema são satisfeitas analisando a qualidade dos dados.
- Seleção de modelos: escolher um modelo que cumpra os requisitos, geralmente considerando a complexidade, a interpretabilidade e as restrições do ambiente de implantação.
- Treinamento: analisar e escolher a metodologia de treino levando em consideração o custo computacional, o tempo de treinamento e o impacto ambiental.

Validação e Experimentação

- Codificação de requisitos: avaliar métricas de desempenho do modelo de negócio.

- Verificação formal: assegura que a funcionalidade do software atenda aos requisitos do projeto. Pode envolver provas matemáticas ou estimativas numéricas dos limites de erro de saída.

Teste:

- Testes unitários: teste da interface do modelo, teste de códigos auxiliares e teste de casos de ponta.
- Validação de boas práticas de código: documentação do código, utilização de Linters, utilização de frameworks de segurança, entre outros.

Implantação:

- Testes de integração: teste de comunicação da aplicação com o resto do sistema.
- Promoção: atualização do modelo em produção.

Monitoração e Observabilidade:

- Loggings: entender porquê o problema ocorreu na aplicação.
- Tracing: entender onde o problema ocorreu na aplicação.
- Alarmes: entender se existe um problema na aplicação.

Por último, vale relembrar que existem aspectos transversais que permeiam todos os estados e etapas como ética (autoria, responsabilidade e vieses), leis e confiabilidade e segurança do sistema.

Nesta disciplina, vamos construir uma solução de ML usando como base a Figura 4. Entretanto, existem diferentes áreas do conhecimento envolvidas e, sendo assim, veremos na aula 2 que não se faz nada sozinho. Vamos manter o escopo desta disciplina nos princípios básicos de MLOps construindo um microserviço de aprendizagem de máquina que não passa por todas essas etapas.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula você conheceu um pouco sobre a origem do termo MLOps, assim como seus princípios, artefatos, estados e etapas. Além disso, vimos como tudo isso se comunica quando estamos construindo um sistema de ML ponta a ponta.

EMEND

REFERÊNCIAS

MLOPS: pipelines de entrega contínua e automação no aprendizado de máquina. **Google Cloud**. 2023. Disponível em: <https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning?hl=pt-br>. Acesso em: 09 set. 2024.

PALEYES, A.; URMA, R, G.; LAWRENCE, N, D. Challenges in deploying machine learning: a survey of case studies. **ACM computing surveys**, v. 55, n. 6, p. 1-29, 2022.


SATO, D. **Continuous Delivery for Machine Learning**. 2019. Disponível em: <https://martinfowler.com/articles/cd4ml.html>. Acesso em: 09 set. 2024.

TREVEIL, Mark et al. **Introducing MLOps**. O'Reilly Media, 2020.

PALAVRAS-CHAVE

Palavras-chave: Aprendizado de máquina. Implantação de Software. MLOps.

EMEND



POSTECH