

MACHINE LEARNING ENGINEERING

FASE 5 | AULA 09 -

MONITORAMENTO GESTÃO E SEGURANÇA DE MODELOS

SUMÁRIO

O QUE VEM POR AÍ?3

HANDS ON4

SAIBA MAIS5

O QUE VOCÊ VIU NESTA AULA?11

REFERÊNCIAS.....12



O QUE VEM POR AÍ?

Nessa aula vamos aprender sobre conceitos que permeiam a construção da nossa aplicação, isto é, vamos aprender sobre monitoramento, gestão e segurança no contexto de aplicações voltadas ao aprendizado de máquina.



HANDS ON

O objetivo desta aula prática é explorar conceitos fundamentais para a construção e manutenção de aplicações voltadas ao aprendizado de máquina, com foco em monitoramento, gestão e segurança.



SAIBA MAIS

Vamos começar falando sobre o tema de monitoramento, o qual consiste no processo de coleta, análise e apresentação de informações sobre nossa aplicação como um todo. Precisamos lembrar que normalmente o nosso objetivo final não é a construção de um modelo, mas sim de um produto. Por sua vez, o produto é composto por vários componentes e todos precisam ser monitorados.

Monitorar é uma prática comum, pois ajuda a identificar problemas, falhas ou tendências indesejadas, fornecendo alertas e relatórios que possibilitam a tomada de decisões adequadas para a manutenção, otimização ou solução de problemas. A forma mais básica de monitoramento envolve a utilização de alarmes, cujo objetivo é avisar que algo inesperado está acontecendo. Entretanto, não basta somente saber que o problema está ocorrendo, às vezes é necessário entender onde está o problema, pergunta que pode ser respondida com a utilização de Tracings. Ele consiste em um conjunto de SPAN de tempo em cada componente de uma aplicação após feita uma requisição utilizando um identificador de correlação (que pode ser uma string identificadora da requisição, e que permeia todas as comunicações realizadas pela aplicação), conforme ilustra a Figura 1:




Figura 1 - Exemplo de Tracing de uma aplicação com cinco componentes (A, B, C, D e E)
Fonte: Elaborado pelo autor (2024)

Por último, após encontrar o problema, é fundamental investigar suas causas. Para isso, precisamos de logs, que são registros detalhados das atividades do sistema, armazenados em arquivos de texto em um formato estruturado, permitindo uma análise posterior. Vale comentar que a depender da sua aplicação, existem certas informações que não devem ser salvas. Além disso, devemos sempre lembrar que o logging ocupa espaço em disco da máquina, e isso precisa ser levado em conta pelos desenvolvedores e desenvolvedoras.

Esses três recursos de monitoração podem ser utilizados em uma gama de contextos, mas agora vamos explorar um pouco mais sobre como devemos monitorar modelos de aprendizado de máquina. O básico a ser monitorado em um modelo de aprendizado de máquina é o seu desempenho, o que pode ser uma tarefa árdua, uma vez que - provavelmente - algum ser humano precisará validar as respostas do modelo para poder gerar uma métrica. Entretanto, pode ser que o desempenho caia devido a uma mudança de comportamento dos dados em produção, conceito conhecido como **data drift**.

É possível monitorar os dados de entrada do modelo e mensurar quão diferente eles são dos dados utilizados durante a fase de treinamento, o que pode ser combinado com alertas para avisar alguém da equipe responsável, ou executar novamente (de maneira automática), o treino do modelo com os novos dados. Porém, nem sempre o desempenho é o que importa, é importante monitorar também os vieses do modelo, uma vez que eles são treinados em dados que podem possuir padrões que não sejam éticos, como por exemplo, garantir que uma aplicação de reconhecimento facial seja imparcial e ofereça a mesma precisão para todas as pessoas, sem discriminação por raça, gênero ou outras características.

Tudo isso permite que um sistema seja facilmente compreendido e diagnosticado, assim sendo, os usuários podem obter insights valiosos sobre o comportamento e desempenho do sistema analisado. Finalmente, é importante adotar ferramentas e plataformas que forneçam uma análise avançada e visualizações intuitivas, facilitando a identificação de padrões e problemas. Pode-se utilizar, por exemplo, ferramentas como: Grafana, ElasticSearch, OpenTelemetry entre outras.

Agora, vamos falar sobre gestão de modelos. Existem várias formas de se imaginar a gestão de um modelo a depender das especificidades do problema e

contexto encontrado. Entretanto, o principal para a maioria dos casos consiste em três perguntas importantes:

- Como vamos disponibilizar o modelo (Inferência)?
- Como vamos trocar a versão que está sendo utilizada pelo modelo (Promoção)?
- Como vamos treinar um novo modelo (Treinamento)?

Essas três perguntas se conectam, conforme exemplificado na Figura 2:




Figura 2 - Principais funcionalidades para gestão de um modelo

Fonte: Elaborado pelo autor (2024)

Inicialmente, uma interface existe para permitir ao funcionário a interação com a aplicação. Ele é capaz de solicitar um treino de um modelo existente e a aplicação de treinamento é capaz de recolher os dados e salvar o modelo treinado. Além disso, o funcionário também é capaz de solicitar a troca do modelo que está servindo os clientes. Por último, os clientes têm a sua própria interface, que permite que eles consumam o modelo disponibilizado.

Para finalizar esta aula, vamos conversar um pouco sobre segurança em aplicações que utilizam um modelo. Um dos temas recorrentes em segurança é o

processo de controle de acesso, o qual consiste em aplicar autenticação e autorização quando necessário. A Figura 3 exemplifica a diferença entre autenticação e autorização. Basicamente, autenticar é o processo de identificar o usuário, mas isso não significa que ele tenha permissão para realizar qualquer ação. A definição dessas permissões é o que chamamos de autorização.




Figura 3 - Autenticação vs Autorização
Fonte: Elaborado pelo autor (2024)

Um dos padrões de autenticação muito utilizados são os serviços de STS (do inglês, “Simple Token Service”). A Figura 4 explica como esse padrão funciona.




Figura 4 - Autenticação vs Autorização
Fonte: Elaborado pelo autor (2024)

Inicialmente, o usuário chama o serviço de STS, que retorna um token com um tempo definido para expirar. Enquanto o tempo não se esgotar, é possível utilizar esse Token em outras chamadas, isto é, fazendo chamadas autenticadas.

A segurança consiste também em pensar nos casos improváveis, e a depender da aplicação, pode ser necessário a construção de camadas redundantes de segurança. Aplicações que utilizam dados PII (do inglês, "Personal Identifiable Information"), como por exemplo: nome, e-mail e CPF, são um desses casos. Imagine que, caso alguém ultrapasse as primeiras camadas de segurança e consiga acesso aos dados salvos na aplicação, esses dados não devem possuir informações PII. Portanto, em alguns dados, pode ser interessante salvá-los de maneira mascarada, conforme mostra a Figura 5:




Figura 5 - Como salvar (fazer o log) de dados PII corretamente
Fonte: Elaborado pelo autor (2024)

Os temas abordados sobre segurança até então, são gerais e aplicáveis para a maioria dos tipos de aplicação existentes. Entretanto, aplicações que utilizam modelos também devem levar em consideração ataques diretos ao modelo. Machine Learning Adversarial (AML) é um campo de estudo dentro da inteligência artificial focado em identificar e mitigar vulnerabilidades em modelos de machine learning que podem ser exploradas por atacantes. O objetivo da AML é criar modelos mais robustos e seguros contra ataques que manipulam dados de entrada para gerar previsões incorretas ou para extrair informações sensíveis, conforme ilustra a Figura 6:




Figura 6 - Exemplo de ataque ao modelo para extrair uma saída equivocada do modelo
Fonte: Elaborado pelo autor (2024)

Existem diferentes tipos de ataques adversários, classificados em ataques de caixa branca (onde o invasor tem acesso total ao modelo), e ataques de caixa preta (onde o conhecimento do invasor sobre o modelo é limitado). Para defender os modelos contra esses ataques, várias estratégias podem ser implementadas, como o treinamento adversarial, que expõe o modelo a exemplos adversários durante o treinamento, e o mascaramento de gradiente (mais complexo), que busca dificultar a exploração das vulnerabilidades. Vale lembrar que o uso de modelos mais simples e interpretáveis, o que facilita a proteção, também pode ser uma alternativa.

O QUE VOCÊ VIU NESTA AULA?

Nessa aula, você aprendeu os principais termos relacionados a monitoramento, gestão e segurança de modelos de Machine Learning.

EMEND

REFERÊNCIAS

BEYER, B. et al. **Site reliability engineering**: How Google runs production systems. [s.l.]: O'Reilly Media, Inc., 2016.

BROWN, Tom B. et al. **Adversarial patch**. arXiv preprint arXiv:1712.09665, 2017.


DATA CAMP. **O que é machine learning adversarial?** 2024. Disponível em: <<https://www.datacamp.com/pt/blog/adversarial-machine-learning>>. Acesso em: 11 set. 2024.

VERICODE. **Monitoramento e observabilidade**. 2023. Disponível em: <<https://blog.vericode.com.br/monitoramento-e-observabilidade/>>. Acesso em: 11 set. 2024.

PALAVRAS-CHAVE

Palavras-chave: Monitoração de Sistemas. Gestão de Modelos. Segurança de Modelos.

EMENDAS



POSTECH